2025 年北京理工大学数学建模竞赛

参赛承诺书

提交包含此承诺书的 pdf 文件，表明所有此文件的作者共同承诺：

我们完全清楚，在竞赛开始后参赛队员不能以任何方式，包括电话、电子邮件、“贴吧”、QQ 群、微信群等，与队外的任何人（包括指导教师）交流、讨论与赛题有关的问题；无论主动参与讨论还是被动接收讨论信息都是严重违反竞赛纪律的行为。

我们以中国大学生名誉和诚信郑重承诺，严格遵守竞赛章程和参赛规则，以保证竞赛的公正、公平性。如有违反竞赛章程和参赛规则的行为，我们将受到严肃处理。

我们授权北京理工大学数学建模竞赛组织方，可将我们的论文以任何形式进行公开展示（包括进行网上公示，在书籍、期刊和其他媒体进行正式或非正式发表等）。

2025.3

“见微知著”——基于 Airbnb 平台的纽约市短租市场数据分析与优化研究

摘要：本文基于 Airbnb 平台纽约市短租市场数据，采用回归分析与聚类分析等方法，系统研究了房屋短租市场的内在特征与规律。研究首先通过主成分分析对多维评价指标进行降维处理，构建房源热度的综合指标；其次运用 K-means 聚类算法（基于肘部法则确定最优类别数）识别出三类具有显著差异的细分市场；进一步建立考虑空间效应的回归模型，定量分析地理位置、房源属性等因素对价格和入住率的影响。空间自相关性分析（Moran's I 和 General G 指数）表明，纽约市房租均价呈现显著的空间集聚特征，而入住率的空间依赖性较弱。最后，基于模型结果以及卡尔曼滤波的思想，研究构建了收益最大化函数，通过求导分析以及理论值与预测值的加权处理，得出不同区域的最优定价策略。

研究发现：1）核心商业区房源价格显著高于周边区域，呈现典型的"中心-外围"分布格局；2）房源类型与区位特征的交互作用对定价影响显著，其中区位因素的贡献度约为房源属性的 2-3 倍；3）最优定价策略存在区域异质性，需结合当地市场竞争状况和政策环境进行调整。本研究不仅为短租市场的理论分析提供了新的方法论框架，也为房东的定价决策和平台运营提供了实证依据。

关键词：短租市场、空间自相关、最优定价、聚类分析、回归模型

“见微知著”——基于 Airbnb 平台的纽约市短租市场数据分析与优化研究

1. 问题背景与重述

1.1. 问题背景

在 21 世纪，共享经济正逐步在全球普及，随着人口数量的提升，城市地区教育、医疗、社会服务等资源的汇集与不确定性分布，使得人口迁移以及非长期的旅居办公成为很多人面临的问题，以 Airbnb 为代表的短租平台通过数字化技术重构了传统住宿业的资源分配模式。共享经济的核心在于通过平台化的运营以及数据汇总，让需求与供应得到高效地匹配，从而有效激活闲置资源的价值。据统计，2024 年纽约市共享住宿的市场规模已经突破百亿美元，其发展深度关系到城市经济活力与居民收入结构。然而 Airbnb 房源的异质性与用户市场群体的高度碎片化，房源类型、装修风格以及服务质量与房东密切相关，使得定价机制绵连显著的复杂性与不确定性。一方面，房东需要再非对称的信息环境下平衡收益与风险，使得价值潜力能更好地吸引到客户；另一方面，平台也需要实时维护动态市场的公平性与稳定性。

1.2. 问题重述

在 Airbnb 上其房源价格受多种因素影响，包括地理位置、房源属性、市场供需关系及房东经营策略等。合理的定价影响房东的收益水平，也直接关系到房源的入住率和市场竞争力。在附件 1 中给出了不同的房源的空间位置、房东信息、价格水平等信息。本文将基于 2024 年纽约市 Airbnb 房源数据，针对平台上房源经营与定价问题展开深入研究，解决以下问题。

问题一：对原始数据进行预处理，包括缺失、异常与重复数据的检测与处理，并说明判断缺失、异常的理由以及处理的方法。利用描述性统计分析，定量地呈现数据各指标的分布特性和基本统计规律。

问题二：针对房源在不同维度上的表现，分析各个细分市场的特征、分布规律及其潜在的经营价值，为制定针对性策略提供理论依据。

问题三：分析地理位置及其他相关变量对房价、入住率的影响，给出空间自相关性和地理位置的差异对房价、入住率的影响，揭示各因素之间的内在联系。

问题四：考虑不同细分市场和区域之间的差异性，给出兼顾收益与入住率的最优定价策略。针对策略实施过程中可能面临的风险，给出相应的改进方向。

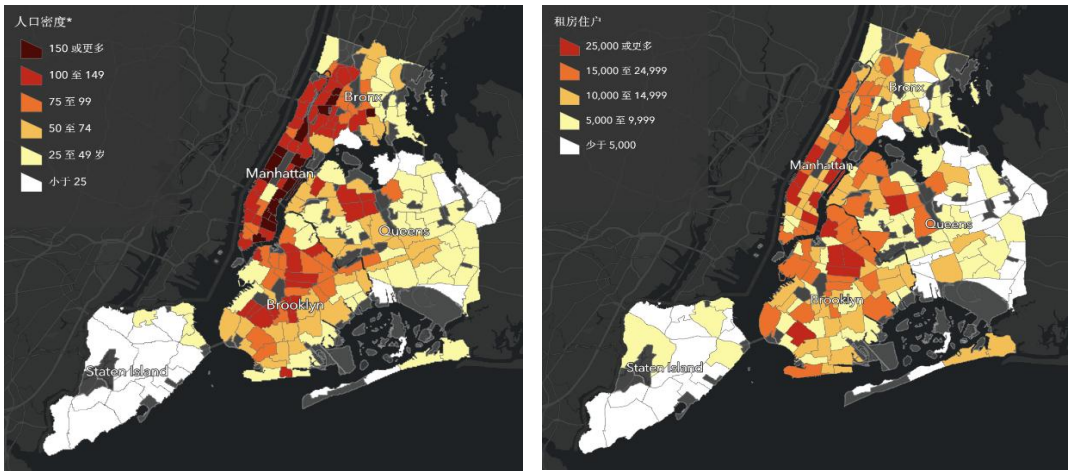


图 1：美国纽约市各行政街区的人口密度（左）和租房住户（右）

2. 问题分析

2.1. 针对问题一的分析

针对问题一，研究者需系统识别原始数据中潜在的问题与缺陷，鉴于数据预处理是建模的关键基础环节。首先，需量化评估各指标的缺失值数量及占比，并分析其缺失机制是否为完全随机或存在特定结构特征。例如，房价数据缺失、房东姓名字段空白、评价指标未公开等情况，这可能源于系统数据存储异常或房东的个性化设置。对此，需根据缺失特征采取相应措施，如删除缺失率过高的字段，或基于地理空间相似性进行插值补全。其次，异常值检测应基于业务逻辑开展，诸如零值房价或极端高价的出现，可能由数据录入错误或特殊房源类型（非目标交易对象）导致。此外，需进行重复数据检测以避免因重复记录导致的模型参数偏误。

在完成数据清洗后，应通过描述性统计定量呈现核心指标的分布特征，具体包括：各行政分区房价的集中趋势与离散程度、入住率极差反映的市场波动特性、微观区域平均评论数量体现的用户偏好等。在此阶段需同步生成数据质量评估报告，为后续建模工作提供可靠性依据。

2.2. 针对问题二的分析

市场是具有维度的，所谓细分市场就是将整体的市场划分为具有相似需求、行为或特征的消费者群体或是子集。在此本文依据不同房源的地理属性 neighbourhood_group（所属的经纬度以及地区）、房间类型 room_type（溢价型、平衡型或是经济型）、房东类型 calculated_host_listings_count（房东的规模程度）以及综合评价指标（我们通过主成分分析方法将反映相同类型问题的三个变量，分别赋予权重，整合为一个统一的数值），进行数据的可视化呈现。主要讨论以下四点问题：

1、探究不同地区地域价格的平均值

2、探究不同房屋类型与房东定价以及现实入住率的关系；

3、由聚类分析看入住率与房价的多元关系

4、由聚类分析看房租价格与纽约地理位置因素的关系

由此，我们可以从数据与结果中尝试得出相应显性关系，并以此作为基础条件以及参考依据，进行后续问题的分析和模型的构建。

2.3. 针对问题三的分析

由问题二的分析可知，房价与入住率等等许多因素具有相关关系。于问题三中，本文旨在构建一个线性回归模型，定量的探究每一个因素对价格与入住率的影响。笔者将价格对数化减小特殊值干扰，同时为确保假设检验的正确性，本文对线性回归模型做怀特检验，并在之后采用了稳健的标准误差方法来消除异方差的对于拟合过程中的干扰。此外，在空间相关性问题中，本文选择采用莫兰指数与 general G 来进行定量的量化评估，并且以可视化的方式呈现空间自相关性，在此基础上对房源价格与入住率进行综合评估与分析。

2.4. 针对问题四的分析

酒店定价策略制定过程中，不同细分市场以及不同行政在显著差异。为了在保证收益的同时提高入住率，需要制定精细化的定价策略，以最大化利润。基于问题三的分析思路，我们将数据按照不同地区与不同房型分别进行线性回归建模，分析价格对入住率和收益的影响。为了兼顾收益与入住率，我们采用利润（收益×入住率）作为衡量标准，并在此基础上进行优化，以寻找最优定价方案。此后经过查阅相关资料，还需要我们就市场需求波动、同质化竞争、顾客价格敏感、法律政策调整等风险进行分析，为房东定

价提供策略与建议。

3. 模型假设与公式符号

1、本文假设出租房评论数量越多，则该房源越受欢迎，热度越高。
2、本文假设房源在去年一年内仅有全年可租与全年不可租两种情况。
3、本文假设房租价格可以影响入住率，但是入住率却不可以影响房租价格

表 1：本文公式中重要符号注释

变量标号	含义描述
x_{ij}	特定步骤的数据集中相应坐标对应的数值
r	pearson 相关系数
n	特定步骤的数据集中使用到的变量数目
total_review	源于四个评论变量的综合评价指标，用来衡量房源受欢迎度
room_in_ratio	源于 availability_365，表示房间的入住率
β_i	回归模型的相应回归系数
γ_0, γ_1	常数项
$\hat{\varepsilon}_i^2$	残差
Moran's I	莫兰指数，反映空间自相关性
G	General G 指数，反映空间自相关性

4. 数据处理与分析

在模型建立之前，考虑到现实情境中数据的复杂性与多源性，我们需要对附件中的数据进行分析统计，以确保对数据的理解使用和模型的构建是有效且准确的。依据题目要求，综合生活常识、专业知识以及附件中的的数据与信息，利用 Matlab 和 Excel 工具进行了多维度全面细致的排查和整理，补充缺失值、检验合理性、剔除极端值，获取关键信息。

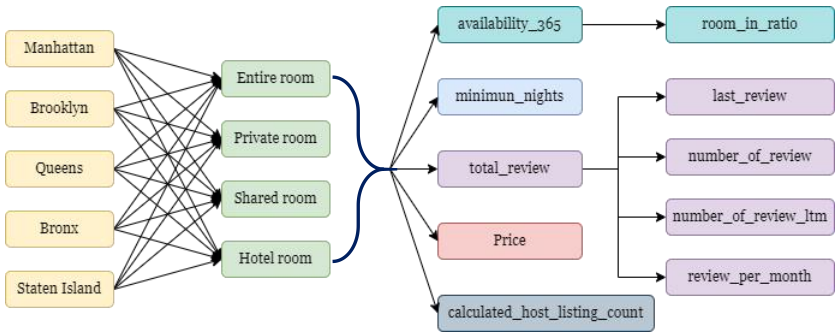


图 2：数据变量要素关系

4.1. 数据去重

首先，我们认真阅读并辨别了附件中各列的标签名以及它们所蕴含的反馈信息。而后，利用 Matlab 进行行间去重处理，检查有无重复行，若有则选择删去其中一项，只保留所有重复行中的第一行。

4.2. 缺失值统计

我们观察到在数据表格中存在不少的缺失值，在编程实现的过程中通过读取到的数据是否为NaN判定表格该处是否为缺失值。我们发现在host_name列中缺失值量极少（接近0%），price列缺失值较多（约30%），license列中缺失值过多。经过评估，删除host_name

缺失值所在行对结果产生的影响极小。price 列作为关键统计数据且占比不低，若采用插值等方法，可能会对模型的偏差误差进行放大，所以直接删除缺失值所在行，且由于剩余数据仍然满足大量条件，故合理可行。而 license 值由于对于本模型暂无用处，且该列缺失值过多，故选择直接删除此列。

经过统计发现并没有严重缺失的行，故不进行因行缺失而导致的整行删除。同时经过特殊值统计，发现 last_review 列和 reviews_per_month 列缺失值总数均为 11892，如此相近，推测不是巧合，故继续探究其中原因。

表 2：数据表中缺失值统计

变量	host_name	price	last_review	reviews_per_month
缺失值个数	6	14815	11892	11892

4.3. 零值统计

由于在现实生活中，评论量为零并非异常错误情况，可能是由于平台相应设置导致的，故也可以反映特定的目标数据，如果全再次发现部剔除增会导致数据分布的情况被破坏。经过再次统计，得到相应数据如下表所示。

表 3：特定数据变量缺失值与零值统计

变量	number_of_reviews	last_review	reviews_per_month	availability_365	number_of_reviews_ltm
缺失值个数	0	11892	11892	0	0
零值个数	11892	0	0	12562	26179

4.4. 缺失值填充

在进行检验之后，我们发现数据集中的 number_of_reviews 这一列数值显示为 0 的行，恰好对应了 last_review 和 reviews_per_month 两列中出现缺失值的行。这种情况表明，对于那些从未收到过评论的条目（即 number_of_reviews 列为 0），相应的最近一次评论日期（last_review）以及每月评论数（reviews_per_month）自然也就没有记录，因此这些字段呈现为空。

基于这一观察结果，为了后续分析处理的便利性，我们决定对 last_review 和 reviews_per_month 这两列中的缺失值进行填充操作，将它们统一填充为 0。这种处理方式既能够反映出这些条目确实没有收到任何评论的事实，又可以避免因数据缺失而可能引发的计算或分析错误。

4.5. 零值比对分析

在分析过程中，我们发现变量 availability_365 这一列的数据有特殊情况。经过严谨的分析和搜索调查，我们发现当这一列的值为零时，面临两种情况，其一是在过去的一年当中，房东将该房源设定成未出租的状态，即没有在租的时间，其二是本房源很受到客户的欢迎，在一年当中密集地出租，两次短租之间衔接密切，不存在空闲时间。

通过对 number_of_reviews 和 availability_365 两列进行比对，当其同时为零时，表明该房源从未被租出过，也没有任何租客评论。本文认为这种情况是由于房东并未实际将房源投入市场出租，或者房源信息处于未激活状态，无法被潜在租客查看及预订，故将所在行删除。而若 availability_365 列为零但 number_of_reviews 列非零，则本文认为

此情况为前述两种可能性的后者，不对所在行进行处理。这一步操作旨在剔除那些不活跃或未真正参与租赁市场的房源信息，从而确保数据的合理性与稳定性。

4.6. 异常值检验

检验缺失值和零值后，继续检验各类数据是否有异常值。例如，availability_365 列是否有大于 365 天的数据，latitude 和 longtitude 列是否有明显偏出纽约市经纬度范围的数据等。

现以 calculated_host_listings_count 列数据可信度检验的具体过程为例：

1、 首先提取 host_id 和 calculated_host_listings_count 两列内容，按照 host_id 列内容进行去重处理。

2、 考察去重后的数据结果，依次比对 calculated_host_listings_count 列当中的每一位数值与原表中相应 host_id 列所在行的出现次数，发现全部吻合。

3、 这说明不同房东所对应的房产数量数据真实可信。同理，我们还回到原表格中进行比对，在名下房产较多的房东随机选取若干个房东，发现房产数的数目，与此房东名下不同房源 id 的个数均保持一致。

经过对各列的多次合理性检查后，发现仅有 price 列有部分远超预期或地区平均值的数据出现，故只需对 price 列进行异常值处理。

4.7. 异常值处理

针对研究区域房价数据的异常值处理问题，本研究采用多主体统计分析方法进行处理（见图 3）。首先通过核密度估计与分行政区柱状图可视化，发现 price 变量在五个行政区均呈现厚尾分布特征。

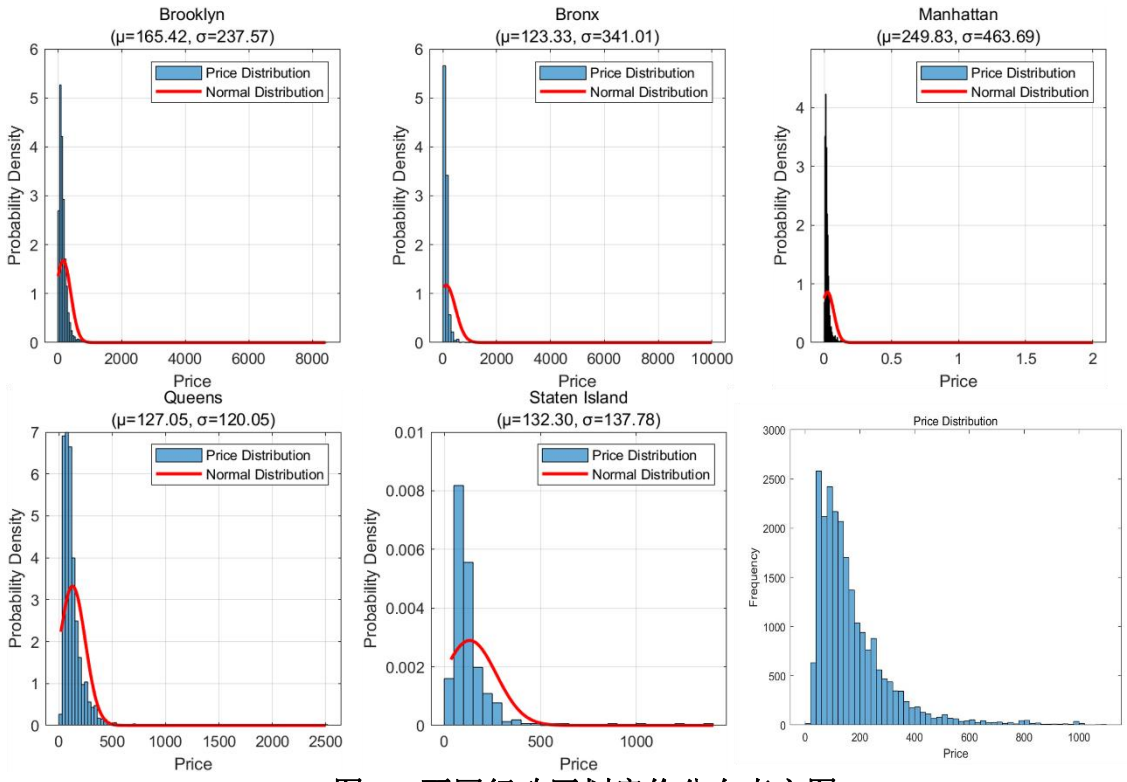
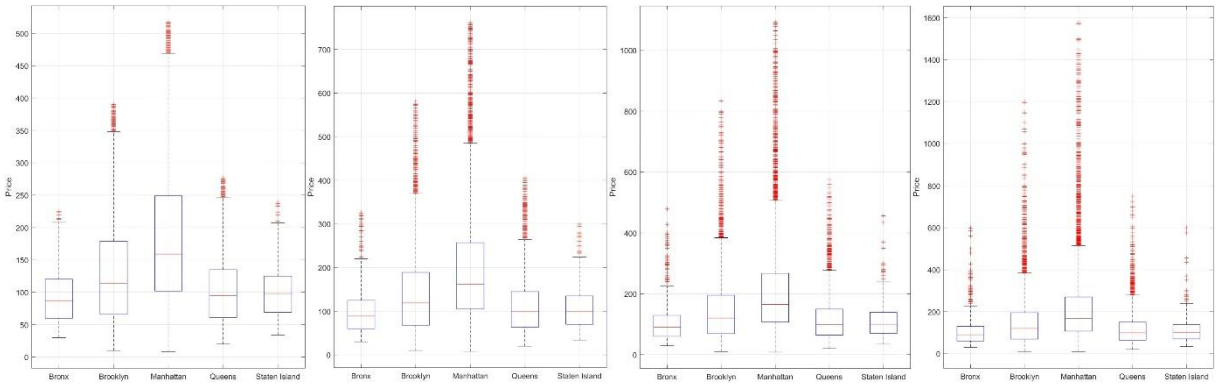


图 3：不同行政区划房价分布直方图

为量化检验其分布形态，分别采用 Jarque-Bera 检验（检验统计量对应概率值 p<0.001）

和 Kolmogorov-Smirnov 正态性检验（p 值远小于 0.01），在显著性水平α=0.05 下均拒绝正态分布原假设。进一步采用半正态分布拟合检验（Shapiro 半正态检验 p 同样显著小于 0.001），结果表明数据也不符合半正态分布特征。基于上述非正态分布特性，传统 3σ准则因依赖正态分布假设而不再适用。本研究采用基于四分位间距（IQR）的相对普适性的统计方法，其数学表达式为：

$$\mathrm{IQR} = Q_3 - Q_1$$



异常值判定阈值为：$[Q_1 - k \cdot \mathrm{IQR},\ Q_3 + k \cdot \mathrm{IQR}]$

图 4：不同调整系数下各行政区价格分布箱线图

其中k为调整系数。通过控制实验法系统测试$k \in \{1.5, 3, 5, 8\}$时的处理效果如图 4，剔除异常数据的比例如表 4，利用“肘部法”的思想，在 k 为 5 对应坐标点前后曲线下降速度变化最快。且当$k = 5$时，在保证剔除强离群点（$|z - score|$ 超出判定阈值范围的极端值）的同时，可保留 98.36%的原始数据量，较 k=1.5 方案减少 25.51%的数据损失，较 k=8 方案降低 36.59%的异常值残留。减小了偏差较大的极端值、特殊值对回归分析的干扰。

表 4：不同调整系数下剔除异常值的比例

	1.5*IQR	3*IQR	5*IQR	8*IQR
保留比例	99.40%	98.36%	97.03%	93.57%

4.8. 描述性统计

表 5：重要参数描述性统计数据呈现

变量	P	M_n	N_o_r	C_h_l_c	A_365	N_o_r_l
平均	171.58	26.59	33.85	96.75	244.25	5.91
标准误差	0.93	0.14	0.5	1.76	0.75	0.16
中位数	130	30	5	3	269	0
众数	100	30	0	1	365	0
标准差	139.81	21.43	74.87	264.17	113.17	23.73
方差	19546.46	459.06	5605.37	69787	12806.89	562.89
峰度	8.27	133.78	136.98	9.71	-1.08	1775.4
偏度	2.44	8.85	7.54	3.28	-0.52	30.27
区域	1084	499	2485	1153	365	1779
最小值	8	1	0	1	0	0
最大值	1092	500	2485	1154	365	1779

*上述表格中的参数：P 为 price，M_n 为 minimum_nights，N_o_r 为 number_of_reviews， C_h_l_c 为 calculated_host_listings_count，A_365 为 availability_365，N_o_r_l 为 number_of_reviews_ltm.

上述表格中所有数据的观测数均为 22634 个。由图中数据可知 price、number_of_reviews、calculated_host_listings_count、number_of_reviews_ltm 四列中的数据由于中位数都远小于平均数，且峰度都相对较大，所以可以认为其具有长尾分布特征；此外，像 minimum_nights 的众数是 30，说明绝大多数情况下房东会考虑短租天数至少 30 天。

5. 细分市场特征与规律分析

5.1. 主成分综合评价模型

5.1.1. 数据处理与标准化

在本数据集变量之间常具有一定的相关性，利用这些指标完成数据属性的维度重建，信息重复容易造成参数偏差，影响综合评价的结果[1]。主成分分析法以少数的综合变量取代原始采用的多维变量，依据不同变量属性之间的强弱关联关系，整合后可以对不同细分市场更明确的分析，同时还减少了在选取指标上花费的时间[2]。故依此对数据进行数据处理、标准化、偏度纠正、去平均值的操作：

1、数据处理：首先将 last_review 时间信息中的缺失值全部填为零，把所有非零日期中最早的一天设置为 1，其余数据比最早日期多 n 天则转换为 n+1；而后将变量 availability_365 转换为入住率 room_in_ratio 进行预处理:

$$\text{room_in_ratio} = 1 - (\text{availability_365}) \big/ 365$$

2、标准化：其次将所有数据进行 Z-score 标准化，通过消除不同变量的量纲差异，将不同数据集转化为均值为 0、标准差 1 的标准分布，使其具有可比性和统一的统计尺度。数学表达式如下（式中 S 表数据的标准差）。

$$\text{last_review}_t = \frac{x - \bar{x}}{S}$$

3、偏度纠正：随后采取偏度纠正的方法，对于偏度绝对值超过阈值 5 的变量，采用广义幂变换方法 Yeo-Jonkson 进行修正，使得数据分布更接近正态分布，从而满足分析的假设条件，减少数据偏度过大对整体拟合的偏差，便于后期进行处理。

其变换函数的数学表达式如下。该变换通过最大似然估计自动优化参数λ，可同时处理正负以及零值数据。对于偏度小于等于 5 的变量，则保留原始数据以避免冗余操作。计算完成后，再次计算各变量偏度以检验修正效果。

$$\psi(y,\lambda) = \begin{cases} \dfrac{(y+1)^{\lambda} - 1}{\lambda} & \lambda \neq 0, y \geqslant 0 \\ \ln(y+1) & \lambda = 0, y \geqslant 0 \\ -\dfrac{(-y+1)^{2-\lambda} - 1}{2-\lambda} & \lambda \neq 2, y < 0 \\ -\ln(-y+1) & \lambda = 2, y < 0 \end{cases}$$

4、去平均值：最后在偏度纠正操作之后，由于数据平均值出现了变化，所以再进行一次去均值处理，即每个数据减去均值用于后续的相关性的分析。

5.1.2. 相关性分析

本文通过相关性分析来探究指标之间的关系，以此判断指标是否出现严重的内生性问题。 通过计算 Pearson 相关系数得到相关系数矩阵。可视化如下。

$$r=\frac{\sum_{i=1}^{n}\left(X_i-\bar{X}\right)\left(Y_i-\bar{Y}\right)}{\sqrt{\sum_{i=1}^{n}\left(X_i-\bar{X}\right)^2}\sqrt{\sum_{i=1}^{n}\left(Y_i-\bar{Y}\right)^2}}$$

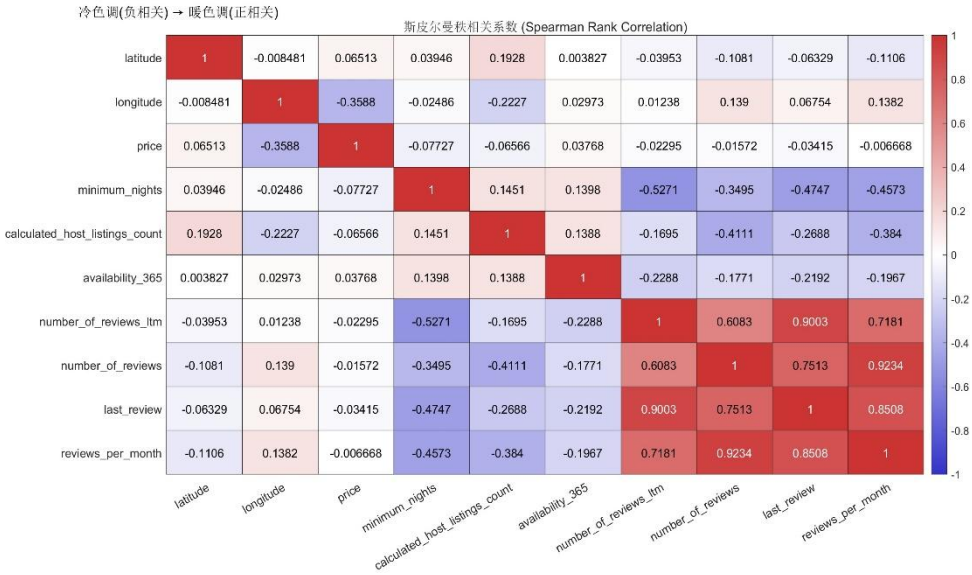


图 5：斯皮尔曼相关系数热力图

同时本文还综合参考了非参数方法分析中，肯德尔相关系数与皮尔逊相关系数的热力图，观察理解最能体现特征的系数，得到以下推测：

minimum_nights 与 number_of_reviews_ltm 的负相关性中尤为突出（斯皮尔曼-0.5271，肯德尔-0.465），而皮尔逊仅为-0.4093，表明两者可能存在单调但非线性的反向关系，即入住时间要求越长，评论数量可能越少。

calculated_host_listings_count 与 number_of_reviews 的负相关性（斯皮尔曼-0.4111，肯德尔-0.3137）可能表明房东房源数量增加可能伴随单房源评论减少，或反映资源分散效应，或反映部分下滑但总体因数量优势仍然上涨的可能性。。

number_of_reviews、reviews_per_month 和 last_review 在所有方法中均呈现高度正相关，表明评论数量、最近评论时间与月均评论频率之间存在紧密联动，可能共同反映房源活跃度。而 number_of_reviews_ltm 与这些变量的强相关性进一步支持了该结论。所以这对这一点我们决定采取主成分分析的方法进一步处理。

5.1.3. 主成分分析

我们需要计算数据集两两变量之间的协方差矩阵$\boldsymbol{R}=(r_{jk})_{n\times n}$，其中$r_{jk}$为第 j 个评价指标与第 k 个评价指标的协方差：

$$r_{jk}=\frac{1}{n-1}\sum_{i=1}^{n}\frac{(x_{ij}-\bar{x}_j)^2\cdot(x_{ik}-\bar{x}_k)^2}{s_j\cdot s_k}$$

然后求出相关系数矩阵的 n 个特征根与特征向量，确定主成分的个数，由特征方程式可以求解得到n个特征值，从大到小进行顺序排列：

$$|\lambda\boldsymbol{I}_n-\boldsymbol{R}|=0$$

$$\lambda_1\geqslant\lambda_2\geqslant\cdots\geqslant\lambda_n\geqslant 0$$

其中特征根的大小描述了每个主成分在评价中所起作用的大小。每一个特征根对应

一个特征向量，记为$\boldsymbol{u}_1,\boldsymbol{u}_2,...,\boldsymbol{u}_n$，求得各主成分为：

$$z_{ij}=\boldsymbol{u}_j^T\boldsymbol{x}_i,\ \boldsymbol{x}_i=(x_{i1},x_{i2},...,x_{in})^T$$

提取的主成分特征根应大于所有主成分特征根的平均值，在此由于进行了标准化处理，即取大于 1 的特征根即可。

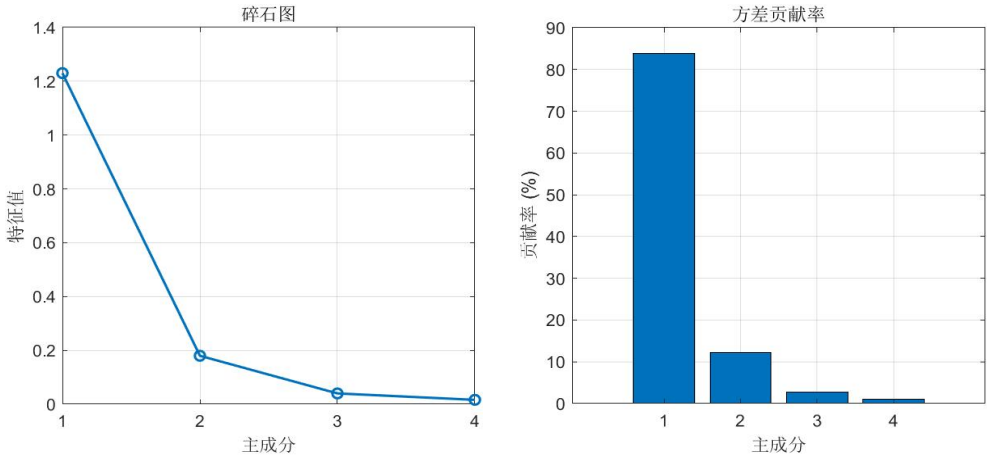


图 6：主成分特征值及相应的方差贡献率

发现最大的特征值$\lambda_1\geq1$，且其累计方差贡献率就已经超过 75%，故选取λ_1对应的特征向量，一次作为参数，将四个指标整合为一个统一的指标 total_review。

$$total_review=0.1409\times number_of_reviews_ltm+0.3139\times number_of_reviews$$
$$+0.884\times last_review+0.3164\times reviews_per_month$$

表 6：主成分分析中特征值以及相应的贡献率

特征值	方差贡献率(%)	累计方差贡献率(%)
1.2302	83.8982	83.8982
0.1799	12.2690	96.1672
0.0400	2.7280	98.8952
0.0162	1.1048	100.0000

5.2. 探究不同地域细分市场的价格特征

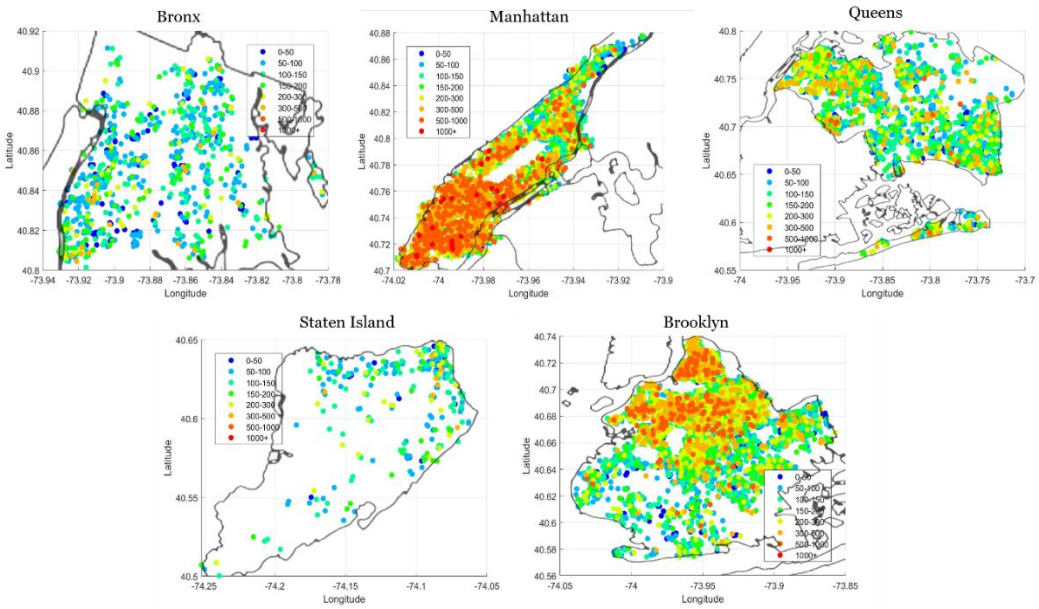


图 7：纽约市五大行政区房租散点图

从纽约市五大行政区的房租数据可视化呈现之中，颜色越高表示房租价格水平越高，分布越密集表示房源数量越多。由此可以得到以下结论，下面将进行详细分析。

- **Manhattan 地区**呈现出大面积的红色和橙色三点，说明大多数房源出于较高水平，尤其是在中城区和下城区，租金集中分布在最高区间。这既是由于曼哈顿是纽约市面积最小的行政区（仅 59 平方公里），但人口密度达到了超过 160 万居民，土地稀缺，同时在这里汇聚了全球顶级的金融（华尔街）、商业（第五大道）、文化（百老汇）和教育（哥伦比亚大学、纽约大学）资源。
- **Brooklyn 地区**整体租金水平仅次于 Manhattan，且在与该地区相邻的威廉斯堡、布鲁克林高地等地域有不少租金散点，相反位置则较少，说明这些地区由于交通便捷，近曼哈顿并且社会逐渐年轻化，较有活力。
- **Queens 地区**房租水平整体比较均衡，中等价位的房源较多，尤以南部、西部的地区房源重组，同样在靠近曼哈顿的地区，有上升趋势。
- **Bronx 地区**房租价格更经济与实惠，与相邻的 Manhattan 地区相邻，大部分散点一蓝色和绿色为主，租金普遍较低，用户多适用于在临近地区通勤的居民。
- **Staten Island 地区**房租分散并且普遍偏低，说明该地人口密度较小，地理位置偏远，可能交通不够便利，缺乏就业机会，因此房价长期低迷，符合 Alonso (1964)提出的“通勤成本-房价负相关”规律[4]。
- 从整体上看，**出租房价具有明显的地域特征**，围绕哈德逊河两岸的诸多地区，即城市核心功能地带房价会收到诸多社会、经济、文化因素的影响，诸如左岸新泽西的“泽西城”、河岸社区的“文化地标效应”、“哈德逊城市广场”的企业入驻以及滨河观景房的整改修缮，都使得本地区的经济溢价现象显著。此外，全市房租价格分布符合**“城市地租中心辐射原则”**，呈现“同心圆+扇形”复合结构。从内而外依此是核心层（以商用、高档住宅为主，土地贡献率站全市 43%）、次级圈层（主要分布办公-居住混合带）、边缘区（通勤成本抵消区位优势，构成价格洼地）。由此可见纽约出租房租的核心内涵是可达性资本化以及功能集聚度在房产价格上的映射[2]。

5.3. 探究不同房源类型细分市场的房价及入住率的特征

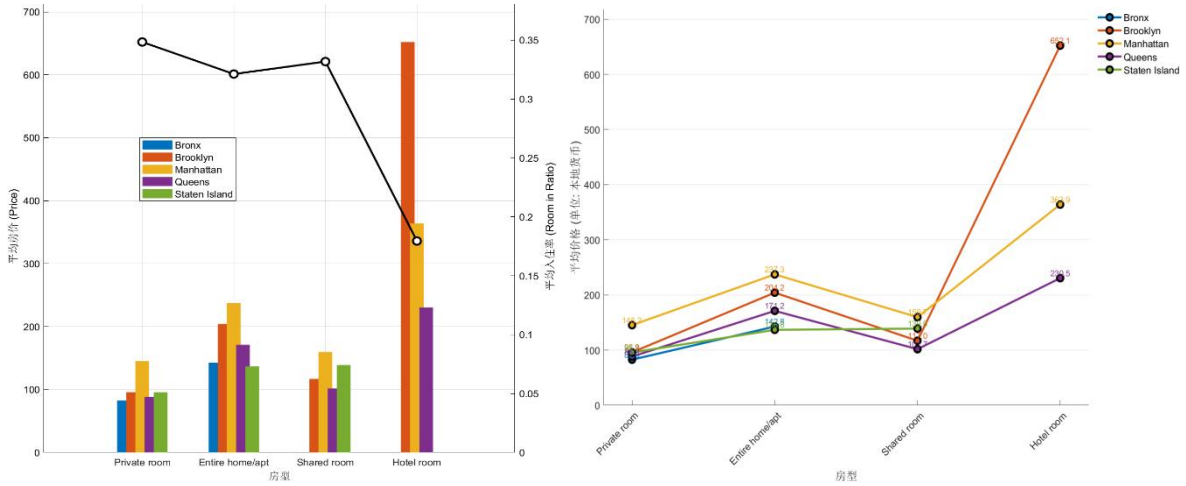


图 8：不同房型分类下各行政区平均房价与平均入住率

分析上述可视化数据，发现平均房价最高的是位于 Brooklyn 的 Hotel room，最低的是位于 Bronx 的 Private room，Manhattan 的各种类型房源（除 Hotel room）普遍高于其他行政区，Entire home 的平均房价普遍高于 Private room 和 Shared room，入住率 Hotel

room 明显低于其余三者。尤此可以得出以下几点结论

• 核心城区房价显著高于边缘区域，经济发展水平以及产业集聚现象是主要因素

数据显示，位于 Manhattan 的 Private room 均价达 700 美元/天，是 Queens（400 美元/天）的 1.75 倍、Station Island（300 美元/天）的 2.3 倍。这一差距与 Manhattan 作为金融和服务业中心的地位直接相关。例如，Glaeser et al. (2005)的研究表明，住房需求刚性在高技能劳动力密集区域更强，支付溢价明显被推高[3]。

• 服务标准化与品牌效益成为酒店房间定价优势，普通的出租房面临同质化问题

图中 shared room 仅 100 美元/天，远低于 Hotel room 的均价。酒店通过 24 小时前台、清洁服务等标准化流程设施[5]，形成品牌溢价；而 shared room 因供给这普遍是个人房东，服务水平差异大，价格接近边际成本（如 Station Island 共享房间均价 120 美元/天，入住率 0.25）。此外，Queens 庄园住宅以 400 单位价格和 0.3 入住率占据中端市场，因其提供长期租赁合同（平均租期 2 年），吸引稳定家庭客群[6]。

• 高价抑制短期需求，低价吸引价格敏感群体，替代效应显著

Manhattan 的 Hotel room 入住率仅 0.1-0.2，而 Station Island 的 Shared room 入住率达 0.25。具体而言，Manhattan 游客更倾向选择邻近的 Queens 酒店（均价 500 美元/天，入住率 0.2）以节省成本，体现价格敏感群体的跨区替代行为[7]。同时，Queens 的 Entire room 入住率稳定（0.3），可能因为租户多为本地中产家庭，需求较为刚性，对租金上涨容忍度较高。

5.4. 聚类方法下的综合细分市场分析

5.4.1. K-means 聚类方法

考虑到数据特征众多并且具有复杂的相关性与特征，将采取 K-means 的聚类方法尝对所有数据进行分析，方法大致如下：

• 1、初始化：随机选取 K 个初始的聚类中心（K 的确认方法）。

• 2、分配样本：计算多有样本点与各置信的距离（关于给定变量的欧氏距离），将每个点分配至最近质心对应的簇。

• 3、更新质心：基于当前簇内所有样本的均值，重新计算各簇质心位置，目标函数即是最小化簇内平方误差 SSE，其中 μ_i 为簇 C_i 的质心。

$$\mathrm{SSE} = \sum_{i=1}^{K} \sum_{x \in C_i} ||x - \mu_i||^2$$

• 4、迭代收敛：重复步骤 2-3，直到质心位置不再变化，或达到最大迭代次数

5.4.2. 房价-入住率二元聚类分析

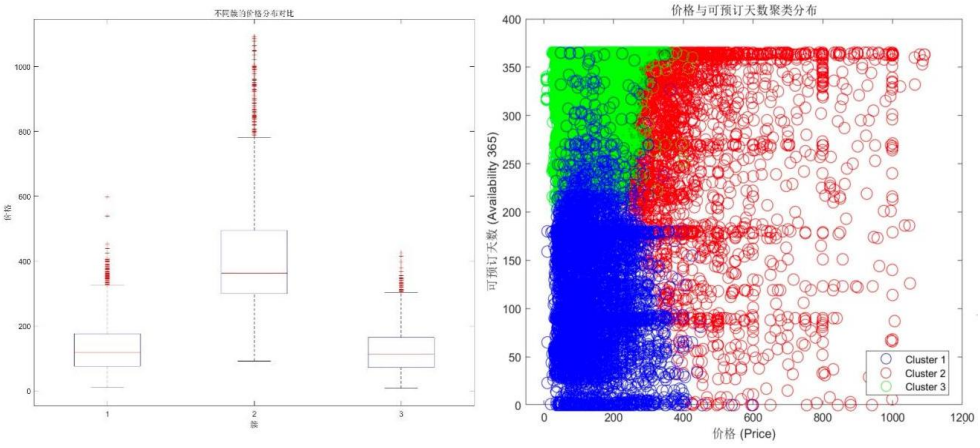


图 9：不同聚类价格箱线图（左）及价格与入住率聚类分布关系（右）

首先，本文遍历候选的 K 值，依次执行 K-means 聚类操作，记录相应的 SSE 值并绘制 K-SSE 曲线，绘制折线图，典型曲线有如下特征：在初始阶段 K 增大时，SSE 急剧下降，即质心划分细化，簇内紧密度提升；其次在拐点 SSE 下降速率显著放缓，形成类似肘部的转折，后续 SSE 的下降将会区域平缓。我们选择拐点处的横坐标作为质心点数，在本模型中即取 K=3。

其次，三种聚类的分布特征如图所示如图所示，据此将房源划分为三种可能的细分市场，具体分类分析以及相应推测如下：

1、 均衡经济型

此类房源价格中等偏下（主要在 150-200 美元/晚），可预订天数中等偏少，说明预定较为火热，供需关系相对均衡合理。房源集中于次级热门区域（如 Brooklyn 威廉斯堡、Queens 长岛市），推测可能以独立公寓或精品单间为主，基础生活设施完备，住宿条件相对优良，兼顾性价比与舒适度。房东多为中小管理团队，可能会采用季节性开放策略及动态定价平衡收益与入住率。用户群体覆盖中短期游客与商务差旅者，需求稳定，且用户市场较为广阔。本类型房源优势在于灵活性，但需防范同质化竞争，建议强化“出行便利”、“家庭友好”等标签，并引入相关优惠策略增加用户粘性。

2、 轻奢高档型

此类房源价格较高且较为分散（主要分布在 300-1000 美元/晚），可预订天数普遍较多。说明此类房源以稀缺性和高溢价为核心竞争力，可能主要分布在曼哈顿中城、SOHO 等核心地段，或为设计型豪华公寓（如顶层复式、景观 loft）。房源设施高端，环境优美观赏性强，同时配备智能家居、私人管家服务或专属设施（如健身房、屋顶泳池等等），满足高端用户对私密性与品质的极致需求。房东多为专业运营管理公司，目标用户集中于高层次商务人士、奢侈品消费者及特殊需求游客（如蜜月旅行、品牌活动参与者）。其消费行为呈现短期高预算特征导向。

3、 低价供给型

此类房源定位于低价市场（如 100-150 美元/晚），全年开放时间较长，实际入住率低，空置问题突出。房源多分布于非核心居住区（如 Staten Island、Bronx 北部等地），以老旧公寓或 Private room 为主，设施简单，而且可能缺少相应的维护管理机制。房东多为个人业主，依赖平台被动接单，定价僵化且无针对性策略，导致长期陷入低价竞争陷阱。用户群体以预算较低的长租客（如学生、短期工）为主，对于地理位置以及居住条件的容忍度较高。核心矛盾在于供给过剩与需求不足的错配，房东可以通过低成本改造或挖掘利用周边资源提升吸引力，同时动态降价策略可缓解空置压力。

5.5. 理论依据分析

作为房东，上述分析可以作为市场情况的参考，房东可以首先依据自己房屋的大致特征，将自己划归为特定的聚类之中，并依此作为市场的参考，评估自己的大致的定价策略与可能得调整方向。

6. 模型的构建与分析

6.1. 地理位置及其他相关变量对房价、入住率的影响

6.1.1. 线性回归的陈述与检验

本研究主要采取了线性回归模型，将数据集中的诸多标签属性作为自变量，探究地理位置、入住率、评论数量（即热度）对于房价和入住率的影响机制和相关联程度。本文通过 stata 软件进行拟合，对于房租价格与房间入住率这两个因变量构建线性回归方程如下。

$$\ln(price)=\sum_{i=1}^{n}\beta_i x_i+\gamma_1$$

$$room_in_ratio=\sum_{i=1}^{n-1}\beta_i x_i+\beta_n\ln(price)+\gamma_2$$

其中$price$表示房租价格，$room_in_ratio$表示入住率。系数及相关数据见表 7。

在线性回归方程的构建当中，我们进行了如下三个关键操作：

其一，本模型对房租价格$price$进行**取对数的处理方法**用$\ln(price)$作为衡量房租因变量的等价指标，如此可以起到稳定方差、降低数据的偏态以及尽可能减小异常值极端值对拟合方程的干扰，同时，还可以用来解释变量之间的弹性关系，在复杂多因素模型中提取出核心的变化关联关系。

其二，本模型通过引入**虚拟变量**（A_1~B_4）来表征区域分类特征，将标签化的类别类型变量转化为数值形式，使其能够纳入线性回归模型，虚拟变量通常会取 0 或者 1，表示是否属于某一类别。引入虚拟变量可以有效控制不同类别对因变量的影响，通过改变回归方程的截距，衡量不同类别相对于参考组的差异。为避免多重共线性问题，具有 K 个类别的变量应引入 K-1 个虚拟变量，以其中某个变量为基准，在本模型中，以 A_1 和 B_4 作为参考值。

其三，在模型进行初步拟合之后，为进一步保证数据的准确度和回归方程的可信度。在初次确定好各自变量在回归方程中的系数之后，进行**怀特检验（White Test）**，来检验回归模型汇总是否存在异方差性。其基本思想是将回归残差的平方作为因变量，构造辅助回归模型，以判断误差项的方差是否会随着自变量系统的变化而变化。辅助回归的表达式如下，本质是将残差平方回归到自变量、自变量的平方和交互项上：

$$\hat{\varepsilon}_j^2=\varphi_0+\sum_{i=1}^{n}\varphi_i x_{ji}+\sum_{i=1}^{n}\varphi_{n+i}x_{ji}^2+\sum_{i=1}^{n}\sum_{l=i+1}^{n}\varphi_{nj}x_{ji}x_{jl}+u_i$$

随后估计辅助回归的决定系数R^2，并构造怀特统计量$LM=nR^2$，在原假设H_0（不存在异方差）成立时，该统计量近似服从卡方分布，其中 q 为辅助回归中的自变量个数：

$$LM=nR^2\sim\chi_q^2$$

在本模型中初次拟合未通过怀特检验，为了保证回归分析的稳健性，以及为后续的 t 检验、T 检验做保障，考虑引入“稳健的标准误”。第一步，保留 OLS 系数的估计，就算存在异方差，这些回归系数也是无偏的。第二部，构造修正协方差矩阵，利用残差只构造修正项，将每个观测点的残差平方作为权重，对协方差矩阵进行加权调整。公示如下

$$\widehat{Var}\left(\hat{\beta}\right)=(X'X)^{-1}\left(\sum_{i=1}^{n}\hat{\varepsilon}_i^2 x_i x_i'\right)(X'X)^{-1}$$

上式中 X 表示自变量矩阵，其每一行代表一个观测样本，每一列代表一个自变量。

其四，我们队最终处理过后的方程，进行 **T 检验与 t 检验**，前者反映模型的整体拟合水平，也称“联合显著性检验”，后者则解释各自变量的具体贡献。带入模型后需要笑傲舍弃检验不通过的变量，数据见表 7。

表 7：怀特检验后考虑稳健的标准误的拟合数据

Variable	Coefficient	Robust Std.err.	t	p>|t|	Coefficient	Robust Std.err.	t	p>|t|
latitude	-1.3042380	0.1112400	-11.72	0.000	0.3415957	0.0609899	5.60	0.000

longtitude	-1.7302450	0.1045409	-16.55	0.000	-0.4490472	0.0604781	-7.42	0.000
minimum_nights	-0.0046039	0.0004270	-10.78	0.000	-0.0014137	0.0001051	-13.45	0.000
total_review	0.0049344	0.0051849	0.95	0.341	0.0554032	0.0024289	22.81	0.000
calculated_host_listings_count	-0.0000260	0.0000136	-1.92	0.055	-0.0000547	0.0000072	-7.58	0.000
price					-0.0240333	0.0036508	-6.58	0.000
A1	0.0000000	(omitted)		(omitted)	0.0000000	(omitted)		(omitted)
A2	-0.1564454	0.0260837	-6.00	0.000	0.0871439	0.0154035	5.66	0.000
A3	0.1128340	0.0210799	5.35	0.000	0.0484808	0.0130799	3.71	0.000
A4	-0.0430328	0. 0224209	-1.92	0.055	0.1004188	0.1419210	7.08	0.000
A5	-0.6740220	0.0482221	-13.98	0.000	-0.0233497	0.0277285	-0.84	0.400
B1	0.5907131	0.0893119	6.61	0.000	0.0327830	0.0411862	0.80	0.426
B2	0.7250796	0.1036290	7.00	0.000	-0.1060193	0.0432911	-2.45	0.014
B3	-0.1119914	0.0892965	-1.25	0.210	0.0365877	0.0411321	0.89	0.374
B4	0.0000000	(omitted)		(omitted)	0.0000000	(omitted)		(omitted)
_cons	-70.02713	8.9617740	-7.81	0.000	-46.78890	5.2622450	-8.89	0.000

*在上图中 A1 代表 Bronx，A2 代表 Brooklyn，A3 代表 Manhattan，A4 代表 Queens，A5 代表 Staten Island，B1 代表 Private room，B2 代表 Entire home，B3 代表 Shared room，B4 代表 Hotel room

6.1.2. 回归结果分析

经过分析上述数据，我们选择剔除未通过 t 检验的自变量，经由对系数 Coefficient 列的数据进行分析，得到如下结论：

1、**房价-入住率规律：**在数据表格中房价与入住率有负相关关系（系数为-0.024），说明从整体上看，当房屋定价有上涨时，其入住率会有所下降，但是由于考虑的因素很多，两者之间的关联关系有可能受到很多的因素影响，

2、区位-房型属性：在上述系数图中，B1、B2 相较于参考值 B4（Hotel room）的大于关系较为明显，说明 Private room 和 Entire home 在房屋定价上具有较高的水平，已有的市场数据告诉我们，相较于 Hotel room，房东将自身出租屋定位设定为这两种房型，会相较 Shared room 有获得更大收益的趋势。

3、**租赁政策反馈：**最短租期要求每增加 1 天，房价与入住率分别下降 0.0046 和 0.0014 个单位（$p<0.001$），凸显市场对灵活短租的偏好。近期评论活跃度虽微弱抑制房价（系数=-0.00002，$p<0.001$），但极显著提升入住率（系数=0.0000186，$p<0.001$），表明信息透明度通过增强房源曝光驱动需求，而差评可能倒逼价格调整。

6.2. 空间自相关性和地理位置的差异对房价、入住率的影响

空间自相关性（Spatial Autocorrelation）是用来分析地理空间特征的核心概念之一，用于描述位于地理空间中相邻近的事物或指标在属性特征上的相似性、关联性或者依赖性。这一概念揭示了地理学第一定律（Tobler's First Law of Geography）的核心思想——“任何事物都与其他事物相关，但邻近的事物比遥远的事物更相关”[8]。它通过对“地理邻近性”与“属性相似性”之间的耦合关系进行量化，作为研究的重要辅助工具，帮助理解空间数据的分布模式、属性的相互作用机制以及潜在的地理特征规律，广泛应用于地理信息科学（GIS）、生态学、经济学、流行病学等领域。

6.2.1. 理论分析推导

同时，我们主要选取全局 Moran's I 指数以及全局 General G 指数进行衡量。

• 全局 Moran's I 指数

所谓自相关性，即是类比原本用于校验两列数据值的斯皮尔曼相关系数，将其作用

于单组数据值之上，其核心点在于为每一个离均差乘积项赋予一个相应的权重ω_{ij}并进行标准化。

空间权重矩阵即是这些权重值的汇总，它用以量化各单元之间的空间联系或临近程度。先对小区域进行二元标号，并按照特定顺序进行排列，用“车步”的临近规则，若小地区之间存在相邻边界，则为对应坐标点赋 1，若无边界相连则赋 0。随后在协方差的基础上添加邻接权重，再进行标准化。公示如下：

$$\text{Moran's I}=\frac{N}{W}\cdot\frac{\sum_{i-1}^{N}\sum_{j=1}^{N}\omega_{ij}(z_i-\overline{z})(z_j-\overline{z})}{\sum_{i=1}^{N}(z_j-\overline{z})^2},\ W=\sum_{i=1}^{N}\sum_{j=1}^{N}\omega_{ij}$$

由此可以将各区位的的属性值归化到$[-1,+1]$，其中+1 代表具有较强的空间正相关性，-1 为具有较强的空间负相关性，0 表示随机分布。

• General G 指数

General G 指数用于度量空间中高值或者低值局部聚集性的全局统计量[9]，其核心思想在于通过比较空间临近单元属性值的乘积与全局属性值的乘积，识别诸如“冷点”或“热点”的非随机聚集模式，其表达式如下。

$$G=\frac{\sum_{i=1}^{n}\sum_{j=1}^{n}\omega_{ij}x_ix_j}{\sum_{i=1}^{n}\sum_{j=1}^{n}x_ix_j},\ \forall j\neq i$$

其中分子用来衡量空间邻近单元值属性的协同增强效应，若高值在空间上聚集，分子将显著增大；同时分布式全局属性值的成绩综合，作为标准化基准，消除数据量纲的影响。

此后进行期望值$E[G]$和方差$V[G]$的推导，假设属性值均独立且同分布，则$E[x_ix_j]=E[x_i]\cdot E[x_j]=\mu^2$。计算公示如下：

$$E[G]=\frac{\sum\omega_{ij}\mu^2}{\sum\mu^2}=\frac{\sum\omega_{ij}}{n(n-1)},\ V[G]=E[G^2]-(E[G]^2)$$

最后通过计算z_G得分将 G 统计量表顺滑为符合正态分布的统计量。

$$z_G=\frac{G-E[G]}{\sqrt{V[G]}}$$

若$|z_G|>1.96$ (显著性水平$\alpha=0.05$)则拒绝原假设，表明存在显著空间聚集，z_G>0 表示高值聚集，z_G<0 表示低值聚集。

6.2.2. 模型结果呈现

依据上述理论规律，将先前处理过的特定数据集代入计算，通过可视化方式将房租以及房屋入住率的莫兰指数、General G 指数呈现如下。

1、房租及空间自相关性

表 8：房价地域分布对应的莫兰指数、General G 指数

指标	Moran's I	General G
指数/观测值	0.3596460	0.0154440
z 得分	25.7146260	7.1113680
p 值	0.0000000	0.0000000

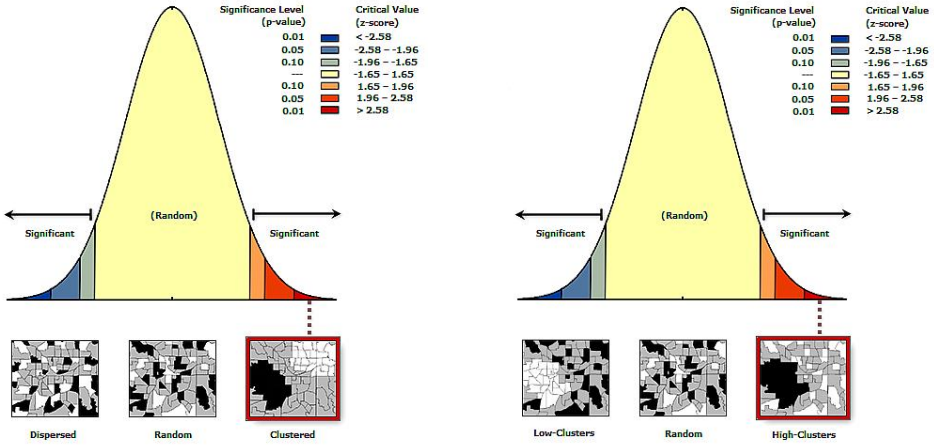


图 11：房价分布的全局莫兰指数（左）与 General G 指数（右）

基于莫兰指数（Moran's I）与 General G 指数的显著性检验结果，**房价空间分布呈现显著的非随机集聚特征**。全局莫兰指数观测值为 0.3596（z=25.7146，p=0.000），远高于随机分布预期（z>2.58，p<0.01），图 11 中的红色虚线即为相应的 z 值所属的分布区间。表明房价存在强正空间自相关，即高（或低）房价区域在空间上显著邻近，形成集聚模式。进一步通过 General G 指数检验（观测值=0.0154，z=7.1114，p=0.000），其 z 得分远超阈值 2.58（p<0.01），证实空间集聚以高值主导，即高房价区域集中分布，形成统计显著的热点（High-Clusters）。两种指标的结果共同指向一下三点结论

1、 **全局集聚性**：房价分布整体偏离随机性，相似价格区域空间邻近，反映城市内部经济、区位或政策因素的梯度效应；
2、 **局部异质性**：高房价区域空间聚集显著，可能由核心商圈、优质资源或投资偏好驱动；
3、 **稳健科学性**：p 值趋近于 0 且 z 得分极端偏离随机区间，结果拒绝"空间独立"原假设，支持集聚模式的客观存在。

此量化分析为识别房价空间结构提供了依据，对城市规划和房地产市场调控具有参考价值。

2、入住率及空间自相关性

表 9：入住率地域分布对应的莫兰指数、General G 指数

指标	Moran's I	General G
指数/观测值	0.0308600	0.0145600
z 得分	2.2939120	1.2252200
p 值	0.0217960	0.2204920

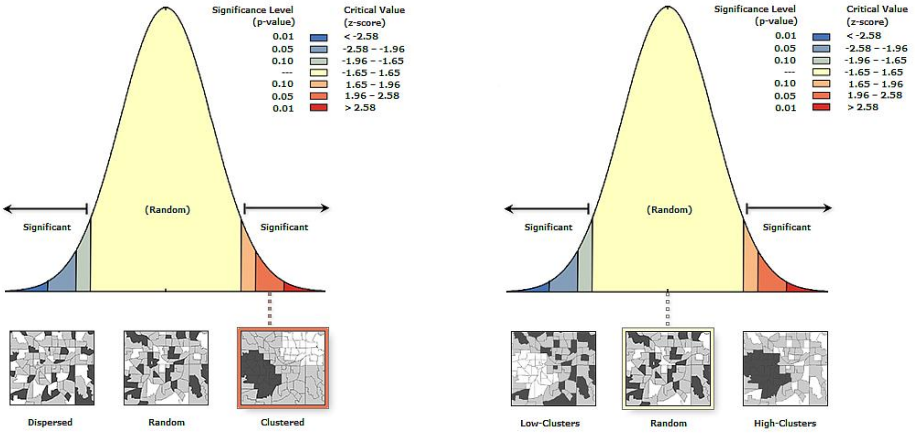


图 12：入住率分布的全局莫兰指数（左）与 General G 指数（右）

基于莫兰指数（Moran's I）与 General G 指数的检验结果，**纽约市入住率空间分布呈现弱正自相关但无显著高值聚集特征**。由图 12，全局莫兰指数观测值为 0.0309（z=2.2939，p=0.0218），在 5%显著性水平下（p<0.05）通过检验，表明**入住率存在轻微的正空间自相关**，即相似入住率区域在空间上略呈邻近趋势，可能反映社区功能或住房类型的局部一致性。然而，莫兰指数绝对值较小（接近 0），说明整体空间关联性较弱，实际集聚效应有限。General G 指数观测值为 0.0146（z=1.2252，p=0.2205），未通过显著性检验（p>0.05），表明入住率的高值或低值区域未形成统计学显著的聚集模式。尽管莫兰指数提示空间非完全随机，但 General G 结果进一步显示，纽约市入住率既无显著热点（High-Clusters）也无冷点（Low-Clusters）集中现象，可能因城市内部住房供需均衡或混合开发政策削弱了极端值的空间分化。通过上述数据分析的一下结论：

1. **弱全局自相关**：入住率分布存在轻微空间依赖性，但集聚强度较低，可能受社区规划或交通节点影响；
2. **局部无显著极化**：高/低入住率区域未形成显著聚集，反映城市住房分布的相对均衡性；
3. **政策启示**：结果或支持纽约市多中心发展策略的有效性，各类型房屋营销商应充分关联自身地域性优势，深化空间异质性归因分析，从而做出合理的定价策略。

4、 可视化反馈

本文将纽约市房源信息按照经纬度进行等间隔的划分取点，构造等分的小区域，计算每个区域内部的房租价格以及入住率的平均值作为本区域的特征属性，利用 ArcGIS 平台进行**局部空间自相关性的可视化分析**。

图中红点表示高值聚集，蓝点表示低值聚集，褐色点表示高值附近分布有低值，浅蓝色点表示低值附近分布高值。由此，我们可以判断房租图中，高值聚集点远多余低值聚集点，呈现较明显的正空间自相关性。也即房屋的平均房价可以普遍参考周边地区的平均属性值进行确定。而在入住率图中，四种颜色的点分布较为离散、数量均较少，说明不具有显著的聚集特征，也验证了图 13 中的正确性。房屋入住率与相临近的地域不具有强相关性，在定价时还需考虑自身独特的区位优势，而非随意跟随大众化趋势。

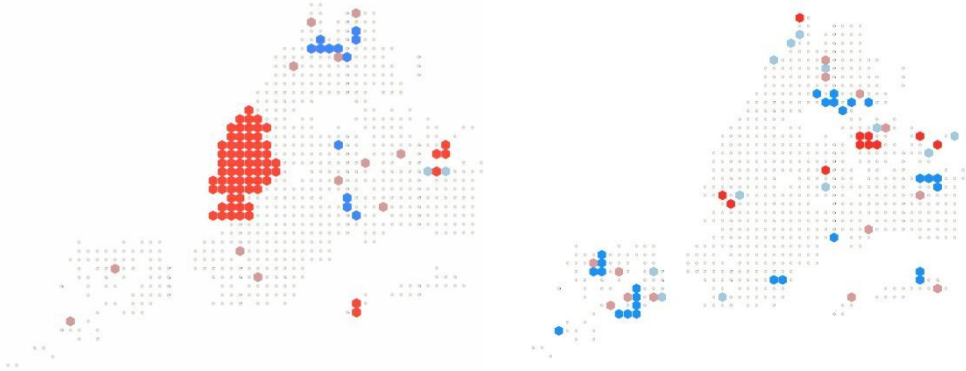


图 13：房租（左）和入住率（右）的空间自相关性可视化呈现

7. 最优定价策略与风险评估

7.1. 最优定价策略

7.1.1. 依据细分市场进行的拟合分析

参考本文先前所叙述的聚类分析思想，将所有出租房源分为三类：均衡经济型、轻奢高档型、低价供给型。经过数据的比对分析，本文得到三种聚类的入住率数据，分别为：均衡经济型 0.651、轻奢高档型 0.207、低价供给型 0.109。由此我们推断在纽约市短租市场之中，面向第一类的用户人群是核心市场，其需求量较高，且供需关系适配性良好，而轻奢高档型与低价供给型则需要针对不同的、特定的用户群体进行策略分析，而不宜沿用前文所述的综合拟合方程。故本文在此沿用先前的回归方程，代入三种聚类进行拟合分析，现将其系数呈现如下（表 10）。

值得一提的是，我们得到轻奢高档型聚类的拟合方程，其 R 值达到了 0.95，说明拟合效果很不错，且具有较强的解释性，此外经比对数据量发现轻奢高档型房源的互助相对集中，其名下皆具有较多的房源，可以认为属于有大运营规模、大运营经验的综合型房东。其服务保障全面，对于市场的判断明确、对房价的设定准确，其收益（入住率 •房租）是最大化程度较高。这说明对于房东，如果其名下的出租房规模较大，可以沿用并参考本文的拟合公式进行合理定价，以使得总收益最大化，如果仅为个体房东，本模型结果表示其房屋定价不完全具有决定作用，因为其房价对于入住率的影响水平不足够显著，但本模型所提供的拟合方程的回归系数则可以较为准确的反映什么因素对于总体收益的影响较大，是正向还是负向的作用。

表 10：按聚类划分的房价及入住率拟合方程系数

Variable	price Coefficient			room_in_ratio Coefficient		
	均衡经济型	轻奢高档型	低价供给型	均衡经济型	轻奢高档型	低价供给型
latitude	-0.397984	2.700419	-1.381720	0.142288	~~0.026432~~	0.097738
longtitude	-1.501955	-2.403020	-2.102102	~~-0.041353~~	~~-0.375409~~	-0.158850
minimum_nights	-0.002986	-0.001019	-0.002579	~~0.000331~~	-0.000706	~~0.000156~~
total_review	-0.094605	~~0.002388~~	~~-0.002553~~	-0.061485	~~0.016173~~	-0.027452
calculated_host_listings_count	-0.002986	0.004198	~~-0.000147~~	0.000334	0.000414	-0.000136
price				0.009388	~~0.005578~~	-0.022661
A1	0.000000	0.173440	0.000000	0.000000	-0.027558	0.000000
A2	0.134075	0.000000	-0.196030	~~0.020255~~	0.000000	0.042180
A3	0.265415	~~0.056817~~	~~0.032561~~	~~0.004325~~	~~0.011170~~	0.039196

Variable	均衡经济型	轻奢高档型	低价供给型	均衡经济型	轻奢高档型	低价供给型
A4	0.128057		~~-0.002353~~	~~0.015263~~		0.035410
A5	-0.346213		-0.804561	~~-0.032490~~		~~-0.016973~~
B1	0.296815	0.000000	0.649423	0.086302	0.000000	0.052795
B2	0.000000	0.000000	0.881320	0.000000	0.000000	~~0.038051~~
B3	-0.902423		~~-0.018988~~	0.108989		~~0.027229~~
B4	-0.867137		0.000000	~~0.070630~~		0.000000
_cons	-89.204440	-287.027100	-94.475810	-8.359781	~~-29.028770~~	-15.603900

*在上图中 A_1 代表 Bronx，A_2 代表 Brooklyn，A_3 代表 Manhattan，A_4 代表 Queens，A_5 代表 Staten Island，B_1 代表 Private room，B_2 代表 Entire home，B_3 代表 Shared room，B_4 代表 Hotel room，直线划掉的部分表示假设检验未通过的情况。

由上图数据可以，以均衡经济型的房价方程为例，我们可以得到，对于房东而言如果期望用户短租的最少天数较多，则最好适当降低房价以吸引住户（在表 10 中两者呈现负相关关系），而同时由于 B1 的相关系数相对参考 B2 为正，则说明用户可以以 Private room 的形式出租自己的房屋效果更好。总结来看，上述方程其实反映了一种市场大众化的趋势，作为房东，参考市场的价格值，同时结合自身房源条件调整，可以尽可能实现个人的总收益最大化。

7.1.2. 最优定价策略函数

本文充分考虑到了问题需求中**“预测性”以及“理论性”**这两者的差异，前者是基于市场普遍数据，构建回归模型，对于新情境新条件下的可能房租价格进行预测。由于本模型参考的数据都是市场反馈的真实情况，并不代表最优化的解，因此仅可作为“预测性”结果，不足以作为“最优化的策略”的全部参考凭证。而后者则是基于房东自身条件对于总收入（房租*入住率）最优化的理论最优值，若单独依据此数值作为唯一参考，可能会存在偏离市场行情很大、不够符合显示考量的情况存在。

所以，本模型在此提出**建设性的设想**，将两者进行整合，借鉴**卡尔曼滤波算法的思想**，将“先验值”与“观测值”通过赋予权重进行加成，得到加权平均值作为最终最优化策略。针对本文情景而言，即利用决定系数R^2作为权重进行加成。其理论可行性在于，当市场预测值决定系数R_1^2较大（接近 1）时，说明市场预测值比较靠近最优化的最终方案，此时预测值所占的权重较大；反之当理论最优解对应的入住率拟合方程决定系数R_2^2较大（接近 1），说明计算值对应的优化程度更高，其占比也应该较大。

具体操作实现流程如下：

1、确定聚类分类，求解市场预测值

首先，房东将自身房源所有的市场要素，如“经纬度”、“房型”、“计划出租的房源数量”以及房东的自身定位作为条件，确定所属聚类类型，将数据代入前文所述相应簇所对应的拟合公式，得到依据市场情况计算出的**预测最优房价**p_1。

$$p_1 = price = \exp\left(\sum_{i=1}^{n} \beta_i x_i + \gamma_1\right)$$

2、利用入住率回归公式，求解理论最优解

其次，利用同样聚类类型的入住率拟合公式，以$price$为自变量代入下式。此公式为兼顾收益与入住率，且考虑总收益（房租*入住率）的表达式：

$$\mathbf{M} = price \cdot room_in_ratio = price \cdot \left(\sum_{i=1}^{n-1} \beta_i x_i + \beta_n \ln(price) + \gamma_0\right)$$

对于每一个特定的聚类，相应的系数β_i均不相同，所以对于相应类型定位的房东，应针对所处类别的的独特特征属性，采取合适的定价方式，使得总收益 **M** 最大化。再对上式进行求导操作，得到极值点处的理论最优解p_2。

$$\sum_{i=1}^{n-1}\beta_i x_i+\beta_n\left(1+\ln(price)\right)=0$$

$$\textbf{a.k.a. } p_2=price=\exp\left(-\left(\beta_n+\sum_{i=1}^{n-1}\beta_i x_i\right)\Big/\beta_n\right)$$

3、决定系数进行权重加成，得到最终的最优策略

最后，我们利用两次拟合方程的决定系数R^2，构建各自的权重，将两个房价进行加权求和，即可得到最终的最优策略。

$$p_0=\frac{R_1^2}{R_1^2+R_2^2}p_1+\frac{R_2^2}{R_1^2+R_2^2}p_2$$

值得一提的是，在表 10 所呈现的六个拟合公式中，轻奢高档型房源的房价拟合方程，其决定系数最高，达到 0.95。类比滤波算法的极端情况，说明其拟合效果较好，解释能力较强，具有较高的收益最大化程度，相应市场预测值的占比极高，故该“预测性”价格本身可直接作为最终最优定价。同时，其入住率的拟合方程中，房价对入住率的相关系数未经过假设检验，说明房价（price）对入住率（$room_in_ratio$）没有影响，在进行加权时可以不用考虑。所以，在这种极端情况下，基于滤波的加权思想，本模型可以直接选取p_1作为其最优化收益策略。

综上所述，本模型充分考虑到了市场的不确定性、计算值的偏差性以及单一价格（“预测性”价格或“理论性”价格）极度可靠的特殊情况，通过赋予权重的方法最小化误差，来实现为房东主体提供最符合自身情况的最优定价策略，具有重大实践意义。

7.2. 风险评估分析

1、 房型-区域功能的适配性问题

数据显示，核心区高端房型房价虽然显著较高（推高 72.5%），但入住率却有下降（下降 10.6%）；边缘地区经济房型虽然维持周转与客源数量较高，但因房价基准较低导致收益收到影响。所以房东可以采取适当措施：**其一、需求聚类分析**，即通过分析本模型前面提到的聚类特征规律，判断区域的核心需求，例如在 Queens 区对于高端房源需求不多，也就需要调整出租房定位以限制过剩供给。**其二、差异化供给策略**，针对高溢价性或是普通型房源，可以采用不同的宣传与服务策略来提升竞争力、锚定市场需求。

2、 刚性租赁策略降低竞争力

回归结果显示，最短租期每增 1 天，房价下降 0.0046 单位（p<0.001），入住率降低 0.0014 单位（p<0.001）。故做出判断刚性租期限制因其缺乏对于市场灵活性的调整显著与市场需求错位。所以房东可以采取一下策略：**其一，租期-价格联动机制**，例如在核心区（A1）最短租期设为 7 天，适配商务客群需求。在边缘区（A5）设为 30 天但提供年租折扣（如 8%租金减免），吸引长租家庭。**其二，进行淡旺季动态调价**，进一步调查了解时间维度上的数据变化，针对相似的时间阶段采取特定的入住率阈值设定（如连续 30 天空置时降价 5%等等）。

3、 忽视市场反馈导致的信息闭环

在本模型中，我们默认将评论数量与房源热度相关联，但事实上用户的评价可以分为多种可能的类型，包括差评或是低曝光现象。所以数据拟合出的函数是一种答题的趋势，房东不应该随意地偏听偏信却忽视了现实中的具体情况。同样给出几点建议：其一，

在房源标题处嵌入高权重关键词（如 cozy、spacious、park 等等）以提高房源的曝光程度与关注度。我们分析了受欢迎程度较高的前 50%的房源名称数据中，删除无意义的语素，词云图分析如图【】，可以作为参考。其二，随时关注房屋住户的反馈，针对负面关键词及一些建议进行及时维护修补并及时反映，提高房屋的好评度。

8. 总结与展望

8.1. 优势优点

1、回归解释性强

本文中线性回归模型直观地反映了房型、热度、最小入住天数等诸多因素对房价和入住率的影响，便于房东理解各因素的驱动方向与关联强度。同时采用虚拟变量的方式，将地域标签属性也纳入回归方程的拟合之中，精准捕捉地域特性规律，具有较强的解释性与普遍性

2、稳健性修正

本模型采用了稳健性修正，利用怀特检验、F 检验和 t 检验，最大程度上减小内生性、异方差等等问题的影响，确保参数估计的可靠性，避免传统 OLS 的偏误。

3、综合空间自相关性

本文综合考量了空间自相关性在纽约市出租房价以及入住率方面的相关性，检索了大量相关政治、经济、社会等领域的文献，充分结合地域特征，综合考量房价和入住率的分布规律。以可视化的方式，直观、严谨、科学地进行呈现。

8.2. 问题不足

1、线性假设可能存在局限，对于非线性交互的可能性兼顾不足，如房价与交通便利性的阈值效应等，此类问题，也需要更多地了解相关数据与前人处理方法

2、出于模型科学性与可解性的考量，并且由于缺少必要数据本模型忽略了评论中负面评论对于因变量的影响，而将正面负面评论作为一个整体考量，其相关行的敏捷度会受到一点影响。

3、模型构建中，由于必要数据的缺失，本模型难以对“时间”这一关键维度进行衡量与评估，但在讨论优化定价策略时，时间维度也是一个至关重要的方面。

8.3. 工作建议

1、**时间维度补充**：进一步查阅相关数据，补充时间维度上的数据特征，构建面板数据模型。或引入广义加性模型（GAM）将连续变量以平滑函数拟合，捕捉非线性效应，进行时空动态建模以及交互项的变量分析，使得模型更加完备，普适性更强。

2、**地理数据精细化处理**：可以采集城市重要的 POI（如商业中心、学校、地铁站）精确位置坐标，用连续且更精准的地理属性代替粗粒度的行政区变量，提升区位解释力。

3、**用户市场画像**：此外，我们还可以收集租客用户的数据集画像，分析他们的评论内容，明确目标用户群体的核心特征与主要需求，便于房东提升服务质量以及服务针对性，提高资源的利用效率，促进供需平衡，避免时间空间上的浪费。

8.4. 外延拓展

1、**商业地产定价分析**：调整变量为“写字楼位置-企业类型-租金成本”，勇毅分析科创园区与金融中心的租赁策略差异，从租户的角度分析选取什么样的地段更有利于产业链铸造、产品销售渠道通畅以及运营的降本增效。

2、**城市规划评估**：本文的研究成果可以拓展至城市基础设施布局决策，将放假模型裤子汉纸公共服务可达性对居民居住满意度的影响，同样利用空间相关性以及

回归分析，量化城市规划与管理水平。

3、**优化短租平台：**借用本研究中呈现出的最小入住天数-评论数-命名词云图等关系，调整网页端的设计，知道房东对房源页面进行优化。

综上所述，本研究基于大量的多变量高维数据，建设性地对数据的内在相关性进行回归分析与聚类分析，得到不同房型、不同地区、不同细分市场的房源特征规律，并进行切实的量化呈现。同时，在对空间自相关性分析的基础上，定量给出了基于不同行政区划分的房东最优定价策略函数。尝试依据此函数，为房东提议使得总收益最大化的房租定价以及服务措施。结合纽约市各地区的政治、经济、文化特征，对房屋短租市场进行多角度综合汇报。

9. 参考文献

[1]黄利文.基于理想点的主成分分析法在综合评价中的应用[J].统计与决策,2021,37(10):184-188.

[2] 颜玉琪.基于 Excel 多元回归模型的纽约房价影响因素分析[A].大数据经济与数字管理国际会议论文集(BDECM 2022)[C].纽约:纽约大学,2022:1005-1009.

[3] Glaeser, E. L., Gyourko, J., & Saks, R. E. (2005). Why have housing prices gone up?［J］. *American Economic Review*, *95*(2), 329-333.

[4] Alonso, W. (1964). *Location and land use: Toward a general theory of land rent*［M］. Cambridge, MA: Harvard University Press.

[5] Rosen, S. (1974). Hedonic prices and implicit markets: Product differentiation in pure competition［J］. *Journal of Political Economy*, *82*(1), 34-55.

[6] Wheaton, W. C. (1990). Vacancy, search, and prices in a housing market matching model［J］. *Journal of Political Economy*, *98*(6), 1270-1292.

[7] Malpezzi, S. (1999). Economic analysis of housing markets in developing and transition economies［J］. *Urban Studies*, *36*(10), 1601-1621.

[8] Tobler, W. R. (1970). A computer movie simulating urban growth in the Detroit region. *Economic Geography*, *46*(sup1), 234–240.

[9] Getis, A., & Ord, J. K. (1992). The analysis of spatial association by use of distance statistics. *Geographical Analysis, 24*(3), 189–206.

10. 附录

1.unique-check

```
%% 重复行删除程序
clc; clear; close all;

% 读取处理后的数据
input_file = '2025 校赛第一轮赛题附件 1-A 题租房价格问题数据.csv';
data = readtable(input_file);

% 删除完全重复的行（保留首次出现的行）
[unique_data, ~, idx] = unique(data, 'rows', 'stable');
removed_rows = height(data) - height(unique_data);

% 写入新文件
output_file = '删去重复行.xlsx';
writetable(unique_data, output_file, 'Sheet', 'Sheet1');

% 显示处理结果
fprintf('===== 去重统计 =====\n');
fprintf('原始数据行数：%d\n', height(data));
fprintf('保留唯一行数：%d\n', height(unique_data));
fprintf('删除重复行数：%d\n', removed_rows);
disp('=== 数据已写入「删去重复行.xlsx」===');
```

2.data-clean

```
%% 数据清洗与导出程序
clc; clear; close all;

% ===== 读取原始数据 =====
raw_data = readtable('删去重复行.xlsx');

% ===== 数据清洗 =====
% 删除 host_name 为空的行（处理空字符串）
valid_rows = ~cellfun(@isempty, raw_data.host_name);
data_cleaned = raw_data(valid_rows, :);

% 删除 price 为缺失值的行（处理数值型缺失）
data_cleaned = data_cleaned(~isnan(data_cleaned.price), :);

% 填充 last_review 缺失值为 0（日期列特殊处理）
if isdatetime(data_cleaned.last_review)
    % 将日期缺失值填充为 NaT（特定日期格式）
    data_cleaned.last_review(isnat(data_cleaned.last_review)) = datetime(0,0,0);
else
    % 处理字符型日期缺失
    data_cleaned.last_review(cellfun(@isempty, data_cleaned.last_review)) =
{'1970-01-01'};
end

% 填充 reviews_per_month 缺失值为 0（数值列）
data_cleaned.reviews_per_month(isnan(data_cleaned.reviews_per_month)) = 0;

% ===== 数据导出 =====
output_filename = '缺失值 0 值处理.xlsx';
writetable(data_cleaned, output_filename, 'Sheet', 'Sheet1');
```

```
% ===== 统计验证 =====
fprintf('===== 处理结果统计 =====\n');
fprintf('原始数据行数：%d\n', height(raw_data));
fprintf('处理后数据行数：%d\n', height(data_cleaned));
fprintf('已删除 host_name 空值行：%d\n', sum(~valid_rows));
fprintf('已删除 price 缺失行：%d\n', sum(isnan(raw_data.price)));
fprintf('reviews_per_month 填充次数：%d\n',
sum(isnan(raw_data.reviews_per_month)));

disp('=== 数据处理完成 ===');
```

3.delete-review-availability-both-0

```
%% 删除指定条件的行并保存
clc; clear; close all;

% ===== 文件配置 =====
input_file = '删去重复行.xlsx';        % 输入文件
output_file = '删除指定行后数据.xlsx';   % 输出文件
target_col1 = 'last_review';          % 目标列 1
target_col2 = 'availability_365';     % 目标列 2（需确认列名）

% ===== 文件存在性检查 =====
if ~exist(input_file, 'file')
    error('输入文件 "%s" 不存在，请检查路径或文件名', input_file);
end

% ===== 读取数据 =====
try
    data = readtable(input_file, 'TextType', 'string'); % 强制文本类型读取
    fprintf('成功读取文件，总行数：%d\n', height(data));
catch ME
    error('文件读取失败，错误信息：\n%s', ME.message);
end

% ===== 列名验证 =====
column_names = data.Properties.VariableNames;
if ~all(ismember({target_col1, target_col2}, column_names))
    fprintf('错误：目标列名不匹配，可用列名为：\n');
    disp(column_names)
    error('请检查列名拼写（可能需改为 availability_365）');
end

% ===== 数据处理 =====
% 转换 last_review 列为字符串格式
data.(target_col1) = string(data.(target_col1));

% 处理 availability_365 列的非数值数据
if ~isnumeric(data.(target_col2))
    fprintf('正在转换"%s"列为数值类型...\n', target_col2);
    data.(target_col2) = str2double(data.(target_col2));
end

% 定义筛选条件
cond1 = (data.(target_col1) == "0");     % last_review 为字符串"0"
```

```
cond2 = (data.(target_col2) == 0);       % availability_365 为数值 0
rows_to_delete = cond1 & cond2;          % 同时满足两个条件

% 删除符合条件的行
cleaned_data = data(~rows_to_delete, :);

% ===== 写入新文件 =====
try
    writetable(cleaned_data, output_file, 'Sheet', 'Sheet1');
    fprintf('成功删除 %d 行数据，保存至文件：%s\n', sum(rows_to_delete), output_file);
catch
    error('写入失败，请关闭目标文件后重试');
end

% ===== 统计报告 =====
fprintf('\n===== 处理结果 =====\n');
fprintf('原始行数：%d\n', height(data));
fprintf('删除行数：%d (占比%.2f%%)\n', sum(rows_to_delete),
100*sum(rows_to_delete)/height(data));
fprintf('处理后行数：%d\n', height(cleaned_data));

% 可选：显示删除的示例行
if sum(rows_to_delete) > 0
    fprintf('\n=== 被删除的示例行（前 3 条）===\n');
    disp(head(data(rows_to_delete, :), 3))
end
```

4.price-histogram-normpdf

```
% 读取 Excel 文件数据
filename = '删除 365=0 和 review=0.xlsx'; % 替换为你的文件名
data = readtable(filename);

% 检查必要的列是否存在
if ~ismember('neighbourhood_group', data.Properties.VariableNames) || ...
   ~ismember('price', data.Properties.VariableNames)
    error('Excel 文件中缺少必要的列: neighbourhood_group 或 price');
end

% 获取不同的 neighbourhood_group
groups = unique(data.neighbourhood_group);
num_groups = length(groups);

% 检查是否有 5 组
if num_groups ~= 5
    warning('数据中 neighbourhood_group 的分组数量不是 5，而是%d', num_groups);
end

% 创建图形窗口
figure('Position', [100, 100, 1200, 800]);

% 对每组数据绘制直方图和正态分布曲线
for i = 1:num_groups
    % 提取当前组的数据
    group_name = groups{i};
    group_data = data(strcmp(data.neighbourhood_group, group_name), :);
    prices = group_data.price;
```

```
    % 计算均值和标准差
    mu = mean(prices);
    sigma = std(prices);

    % 创建子图
    subplot(2, 3, i); % 假设最多 6 个子图(2 行 3 列)

    % 绘制直方图
    h = histogram(prices, 'Normalization', 'pdf', 'BinMethod', 'auto');
    hold on;

    % 计算理想正态分布曲线
    x = linspace(min(prices), max(prices), 1000);
    y = normpdf(x, mu, sigma);

    % 绘制正态分布曲线
    plot(x, y, 'r', 'LineWidth', 2);

    % 添加标题和标签
    title(sprintf('%s\n(μ=%.2f, σ=%.2f)', group_name, mu, sigma));
    xlabel('Price');
    ylabel('Probability Density');
    legend('Price Distribution', 'Normal Distribution');
    grid on;

    hold off;
end

% 调整子图间距
sgtitle('Price Distribution by Neighbourhood Group with Normal Distribution Fit');
set(gcf, 'Color', 'w');
```

5.price-norm-test-JB-KS

```
% 读取 Excel 文件数据
filename = '删除 365=0 和 review=0.xlsx'; % 替换为你的文件名
data = readtable(filename);

% 检查必要的列是否存在
if ~ismember('neighbourhood_group', data.Properties.VariableNames) || ...
   ~ismember('price', data.Properties.VariableNames)
    error('Excel 文件中缺少必要的列: neighbourhood_group 或 price');
end

% 获取不同的 neighbourhood_group（确保五个区名称正确）
groups = {'Bronx', 'Brooklyn', 'Manhattan', 'Queens', 'Staten Island'};
num_groups = length(groups);

% 初始化结果存储（修正列名对齐问题）
results = table('Size', [num_groups, 7], ...
    'VariableTypes', {'string', 'double', 'double', 'double', 'double', 'double',
'double'}, ...
    'VariableNames', {'Group', 'Mean', 'Std', 'Skewness', 'Kurtosis', 'JB_p',
'KS_p'});

% 对每组数据进行正态性检验
for i = 1:num_groups
```

```
    % 提取当前组的数据
    group_name = groups{i};
    group_data = data(strcmp(data.neighbourhood_group, group_name), :);
    prices = group_data.price;

    % 计算统计量
    mu = mean(prices);
    sigma = std(prices);
    skew = skewness(prices);
    kurt = kurtosis(prices);

    % Jarque-Bera 检验
    [~, p_jb] = jbtest(prices, 0.05);

    % Kolmogorov-Smirnov 检验（标准化后检验）
    [~, p_ks] = kstest((prices - mu) / sigma);

    % 存储结果
    results.Group(i) = group_name;
    results.Mean(i) = mu;
    results.Std(i) = sigma;
    results.Skewness(i) = skew;
    results.Kurtosis(i) = kurt;
    results.JB_p(i) = p_jb;
    results.KS_p(i) = p_ks;
end

% 显示检验结果
disp('正态性检验结果:');
disp(results);

% 输出结论
fprintf('\n 结论:\n');
for i = 1:num_groups
    group_name = results.Group(i);
    jb_p = results.JB_p(i);
    ks_p = results.KS_p(i);

    jb_result = ifelse(jb_p > 0.05, '不能拒绝正态性 (p > 0.05)', '拒绝正态性 (p ≤
0.05)');
    ks_result = ifelse(ks_p > 0.05, '不能拒绝正态性 (p > 0.05)', '拒绝正态性 (p ≤
0.05)');

    fprintf('组别: %s\n', group_name);
    fprintf('  - JB 检验: %s (p = %.4f)\n', jb_result, jb_p);
    fprintf('  - KS 检验: %s (p = %.4f)\n', ks_result, ks_p);
    fprintf('----------------------------------\n');
end

% 辅助函数（类似 Excel 的 IF 函数）
function output = ifelse(condition, true_val, false_val)
    if condition
        output = true_val;
    else
        output = false_val;
    end
end
```

6.price-boxplot

```
% 读取数据
filename = '删除 365=0 和 review=0.xlsx';
data = readtable(filename);

% 检查必要列
if ~ismember('neighbourhood_group', data.Properties.VariableNames) || ...
   ~ismember('price', data.Properties.VariableNames)
    error('Excel 文件中缺少 neighbourhood_group 或 price 列');
end

% 定义五个行政区
groups = {'Bronx', 'Brooklyn', 'Manhattan', 'Queens', 'Staten Island'};
num_groups = length(groups);

% 提取各组数据（允许不同长度）
prices = cell(num_groups, 1);
for i = 1:num_groups
    prices{i} = data.price(strcmp(data.neighbourhood_group, groups{i}));
    prices{i} = prices{i}(~isnan(prices{i})); % 移除 NaN 值
end

% 创建图形
figure('Position', [100, 100, 900, 600]);

% ========== 方法 1：使用通用 boxplot（兼容所有版本） ==========
subplot(2, 1, 1);
hold on;
for i = 1:num_groups
    % 绘制箱线图（手动指定位置）
    boxplot(prices{i}, 'Positions', i, 'Widths', 0.6, 'Colors', 'k', 'Symbol', 'r+');
end
set(gca, 'XTick', 1:num_groups, 'XTickLabel', groups);
title('各行政区价格分布（传统 boxplot）');
ylabel('Price');
grid on;

% 标记均值
means = cellfun(@mean, prices);
plot(1:num_groups, means, 'rx', 'MarkerSize', 10, 'LineWidth', 2);
legend('均值', 'Location', 'northwest');
hold off;

% ========== 方法 2：使用更美观的 violinplot 替代 ==========
subplot(2, 1, 2);
if exist('violinplot', 'file') == 2 % 检查是否安装 violinplot 工具箱
    violinplot(prices, groups, 'ShowMean', true);
    title('各行政区价格分布（小提琴图）');
else
    text(0.5, 0.5, '如需更美观的可视化，请安装 violinplot 工具箱', ...
         'HorizontalAlignment', 'center', 'FontSize', 12);
    title('小提琴图未安装（替代方案）');
end

% 调整布局
```

```
sgtitle('价格分布对比分析');
set(gcf, 'Color', 'w');
```

7.IQR-k=5

```
% 读取数据
filename = '删除 365=0 和 review=0.xlsx';
data = readtable(filename);

% 检查必要列
if ~ismember('neighbourhood_group', data.Properties.VariableNames) || ...
   ~ismember('price', data.Properties.VariableNames)
    error('Excel 文件中缺少 neighbourhood_group 或 price 列');
end

% 定义五个行政区（按实际数据调整名称）
groups = {'Bronx', 'Brooklyn', 'Manhattan', 'Queens', 'Staten Island'};
num_groups = length(groups);

% 初始化清洗后的数据表
clean_data = table();

% 设置 IQR 倍数（此处设为 5）
iqr_multiplier = 5;

% 遍历每个行政区
for i = 1:num_groups
    % 提取当前组数据
    group_name = groups{i};
    group_mask = strcmp(data.neighbourhood_group, group_name);
    group_prices = data.price(group_mask);

    % 计算 IQR 和边界（使用 IQR 5 倍）
    Q1 = prctile(group_prices, 25);
    Q3 = prctile(group_prices, 75);
    IQR = Q3 - Q1;
    lower_bound = Q1 - iqr_multiplier * IQR;
    upper_bound = Q3 + iqr_multiplier * IQR;

    % 标记非异常值（保留范围内的数据）
    is_normal = (group_prices >= lower_bound) & (group_prices <= upper_bound);
    clean_group_data = data(group_mask, :);
    clean_group_data = clean_group_data(is_normal, :);

    % 合并到总表
    clean_data = [clean_data; clean_group_data];

    % 打印统计信息
    fprintf('【%s】\t 原始数据: %d 条\t 剔除异常值: %d 条\t 保留数据: %d 条\n', ...
            group_name, sum(group_mask), sum(~is_normal), sum(is_normal));
    fprintf('  边界值: [%.2f, %.2f]\tIQR: %.2f\n', lower_bound, upper_bound, IQR);
end

% 保存清洗后的数据（可选）
writetable(clean_data, '清洗后数据_IQR5.xlsx');
```

```
% 可视化对比（原始 vs 清洗后）
figure('Position', [100, 100, 1400, 600]);

% 原始数据箱线图
subplot(1, 2, 1);
boxplot(data.price, data.neighbourhood_group, 'GroupOrder', groups, 'Whisker',
1.5);
title('原始数据箱线图（IQR 1.5 倍异常值）', 'FontWeight', 'bold');
ylabel('Price');
grid on;

% 清洗后数据箱线图（IQR 5 倍剔除）
subplot(1, 2, 2);
boxplot(clean_data.price, clean_data.neighbourhood_group, 'GroupOrder', groups,
'Whisker', 1.5);
title(sprintf('清洗后数据箱线图（IQR %.1f 倍剔除异常值）', iqr_multiplier),
'FontWeight', 'bold');
ylabel('Price');
grid on;

% 调整图形样式
set(gcf, 'Color', 'w');
sgtitle('价格数据异常值剔除效果对比', 'FontSize', 14, 'FontWeight', 'bold');
```

8.price-scatter

```
% 读取数据（假设是 CSV 或 Excel 文件）
data = readtable('IQR=5 剔除五个行政区 price 异常值.xlsx'); % 如果是 CSV，用
readtable('file.csv')

% 定义五个行政区
neighborhoods = {'Bronx', 'Brooklyn', 'Manhattan', 'Queens', 'Staten Island'};

% 设置价格区间划分（根据你的数据调整）
price_bins = [0 50 100 150 200 300 500 1000 inf];
price_labels = {'0-50', '50-100', '100-150', '150-200', '200-300', '300-500',
'500-1000', '1000+'};
num_bins = length(price_bins) - 1;

% 创建冷色调→暖色调渐变颜色（蓝→青→绿→黄→红）
cool_warm_colors = [
    0   0   1;   % 蓝色（最低价）
    0   1   1;   % 青色
    0   1   0;   % 绿色
    1   1   0;   % 黄色
    1   0.5 0;   % 橙色
    1   0   0    % 红色（最高价）
];
% 插值生成足够的颜色
cool_warm_map = interp1(linspace(0, 1, size(cool_warm_colors, 1)),
cool_warm_colors, linspace(0, 1, num_bins));

% 为每个行政区绘制散点图
for i = 1:length(neighborhoods)
    neighborhood = neighborhoods{i};
    mask = strcmp(data.neighbourhood_group, neighborhood);
    subdata = data(mask, :);
```

```
    figure;
    hold on;

    % 绘制每个价格区间的散点
    for j = 1:num_bins
        lower = price_bins(j);
        upper = price_bins(j+1);

        if j == num_bins
            price_mask = (subdata.price >= lower) & (subdata.price <= upper);
        else
            price_mask = (subdata.price >= lower) & (subdata.price < upper);
        end

        % 使用渐变色映射
        scatter(subdata.longitude(price_mask), subdata.latitude(price_mask), ...
            36, ... % 点的大小
            cool_warm_map(j, :), ... % 颜色
            'filled', ... % 填充点
            'DisplayName', price_labels{j});
    end

    % 美化图形
    title(sprintf('Price Distribution in %s (Cool→Warm Colors)', neighborhood));
    xlabel('Longitude');
    ylabel('Latitude');
    legend('Location', 'best');
    grid on;
    hold off;
end
```

9.price-room-in-ratio

```
% 读取数据文件
filename = 'IQR=5 剔除五个行政区 price 异常值.xlsx'; % 或.csv
if exist(filename, 'file')
    data = readtable(filename);
else
    error('文件未找到，请检查文件名和路径');
end

% 提取所需数据列
required_cols = {'room_type', 'neighbourhood_group', 'price', 'room_in_ratio'};
if ~all(ismember(required_cols, data.Properties.VariableNames))
    error('数据文件中缺少必要的列');
end

% 数据预处理
room_types = {'Private room', 'Entire home/apt', 'Shared room', 'Hotel room'};
neighbourhoods = unique(data.neighbourhood_group);
colors = lines(length(neighbourhoods)); % 为每个行政区分配独特颜色

% 计算每种房型-行政区的平均价格和入住率
avg_price = zeros(length(room_types), length(neighbourhoods));
avg_ratio = zeros(length(room_types), 1);

for i = 1:length(room_types)
```

```
    for j = 1:length(neighbourhoods)
        idx = strcmp(data.room_type, room_types{i}) & ...
              strcmp(data.neighbourhood_group, neighbourhoods{j});
        avg_price(i,j) = mean(data.price(idx));
    end
    % 计算每种房型的平均入住率
    idx = strcmp(data.room_type, room_types{i});
    avg_ratio(i) = mean(data.room_in_ratio(idx));
end

%% 创建组合图表
figure('Position', [100, 100, 1000, 600]);

% 绘制柱状图（左侧 y 轴）
yyaxis left
hold on
bar_handles = gobjects(length(neighbourhoods), 1); % 存储柱状图句柄

% 为每个行政区绘制柱状图
x_pos = 1:length(room_types);
x_offset = linspace(-0.2, 0.2, length(neighbourhoods)); % 柱子位置偏移

for j = 1:length(neighbourhoods)
    bar_pos = x_pos + x_offset(j);
    bar_handles(j) = bar(bar_pos, avg_price(:,j), 0.15, ...
                     'FaceColor', colors(j,:), ...
                     'EdgeColor', 'none');
end

ylabel('平均房价 (Price)');
set(gca, 'YColor', 'k');

% 绘制折线图（右侧 y 轴）
yyaxis right
plot(x_pos, avg_ratio, 'k-o', ...
     'LineWidth', 2, ...
     'MarkerSize', 8, ...
     'MarkerFaceColor', 'w');
ylabel('平均入住率 (Room in Ratio)');
set(gca, 'YColor', 'k');

% 设置图表属性
set(gca, 'XTick', x_pos, 'XTickLabel', room_types);
xlabel('房型');
title('各行政区不同房型的房价与入住率比较');
grid on;

% 添加图例
legend([bar_handles; gco], [neighbourhoods; '平均入住率'], ...
       'Location', 'bestoutside', ...
       'FontSize', 10);
% 调整坐标轴范围
yyaxis left
ylim([0 max(avg_price(:))*1.1]);
yyaxis right
ylim([0 max(avg_ratio)*1.1]);
```

```
% 添加数据标签
for i = 1:length(room_types)
    for j = 1:length(neighbourhoods)
        text(x_pos(i)+x_offset(j), avg_price(i,j), ...
             num2str(avg_price(i,j), 'Rotation', 90, ...
             'VerticalAlignment', 'bottom', ...
             'HorizontalAlignment', 'center', ...
             'FontSize', 8));
    end
    text(x_pos(i), avg_ratio(i), ...
         [' ' num2str(avg_ratio(i))], ...
         'VerticalAlignment', 'middle', ...
         'HorizontalAlignment', 'left', ...
         'FontSize', 9, 'Color', 'k');
end

disp('图表绘制完成');
```

10.correlation

```
% 读取数据文件（自动检测.xlsx 或.csv 格式）
filename = 'pre_cor';
if exist([filename '.xlsx'], 'file')
    data = readtable([filename '.xlsx']);
elseif exist([filename '.csv'], 'file')
    data = readtable([filename '.csv']);
else
    error('文件未找到: 请确保 pre_cor.xlsx 或 pre_cor.csv 存在于当前目录');
end

% 选择需要标准化的列
target_cols = {'latitude', 'longitude', 'price', 'minimum_nights', ...
               'calculated_host_listings_count', 'availability_365'};

% 检查所有列是否都存在
missing_cols = setdiff(target_cols, data.Properties.VariableNames);
if ~isempty(missing_cols)
    error('文件中缺少以下列: %s', strjoin(missing_cols, ', '));
end

% 提取需要标准化的数据
data_to_normalize = data(:, target_cols);

% 转换为数值矩阵（忽略非数值数据）
numeric_data = table2array(data_to_normalize);

% Z-score 标准化函数
zscore_normalized = zscore(numeric_data);

% 将标准化后的数据存回新表格
normalized_data = array2table(zscore_normalized, 'VariableNames', target_cols);

% 显示前 5 行标准化结果
disp('标准化后的前 5 行数据:');
disp(normalized_data(1:5, :));

% 可视化标准化前后的数据分布对比
figure('Position', [100, 100, 1200, 600]);
```

```
% 标准化前的箱线图
subplot(1,2,1);
boxplot(numeric_data, 'Labels', target_cols);
title('标准化前的数据分布');
ylabel('原始值');
set(gca, 'XTickLabelRotation', 45);

% 标准化后的箱线图
subplot(1,2,2);
boxplot(zscore_normalized, 'Labels', target_cols);
title('Z-score 标准化后的数据分布');
ylabel('标准化值');
set(gca, 'XTickLabelRotation', 45);

% 保存标准化后的数据到新文件
writetable(normalized_data, 'pre_cor_normalized.xlsx');
disp('标准化数据已保存为: pre_cor_normalized.xlsx');

% 读取标准化后的数据文件
filename = 'pre_cor_normalized.xlsx';
if exist(filename, 'file')
    data = readtable(filename);
elseif exist('pre_cor_normalized.csv', 'file')
    data = readtable('pre_cor_normalized.csv');
else
    error('文件未找到: 请确保 pre_cor_normalized.xlsx 或 pre_cor_normalized.csv 存在
');
end


% 提取前 10 列数据（如果不足 10 列则使用全部列）
num_cols = min(10, width(data));
selected_data = data(:, 1:num_cols);
var_names = selected_data.Properties.VariableNames;
data_matrix = table2array(selected_data);

% 计算三种相关系数矩阵
pearson_corr = corr(data_matrix, 'Type', 'Pearson');
spearman_corr = corr(data_matrix, 'Type', 'Spearman');
kendall_corr = corr(data_matrix, 'Type', 'Kendall');

% 创建自定义蓝-白-红色彩图（冷到暖渐变）
colors = zeros(256,3);
% 蓝色渐变（0 到 0.5：深蓝到浅蓝）
colors(1:128,3) = linspace(0.8, 1, 128)';    % 蓝色通道
colors(1:128,1) = linspace(0.2, 1, 128)';    % 红色通道（渐变到白）
colors(1:128,2) = linspace(0.2, 1, 128)';    % 绿色通道（渐变到白）
% 红色渐变（0.5 到 1：浅红到深红）
colors(129:256,1) = linspace(1, 0.8, 128)';  % 红色通道
colors(129:256,2) = linspace(1, 0.2, 128)';  % 绿色通道（渐变出）
colors(129:256,3) = linspace(1, 0.2, 128)';  % 蓝色通道（渐变出）

%% 绘制皮尔逊相关系数热力图
figure('Position', [100, 100, 800, 700], 'Name', 'Pearson Correlation');
h1 = heatmap(var_names, var_names, pearson_corr);
h1.Colormap = colors;
```

```
h1.ColorLimits = [-1 1];
h1.Title = '皮尔逊相关系数 (Pearson Correlation)';
h1.ColorbarVisible = 'on';
h1.FontSize = 12;
h1.Interpreter = 'none';
annotation('textbox', [0.3 0.9 0.4 0.05], 'String', '冷色调(负相关) → 暖色调(正相关)', ...
           'EdgeColor', 'none', 'HorizontalAlignment', 'center', 'FontSize', 14);

%% 绘制斯皮尔曼秩相关系数热力图
figure('Position', [100, 100, 800, 700], 'Name', 'Spearman Correlation');
h2 = heatmap(var_names, var_names, spearman_corr);
h2.Colormap = colors;
h2.ColorLimits = [-1 1];
h2.Title = '斯皮尔曼秩相关系数 (Spearman Rank Correlation)';
h2.ColorbarVisible = 'on';
h2.FontSize = 12;
h2.Interpreter = 'none';
annotation('textbox', [0.3 0.9 0.4 0.05], 'String', '冷色调(负相关) → 暖色调(正相关)', ...
           'EdgeColor', 'none', 'HorizontalAlignment', 'center', 'FontSize', 14);

%% 绘制肯德尔τ相关系数热力图
figure('Position', [100, 100, 800, 700], 'Name', 'Kendall Tau Correlation');
h3 = heatmap(var_names, var_names, kendall_corr);
h3.Colormap = colors;
h3.ColorLimits = [-1 1];
h3.Title = '肯德尔τ相关系数 (Kendall τ Correlation)';
h3.ColorbarVisible = 'on';
h3.FontSize = 12;
h3.Interpreter = 'none';
annotation('textbox', [0.3 0.9 0.4 0.05], 'String', '冷色调(负相关) → 暖色调(正相关)', ...
           'EdgeColor', 'none', 'HorizontalAlignment', 'center', 'FontSize', 14);

disp('三种相关系数热力图绘制完成');
```

11.z-score

```
% 1. 读取原始 Excel 文件
filename = '评价性数据.xlsx';  % 替换为你的 Excel 文件名
data = readtable(filename);

% 2. 选择需要标准化的列
columns_to_normalize = {'number_of_reviews', 'last_review', 'reviews_per_month', 'number_of_reviews_ltm'};

% 3. 创建新表存储标准化结果
normalized_data = data;  % 复制原始数据

% 4. 对每列进行 Z-score 标准化
for i = 1:length(columns_to_normalize)
    col_name = columns_to_normalize{i};
    col_data = table2array(data(:, col_name));

    if ~isnumeric(col_data)
        error('列 %s 包含非数值数据，请先清理数据', col_name);
```

```
    end

    mu = mean(col_data, 'omitnan');
    sigma = std(col_data, 'omitnan');
    normalized_data.(col_name) = (col_data - mu) / sigma;
end

% 5. 保存结果
output_filename = '评价性数据_zscore 标准化.xlsx';
writetable(normalized_data, output_filename);
disp(['标准化完成！结果保存到: ' output_filename]);
```

12.adjustment.py

```
import numpy as np
import pandas as pd
from scipy.stats import yeojohnson

df = pd.read_excel('prePCA.xlsx')
# 计算偏度
skewness = df.skew()
print(skewness)

for i in range(len(skewness)):
    if skewness[i] > 5:
        # 对数据进行变换
        df.iloc[:, i], _ = yeojohnson(df.iloc[:, i])
    else:
        df.iloc[:, i] = df.iloc[:, i]

skewness = df.skew()
print(skewness)

df.to_excel('output.xlsx', index=False) # index=False 表示不保存索引
```

13.review-PCA

```
%% 读取数据
data = readtable('pre_PCA.xlsx');
data_matrix = table2array(data);

%% 去均值处理
centered_data = data_matrix - mean(data_matrix, 1);

%% 执行 PCA（禁用自动中心化）
[coeff, ~, latent, ~, explained] = pca(centered_data, 'Centered', false);

%% 可视化设置
figure('Position', [100 100 1200 800])

% 1. 方差贡献率图
subplot(2,2,1);
bar(explained(1:4));
grid on;
title('方差贡献率');
xlabel('主成分');
ylabel('贡献率 (%)');
xticks(1:4)
```

```
% 2. 碎石图
subplot(2,2,2);
plot(1:4, latent(1:4), '-o', 'LineWidth', 1.5);
grid on;
title('碎石图');
xlabel('主成分');
ylabel('特征值');
xticks(1:4)

% 3. 特征向量热图（蓝色渐变）
subplot(2,2,[3,4]);

% 创建自定义蓝色渐变 colormap
blue_gradient = [linspace(0.9,0.2,64)' linspace(0.9,0.2,64)'
linspace(1,0.5,64)']; % 从淡蓝到深蓝
colormap(blue_gradient);

% 处理变量名称中的下划线
varNames = data.Properties.VariableNames;
varNames = cellfun(@(x) strrep(x, '_', '\_'), varNames, 'UniformOutput', false);

% 创建热力图
h = heatmap(varNames, {'PC1','PC2','PC3','PC4'}, coeff(:,1:4)');
h.Title = '特征向量热图 (蓝色渐变)';
h.Colormap = blue_gradient;  % 应用自定义 colormap
h.XLabel = '原始特征';
h.YLabel = '主成分';
h.FontSize = 10;

% 设置颜色范围（根据数据范围自动调整）
color_min = min(coeff(:));
color_max = max(coeff(:));
clim([color_min color_max]); % 确保颜色映射覆盖数据全范围

%% 可选：添加颜色条说明
% colorbar('Ticks',linspace(color_min,color_max,5),...
%          'TickLabels',{'最低','','','','最高'});
```

14.k-means-3

```
%% 数据读取与预处理
% 读取 Excel 数据文件
data = readtable('IQR=5 剔除五个行政区 price 异常值.xlsx');

% 提取关键特征列（示例字段，需根据实际数据调整）
% 假设数据包含以下字段：price, availability_365, number_of_reviews, latitude,
longitude
X = [data.price, data.availability_365, data.number_of_reviews, data.latitude,
data.longitude];

% 标准化数据（Z-score 标准化）
X_normalized = zscore(X);

%% 确定最佳聚类数 K（肘部法则）
% 计算不同 K 值下的簇内平方和（SSE）
```

```
max_clusters = 8;
sse = zeros(max_clusters, 1);
for k = 1:max_clusters
    [~, ~, sumd] = kmeans(X_normalized, k, 'Replicates', 10);  % 重复 10 次避免局部最优
    sse(k) = sum(sumd);
end

% 绘制肘部图
figure;
plot(1:max_clusters, sse, 'bo-');
xlabel('聚类数 K');
ylabel('簇内平方和 (SSE)');
title('肘部法则确定最佳 K 值');
grid on;

%% 执行 K-means 聚类（选择 K=3）
k = 3;  % 根据肘部图或业务需求调整
[cluster_labels, centroids] = kmeans(X_normalized, k, 'Replicates', 10);

%% 可视化聚类结果
% 地理分布图（经纬度散点图）
figure;
gscatter(data.longitude, data.latitude, cluster_labels, 'rgb', 'o', 10);
xlabel('经度');
ylabel('纬度');
title('房源地理分布聚类结果');
legend('Cluster 1', 'Cluster 2', 'Cluster 3');

% 特征分布图（价格 vs 入住率）
figure;
gscatter(data.price, data.availability_365, cluster_labels, 'rgb', 'o', 10);
xlabel('价格 (Price)');
ylabel('可预订天数 (Availability 365)');
title('价格与可预订天数聚类分布');
legend('Cluster 1', 'Cluster 2', 'Cluster 3');

%% 聚类结果分析
% 计算每个簇的统计特征
clustered_data = array2table([X, cluster_labels], ...
    'VariableNames', {'Price', 'Availability', 'Reviews', 'Latitude', 'Longitude', 'Cluster'});

% 按簇分组统计均值
cluster_stats = grpstats(clustered_data, 'Cluster', {'mean', 'median', 'std'});
disp(cluster_stats);

% 绘制箱线图（价格分布对比）
figure;
boxplot(clustered_data.Price, clustered_data.Cluster);
xlabel('簇');
ylabel('价格');
title('不同簇的价格分布对比');
```

15.k-means-total-3

```
%% Step 1: 读取数据
filename = 'processed_profit_fixed_dates.xlsx';
data = readtable(filename);

% 明确使用哪些数值列
numericCols = { 'price', 'minimum_nights', ...
                'calculated_host_listings_count','total_review', ...
               'room_in_ratio'};

% 提取数值数据
X = data{:, numericCols};

% 去除缺失
X = rmmissing(X);

% 标准化
X_norm = normalize(X);

%% Step 2: 用肘部法则选择 k
maxK = 10;
sumd = zeros(1, maxK);
for k = 1:maxK
    [~, ~, D] = kmeans(X_norm, k, 'Replicates', 5, 'Display', 'off');
    sumd(k) = sum(D);
end

% 可视化肘部图
figure;
plot(1:maxK, sumd, '-o', 'LineWidth', 1.5);
xlabel('聚类数 (k)');
ylabel('总误差平方和');
title('肘部法则选择最佳聚类数');
grid on;

%% Step 3: 正式聚类（你可以根据上面图手动选择合适的 k）
k = 3;  % <== 手动设置最佳 k，按需修改
[idx, C] = kmeans(X_norm, k, 'Replicates', 20, 'Display', 'final');

%% Step 4: 可视化结果（price vs room_in_ratio）
price_col = find(strcmp(numericCols, 'price'));
room_ratio_col = find(strcmp(numericCols, 'room_in_ratio'));

figure;
gscatter(X(:, price_col), X(:, room_ratio_col), idx);
xlabel('Price');
ylabel('Room-in Ratio');
title('K-means 聚类结果');
legend('Cluster 1', 'Cluster 2', 'Cluster 3', 'Location', 'best');
grid on;

%% Step 5: 保存模型，用于预测
model.centroids = C;
model.mean = mean(X);
model.std = std(X);
model.numericCols = numericCols;
save('cluster_model.mat', 'model');
```

```
fprintf('聚类完成，模型已保存。\n');
%% Step 6: 保存带聚类标签的数据到 Excel

% 添加聚类标签列到原始数据表
data.ClusterLabel = NaN(height(data),1);  % 先初始化
data_cleaned = data(~any(ismissing(X), 2), :);  % 去除参与聚类的数据行
data_cleaned.ClusterLabel = idx;  % 加入聚类结果

% 保存为 Excel 文件
outputFilename = 'clustered_output.xlsx';
writetable(data_cleaned, outputFilename);

fprintf('带聚类标签的数据已保存为：%s\n', outputFilename);
```

16.stata-nihe

```
import excel "C:\Users\HP\Desktop\拟合\processed_profit_fixed_dates.xlsx",
sheet("Sheet1") firstrow
tab neighbourhood_group,gen(A)
tab room_type,gen(B)
reg price latitude longitude minimum_nights calculated_host_listings_count
total_review A1 A2 A3 A4 A5 B1 B2 B3 B4
estat imtest,white
reg price latitude longitude minimum_nights calculated_host_listings_count
total_review A1 A2 A3 A4 A5 B1 B2 B3 B4,r
reg room_in_ratio latitude longitude price minimum_nights
calculated_host_listings_count total_review A1 A2 A3 A4 A5 B1 B2 B3 B4
estat imtest,white
reg room_in_ratio latitude longitude price minimum_nights
calculated_host_listings_count total_review A1 A2 A3 A4 A5 B1 B2 B3 B4,r
```