参赛承诺书

提交包含此承诺书的 pdf 文件，表明所有此文件的作者共同承诺：

我们完全清楚，在竞赛开始后参赛队员不能以任何方式，包括电话、电子邮件、“贴吧”、QQ 群、微信群等，与队外的任何人（包括指导教师）交流、讨论与赛题有关的问题；无论主动参与讨论还是被动接收讨论信息都是严重违反竞赛纪律的行为。

我们以中国大学生名誉和诚信郑重承诺，严格遵守竞赛章程和参赛规则，以保证竞赛的公正、公平性。如有违反竞赛章程和参赛规则的行为，我们将受到严肃处理。

我们授权北京理工大学数学建模竞赛组织方，可将我们的论文以任何形式进行公开展示（包括进行网上公示，在书籍、期刊和其他媒体进行正式或非正式发表等）。

2025.5

“风云变幻”——基于 XGBoost 与 VAR 协同预测大气边界层高度

摘要：本文研究了大气边界层高度（Atmospheric Boundary Layer Height, ABLH）与诸多气象要素及空气质量指标之间的量化关系，并构建了预测模型以提升空气质量预报精度及 ABLH 计算准确度。

首先，针对 ABLH 与气象要素的量化关系，研究利用 XGBoost 决策树模型分析了温度、湿度、风速、气压等因素对 ABLH 的影响。通过数据预处理和特征重要性评估，发现潜热通量对 ABLH 的影响最为显著，表明其是驱动边界层高度变化的主导因子。

其次，为探究 ABLH 与空气质量指标的关联，研究采用向量自回归（VAR）模型分析其时间序列特征。通过主成分分析（PCA）对 ABLH 数据降维，并按月份划分数据以捕捉季节性差异，构建了多变量动态模型。结果显示，ABLH 变化与污染物浓度（如 PM2.5）存在显著相关性，反映了边界层高度对污染物扩散的调控作用。

最后，研究提出了一种基于贝叶斯估计的正态序列融合模型，用于预测次日 ABLH。该模型整合了 XGBoost 和 VAR 的预测结果，利用贝叶斯信息融合策略提升精度。模型能够处理高维数据并捕捉非线性关系，具有较高的准确性和泛化能力。

关键词：XGBoost 决策树、VAR 向量自回归、贝叶斯信息融合、PCA

“风云变幻”——基于 XGBoost 与 VAR 协同预测大气边界层高度

1. 问题背景与重述

1.1. 问题背景

大气边界层高度（Atmospheric Boundary Layer Height, ABLH）是表征近地表大气湍流混合、污染物扩散和能量交换的核心参数，其动态变化直接影响空气质量预报精度、污染物垂直传输效率及局地气候系统的稳定性。

在城市化与工业化叠加的长三角地区，ABLH 的时空异质性因复杂下垫面特征和人为热释放效应显著增强，导致边界层结构对气象要素（如温度、湿度、风速、气压）的敏感性进一步凸显。研究表明，温度垂直梯度通过热力浮力作用调控边界层发展[1]，湿度场影响大气稳定度[2]，风速切变则通过机械湍流改变混合层厚度[3]，而气压场与地形耦合可能引发局地环流异常[4]，进而干扰 ABLH 的日变化规律。然而，如何从多维度气象数据中提取关键驱动因子并建立量化关系模型，仍是当前研究的难点。此外，ABLH 的压缩会限制污染物的垂直扩散，导致 $PM_{2.5}$、PM_{10}、NO_2 等污染物浓度积聚，但其与空气质量指数（AQI）的耦合机制尚不明确，亟需结合地面污染物浓度数据构建跨尺度关联模型。

1.2. 问题重述

在研究空气污染扩散、天气预报、气候变化等问题时，大气边界层高度(ABLH)是一个非常重要的指标。ABLH 与很多因素有关，比如温度、湿度、风速、气压等。位于嘉兴的北京理工大学长三角研究院曾利用激光雷达观测大气边界层高度，并同步获取了当地的温度、湿度、风速、气压等相关数据，结合相关数据解决以下问题：

1、建立数学模型分析 ABLH 与温度、湿度、风速、气压等因素之间的量化关系，评估这些因素对 ABLH 的影响大小。

2、ABLH 的变化会影响到当地空气质量，请结合当地空气质量数据，选择合理的数学模型分析 ABLH 与空气质量相关指标($PM_{2.5}$、PM_{10}、NO_2、AQI 等)的量化关系，　3、建立一个数学模型，根据天气预报数据来预测次日 ABLH，并说明该模型的合理性。

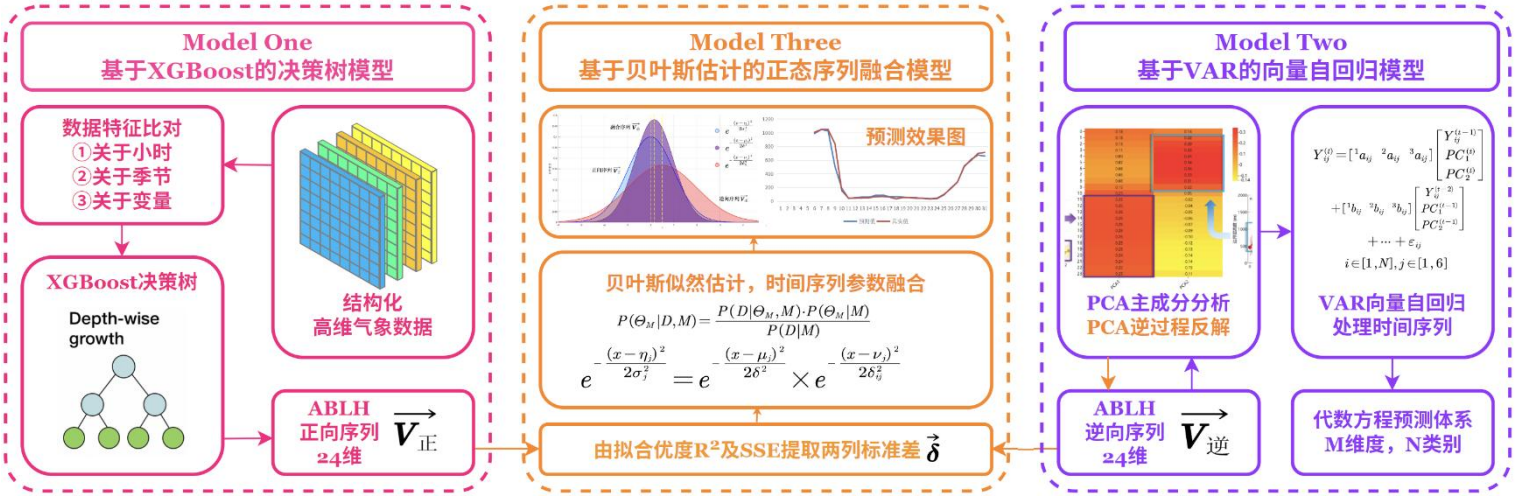


图 1：全文模型综合实现过程示意图

2. 问题分析

2.1. 对问题一的分析

在问题一中，本文将首先从数据集的显式分布特征入手，理解目标自变量与目标因变量的含义，充分利用提供的数据细节进行趋势探查。考虑到数据点所具有的特征维度较多，本文着重考虑以下三种角度：

① ABLH 数据在一天内的小气象变化，应按照日期内的小时进行划分
② ABLH 数据在季度之间的大气候变化，应按照月份进行划分；
③ 关联不同的气象数据观测值，同时兼顾其彼此的相关性、随时间的分布特征以及其与大气层高度 ABLH 的共同作用。

前人研究表明，温度、湿度、风速可能会通过热力湍流、机械湍流等因素主导日间 ABLH 变化[5]。在本文中，主要采用**“基于的 XGBoost 决策树的集成学习模型”**进行高维度拟合变换，首先沿用上述三种分析变化规律与关的角度，随后构建树模型来拟合不同气象因素对 ABLH 的影响，同时利用模型深度量化各自变量因子贡献度，进行目标任务的综合考察与分析。

2.2. 对问题二的分析

在问题二中，经过对数据的分析考察，发现一天之内的大气层高度 ABLH 的较强共线性。为了研究 ABLH 对每日空气污染物的影响情况，本文首先考虑利用 PCA 对一天 ABLH 数据的降维，同时考虑到空气污染物的自相关影响，本文利用可以处理多变量时间序列的向量自回归（VAR）模型进行对空气污染物的预测。

在对数据的全年可视化分析中，由于空气污染物具有极强的季节差异性，而传统聚类可能会破坏时间序列的连贯性，在模型建立的过程中，本文选择按照月份对数据进行划分，然后对不同月份的数据分别进行模型参数的求解。随后对模型的参数做因果检验，保证了模型整体的可行性与准确性。

2.3. 对问题三的分析

在问题三中，模型需要根据天气预报的数据对次日的 ABLH 进行预测，天气预报可包括的有次日的温度，湿度，风速，空气污染物等数据，恰好满足前两个模型所使用的核心要素，故选择协同地综合利用前两问构建的模型。值得一提的是，本文为处理对不同模型预测数据的整合问题，采取了贝叶斯信息融合策略。对模型一的化用可以沿用正常的顺序，而在模型二中由于是根据 ABLH 预测空气污染物，所以在本问题中，需要利用空气污染物的预测值对 ABLH 进行反解。

此外，在贝叶斯信息融合中，需要得到不同信息源下模型参数地概率密度分布，为此，本文假设两个模型得到的预测数据对应的概率密度分布均为正态分布，并通过决定系数 R2 与残差平方和的关系，估计正态分布的方差。经过数学推到，从而实现了信息的整体融合，提高了预测的精度与可信度。

3. 模型假设与公式符号

3.1. 模型假设

1、假设模型计算出的预测值与实际值之间的误差是符合正态分布的
2、假设天气预报的数据是准确的，不考虑数据的偏差或极端值对拟合的干扰
3、假设一天之内 24 小时的 ABLH 数据对于第二天的数据预测作用平等

3.2. 公式符号

符号	含义解释
$\mathcal{L}^{(k)}$	XGBoost 模型目标函数
w_j^*	XGBoost 模型节点权重
$\hat{y}_i^{(k)}$	第 k 时间步中 XGBoost 模型的预测值
$Y_{ij}^{(k)}$	第 k 时间步中 VAR 模型的空气质量数据
$PC_1^{(k)}$, $PC_2^{(k)}$	PCA 选取的主成分特征
δ_j^2, δ_{ij}^2	正/逆序列方差
$\hat{\boldsymbol{x}}$	PCA 反解得到的 2 维向量
$\overrightarrow{\boldsymbol{V}_{正}}$, $\overrightarrow{\boldsymbol{V}_{逆}}$	正序列/逆序列
σ_j, η_j	贝叶斯融合后的分布方差与均值

表 1：公式符号摘要

4. 模型一：基于 XGBoost 决策树的集成学习模型

4.1. 数据预处理

在模型建立之前，考虑到现实情境中自然环境数据的复杂性与异变性，我们需要对相关附件中的多维度数据进行分析统计，以确保对数据的理解使用和模型的构建是有效且准确的。

4.1.1. 缺失值检验

经过比对分析，发现两份数据表格中各列数据均不存在缺失值与零值，其日期对应列均按照时间顺序有序排列，间隔均匀，均为 1 小时，此外亦无两行完全重复，不需要进行填充与剔除操作。

4.1.2. 异常值检验处理

	U 向分量风 /m/s	V 向分量风 /m/s	2m 气温/K	表面气压 /Pa	地表温度 /K	潜热通量/ W/(m^2)	感热通量/ W/(m^2)	相对湿度 /%	大气边界层高度/m
Max	9.269867	8.395798	314.6592	103923.625	305.71997	45463	303409	99.9	2234.2793
Average	-0.740459	-0.380057	291.7164	101546.177	291.30296	-243987.5	-76292.02	74.2	507.8824
Min	-8.452133	-8.837631	268.6289	99540.625	268.69653	-1860892	-1108245	23	10.3064

表 2：数据集气象数据的最值汇总

首先本文依据不同数据指标的数值分布，绘制条形图如下，见图 2。由折线图可知，本数据集中各类数据均呈现较好的连续性与集中性，不存在与主体部分脱节的极大或极小值。随后，经过与“国家气象信息中心的”长江三角洲地区气象数据相关数据文件的比对，本文并未发现过于极端的数据值。此外，针对数据列表中的最大、最小值，本文进行初步判断，发现每一项数据的平均值与官方参考值相差不超过 10%，并且极值均处在和合理的范围内。所以，由于同一时间点的数据维度较高，自然环境天气多变，可以认为本实验中不存在差异过大的异常值值干扰。

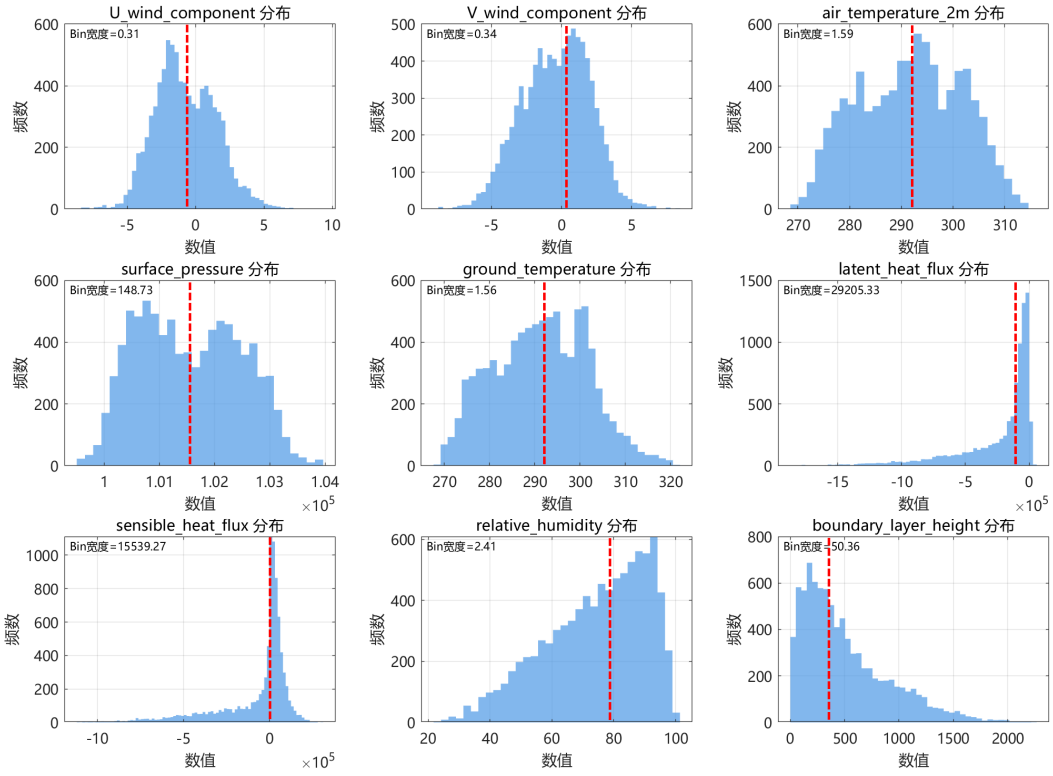


图 2：气象参数频数分布条形图

4.2. 数据结构初步分析

在进行模型分析之前，本文结合相关科学常识与物理学知识，对数据集中涉及到的诸多大气科学的专有名词进行初步的概念阐释与定义，为了加深对模型所面对和解决的问题的理解，同时也有助于后面对机器学习运行结果的解释与认识。

4.2.1. 大气边界层高度日变化分析

大气边界层（Atmospheric Boundary Layer）是地表与自由大气间的湍流活跃层，其高度（ABLH）通常定义为湍流活动显著减弱或消失的垂直位置。在不同假设与不同运用情境下，可以采用不同的方式去对此数值进行拟合估计[6]。其在气象学领域中具有极强的物理意义，可分为如下几方面：

① ABLH 可以表征大气湍流混合能力与垂直扩散效率
② ABLH 可以反映地表能量平衡与大气热力学过程的关键纽带
③ ABLH 是环境评估的核心参数，其动态变化直接影响污染物浓度分布
④ ABLH 的周期性变化揭示地表与大气的在时间驱动下的动态耦合机制

⑤ ABLH 在复杂地形中具有特殊的动力学特性与意义

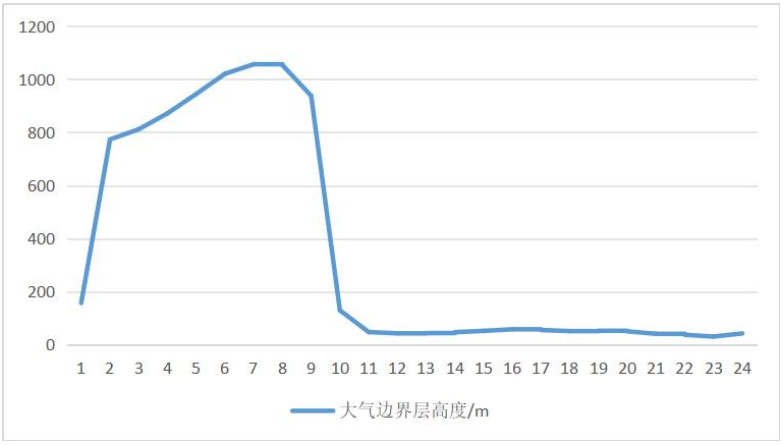


图 3：ABLH 逐小时数值折线图

考虑到本数据集中数据点的可选参考维度较高，需要在同时考虑时间、测量物理量类型、时间季节序列等因素的基础上探讨自变量与因变量的关系。故先选择在时间角度进行降维，按照一年四季的月份划分，在每一个季度 3 个月的时间内，对每一天 24 个小时的数据进行取平均值处理。本文在此呈现出一年四个季度的 ABLH 在每小时内的平均值随一天中时间序列的变化趋势折线图，如图 3。

从整体来看，一年四季边界层高度虽然在变化幅度与绝对数值上存在差异，但其日变化的基本节奏高度一致，均表现出显著的日变化规律，并且可以划分为两个部分进行分析：第一部分为 0—10 小时，在此段内 ABLH 凌晨至清晨缓慢上升，上午（约 6 - 9 时）迅速抬升至峰值，中午前后达到最大值后迅速下降；第二部分为 10—24 时，ABLH 在此时段午后至深夜均保持在较低且稳定的水平。依据 Stull 等人研究推测[7]，这一变化趋势可能主要受到太阳辐射的驱动，地表加热增强湍流混合使得边界层快速增长，而午后太阳辐射减弱、大气稳定性增强，则使边界层高度随之降低。

4.2.2. 大气边界层高度季节分析

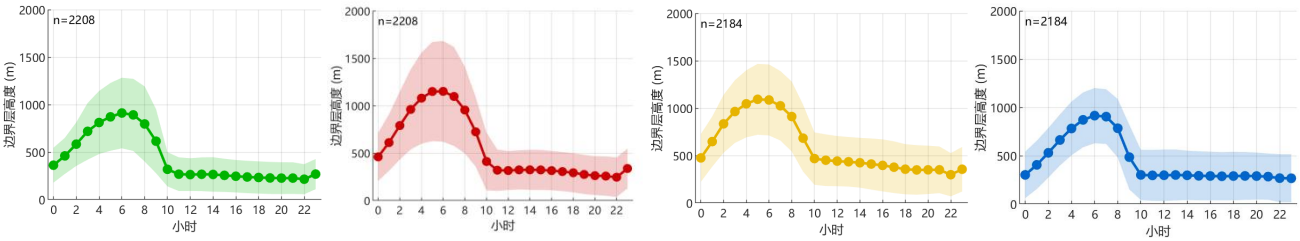


图 4：不同季节中 ABLH 平均值折线图

由图 4 中可知，**经不同季节之间对比分析，ABLH 具有明显的季节性差异性，并且与各季节的基本特点想符合**。其中夏季（红色）边界层高度显著高于其他季节，上午的快速抬升过程更加陡峭，峰值接近 1300 米，表明在强烈日照与干燥空气条件下，垂直混合更为活跃。春秋两季（绿色与黄色）趋势较为接近，峰值在 1100 米左右，边界层的形成与衰减过程较为温和，表现出典型的过渡季节特征。而冬季（蓝色）边界层整体高度最低，日间峰值不足 1000 米，下降速度也最为迅速，反映出冬季地表辐射弱、湍流发展受限[5]，大气更稳定。

4.2.3. 不同气象数据与 ABLH 的作用

类比上文对 ABLH 进行的处理，也对其余数据集中八项数据进行可视化处理，按照横坐标为小时时间、纵坐标为诸多气象学物理量，绘制不同季度类别下的变化，如图 5。

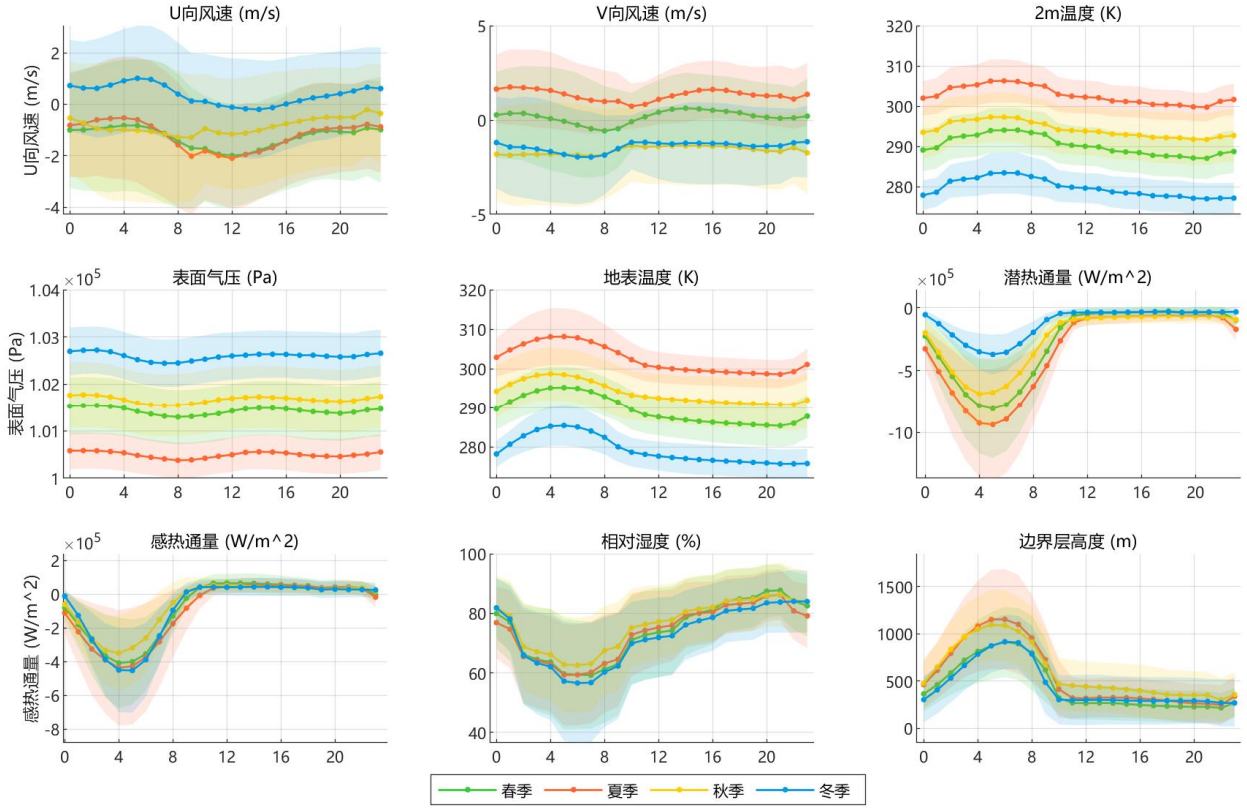


图 5：气象参数逐小时变化季节对比特征

注：上图中折线为相应小时在该季度下的平均值，四条颜色区块则表示相应的取值范围

分析图片中的增减变化趋势与不同时间维度下的数值比对，可以进行如下分析：

1、温度与边界层高度同步性最强

图中地表温度与 2m 温度在深夜 0–10 h 期间同步先攀升后下降，四个季度的温度差异也符合正常规律，其整体的变化趋势与 ABLH 曲线趋势高度重合。这一现象可用 Monin–Obukhov 相似理论[8]解释：地表温度升高产生正的感热通量，使得近地层空气温度剖面变得不稳定（温度随高度减小率超过干绝热率），地表向大气释放更多的感热通量，导致大气热不稳定增强，浮力上升运动更强，进而推动 ABLH 的抬升。温度与 ABLH 的高度同步，说明热力通量是日变化主控因子，具有较强的可解释性，其增量对 ABLH 变化具有一阶贡献，与前人研究成果相符[9]。

2、湿度与 ABLH 呈负相关

相对湿度（RH）在图中清晨时段达到最低，恰与 ABLH 峰值重合；夜间湿度高峰对应 ABLH 最低，表明 RH 每增加 10%可使 ABLH 峰值降低大约 100 m 量级。其物理机制在于高湿条件下，大气稳定度提高：水汽增多伴随潜热释放和气体密度变化，使得环境温度廓线趋于稳定，抑制热力湍动和对流发展；反之，当湿度降低时，干绝热升温率更大，有利产生不稳定剖面并促进湍流。

3、风速与气压对 ABLH 的辅助作用

U,V 分量风速在中午前后虽出现~1 m/s 的增强，但其振幅远小于热力通量变化。气压日内仅在1.01×10^5~1.03×10^5Pa 微幅波动。两者的变化趋势与 ABLH 的变化趋势相似性较小，推测辅助作用较弱。

4、潜热通量与感热通量对边界层高度的耦合影响

图中感热通量（H）和潜热通量（LE）均表现出明显的日变化规律，约在 6–9 时快速上升，正午前后趋于稳定，夜晚时逐渐回落。其中，H 在春夏秋季中午呈正值，说明地表向大气输送热量，冬季则整体偏弱，甚至为负，表明热通量抑制边界层发展；而 LE 在清晨前后均为负值，日间接近零或略为正值，夏季负值最大，表明蒸发和潜热交换较强。ABLH 与 H 的变化趋势有较强的负相关性，均呈现出较强的的单峰特征。相比之下，LE 的变化与 ABLH 的相关性较弱。

4.3. XGBoost 机器学习拟合算法

4.3.1. 模型特点优势

XGBoost 是一种由很多的 CART 分类回归树构成的 Boosting 集成学习算法模型，既可以用来进行分类的任务，也可以用来进行连续性目标变量预测的任务。在此本文选用之来构建基于回归树的模型，主要原因在于其有以下三点优势。

① XGBoost 相对多元回归，具有**较强的非线性关系**。在此情境中由于需要解释客观复杂的物理量之间的耦合作用关系，利用此模型不需要手动构造多项式或者交互项来对复杂作用关系进行拟合；

② XGBoost 可以通过树的分裂过程自动学习变量之间的交互作用，输出特征重要性排序，**直观显示不同变量对于 ABLH 的贡献度**。在此情境中适合用来对多变量的关系进行量化处理，只管评估影响；

③ XGBoost 相对多元回归，**对异常值不那么敏感**，内置了正则化与交叉检验可以处理噪声的破坏。在此情境中由于环境数据的不确定性较大，高维数据的特征较复杂，本模型可以尽可能避免错误拟合了数据特征。

4.3.2. 模型实现流程

XGBoost 的核心思想在于：通过不断地不断进行特征分裂来添加树结构，通过不断学习一个新函数来拟合上次预测的残差，使得回归不断优化。由此延伸，对于k棵决策树中样本对应的权重，求和即为所求的预测值。在此将其核心实现步骤进行呈现：

Step 1：数据与模型准备

再进行模型实现之前，需要先对各组数据进行$z-socre$标准化，将数据转换为均值为 0、标准差为 1 的标准正态分布，便于不同数据集间的比较与分析。而后需要划分训练集与测试集，并设定模型的相关超参数，包括树的最大数量、树的最大深度、学习率、正则化项系数等等，用来平衡调控模型的复杂度及拟合精度。

Step 2：样本输入与残差准备

在此，由于本模型需要对整体的的泛函进行优化，故需要先定义目标函数，如下所示，用来衡量树的的综合拟合效果：

$$\mathcal{L}^{(k)}=\sum_{i=1}^{n} l\left(y_i,\hat{y}_i^{(k)}\right)+\Omega\left(f_k\right)$$

该函数前半部分为损失函数项（用来揭示训练误差），后半部分为正则化项（用来惩罚复杂模型）。正则化项值越小复杂度越低，泛化能力越强，表达式为：

$$\Omega(f)=\gamma T+\frac{1}{2}\lambda\sum_{j=1}^{T} w_j^2$$

上式中γ和λ为模型超参数，T为叶子结点的数量，前一项用来控制节点的分裂，w_j为第j个叶子的权重，后一项通过对权重进行 L2 正则化，使得目标函数更倾向于选择权重较小的模型，有利于简化和泛化。

此时输入第一轮样本后，模型会开始进行迭代拟合。在每轮迭代中，根据前一轮的预测结果，计算并记录每个样本的如下两个重要判决量，后续将作用于树的分裂过程：

- 一阶导数 $g_i=\partial\mathcal{L}^{(k)}\big/\partial\hat{y}_i$，表示梯度，即为房钱预测误差的方向
- 二阶导数 $h_i=\partial^2\mathcal{L}^{(k)}\big/\partial\hat{y}_i^{\,2}$，表示 Hessian 矩阵，即损失函数在此处的曲率

Step 3：分裂候选并寻找最优切分

基于上一步骤生成的决策树，对样本的每一种特征枚举其所有的可能切分点，将每种可能切分之后的的结果划分为“左子节点”和“右子节点”。对每一种切分尝试，计算“是否执行此操作”带来的目标函数增益（Gain）：

$$Gain=\frac{1}{2}\left[\frac{G_L^2}{H_L+\lambda}+\frac{G_R^2}{H_R+\lambda}-\frac{\left(G_L+G_R\right)^2}{H_L+H_R+\lambda}\right]-\gamma$$

其中G_L,H_L表示左子集的梯度和 Hessian 二阶导之和，G_R,H_R表示右子集的梯度和 Hessian 之和，λ为 L2 正则化项，γ为最小分裂增益阈值（用来控制剪枝）。

将模型的数据带入上述增益 Gain 计算，在所有特征的左右切分点中找到增益最大的分裂点，若该分裂点的 Gain 小于阈值γ，则不再进行分裂，可以认为构造完成决策树。重复 **Step 2** 和 **Step 3** 过程递归构建左右子树，直到达到最大深度，或增益小于最小阈值，或节点样本数小于设定值。

Step 4：确定叶片权重与模型学习

当树结构固定之后，模型会利用目标函数最小化的原则，为每一片叶子节赋予合适的权重大小，其原理主要是进行二阶的 Taylor 展开操作，通过求导方法得到相应的w_j^*，其简要过程呈现如下：

$$\begin{aligned}\mathcal{L}^{(k)}&=\sum_{i=1}^{n} l\left(y_i,\hat{y}_i^{(k-1)}+f_k(x_i)\right)+\gamma T+\frac{1}{2}\lambda\sum_{j=1}^{T} w_j^2\\&\simeq\sum_{j=1}^{n}\left[G_j w_j+\frac{1}{2}(H_j+\lambda)w_j^2\right]+\gamma T\end{aligned}$$

其中G_j,H_j的定义同上，在此通过结构函数将投入的数据变量映射到某个特定索引号的叶子节点上去。经过求导可以得到相应的权重：

$$w_j^*=-\frac{G_j}{H_j+\lambda},\ \text{此时}\ \mathcal{L}^{(k)}=-\frac{1}{2}\sum_{j=1}^{T}\frac{G_j^2}{H_j+\lambda}+\gamma T$$

此时前的树结构固定后，对于投入样本的总体预测值将更新为$\hat{y}_i^{(k)} = \hat{y}_i^{(k-1)} + \eta f_k(x_i)$，故最后将森林中$k$棵树所得到的预测值按照学习率权重相加即可得到最终的样本预测值。

4.3.3. 斯皮尔曼相关系数分析

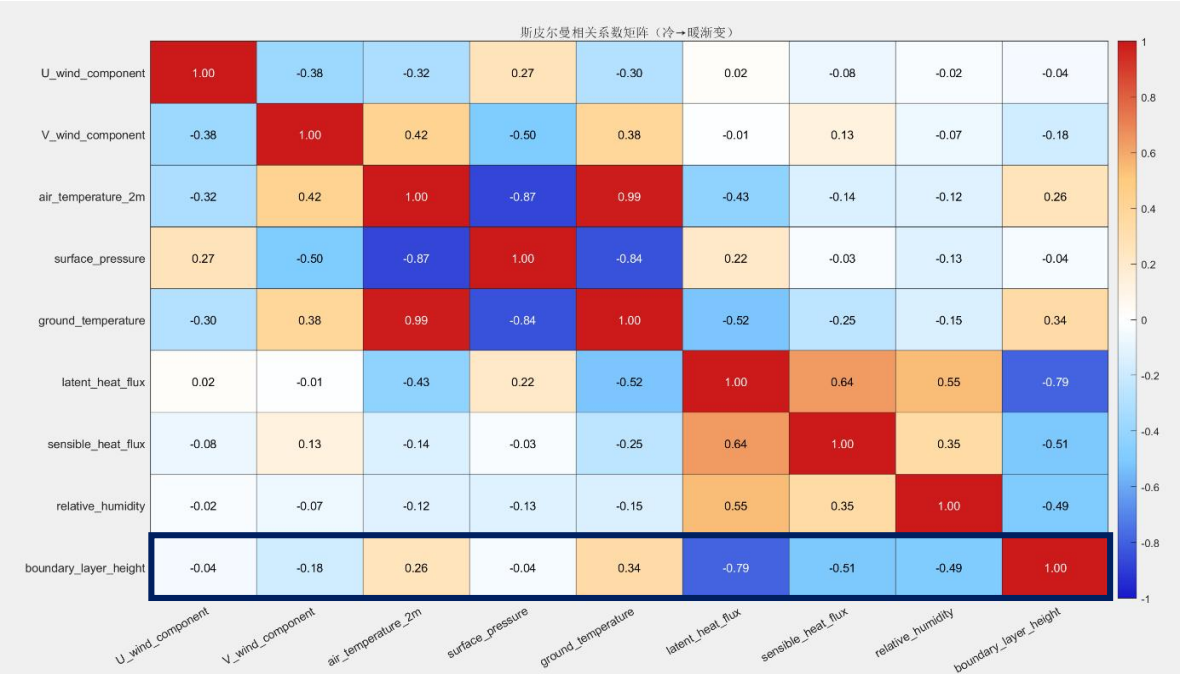


图 6：斯皮尔曼相关系数热力图

再投入数据到 XGBoost 模型之前，本文先通过相关性分析来探究指标之间的关系，对气象指标间的相关性做初步判断，同时也依据此分析是否出现严重的内生性问题。通过计算 Spearman 相关系数得到相关系数矩阵，如图 6。在此主要关注最后一行（最后一列）的内容，即诸多气象因素与大气层高度 ABLH 的关系。由图可知地表温度以及 2m 处气温对 ABLH 有较强的正相关性，而潜热通量 LE、感热通量 H 与相对湿度 RE 对 ABLH 具有较强的负相关作用，尤其以潜热通量为主，这一现象与前文可视化结果保持一致。

4.3.3. XGBoost 操作实现

1、参数设定

本文对于模型的参数进行了优化设置：最多 100 棵决策树，每棵树的最大深度限制为 5 层以防止过拟合，以及泛化能力较差的问题；学习率设为 0.1 以确保模型稳定收敛；采用 0.8 的样本采样比例来增强模型的泛化能力。以均方误差作为优化目标，并固定随机种子以保证实验可重复性。

2、结果呈现

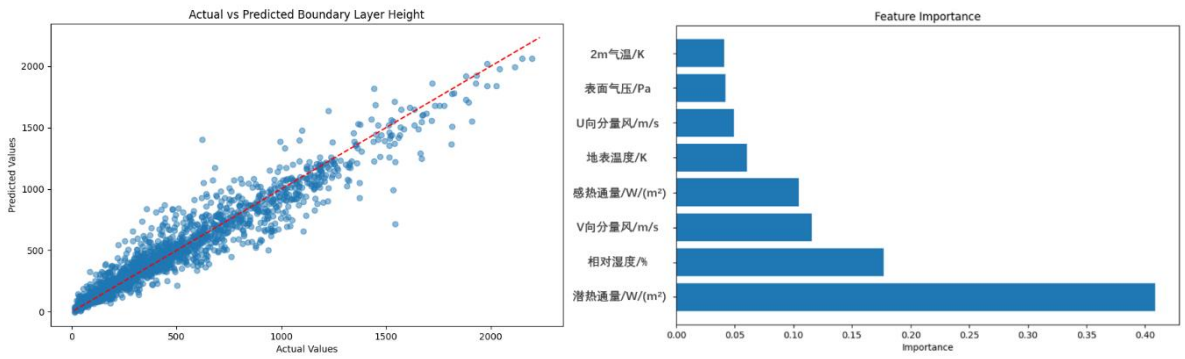


图 7：ABLH 预测值与实际值关系（左）不同特征分量的影响权重（右）

对于图 7，观察显示，数据点在 0-1000 米范围内紧密贴合 1:1 线，表明模型在低高度时预测高度准确，误差较小。然而，在 1000 米以上，数据点出现一定分散，偏离 1:1 线，提示模型在较高 ABLH 值时可能存在欠预测或过预测的现象。这表明 XGBoost 模型在常规条件下表现优异，在极端高 ABLH 场景下准确性可能略有下降。而对于不同的气象特征，其重要性占比如下表 3。

	潜热通量	相对湿度	V 向分量风	感热通量	地表温度	U 向分量风	表面气压	2m 气温
Feature Importance	0.4088	0.1773	0.1159	0.1048	0.0605	0.0493	0.0424	0.0410

表 3：不同气象特征的重要性占比

上表中的 Feature Importance 可以用来衡量一个变量在整体树模型中的贡献率，其数值定义为**该特征在所有树中作为分裂节点的总次数**。分析可知，其中，2m 气温以 0.4088 的得分遥遥领先，是影响 ABLH 预测的最重要特征，表明温度对边界层高度的决定性作用，此结果与 Stull 等人的研究成果“温度具有 40%左右的解释性”一致[7]。表面气压以 0.1773 位居第二，显示气压变化对 ABLH 的显著影响。其余特征如风速分量、地表温度和感热通量也有一定贡献，但重要性较低，而潜热通量得分仅 0.0410，影响最小。这一结果与气象学中温度和气压驱动边界层发展的物理机制一致，亦与上文中图【】呈现出的 Spearman 相关系数中的内容同步。

5. 模型二：基于 VAR 的向量自回归模型

5.1. 污染物数据分析处理

5.1.1. AQI 指数检验处理

AQI（空气质量指数）为区域内空气质量即空气污染水平的衡量值，其数值计算基于多种污染物的浓度，采用分段线性插值法分别计算各污染物的 AQI 值，最终取最大值作为当天的 AQI 指数。对于每种污染物，其 IAQI 的计算值如下：

$$AQI_i = \frac{I_{\text{high}} - I_{\text{low}}}{C_{\text{high}} - C_{\text{low}}} \times (C - C_{\text{low}}) + I_{\text{low}}$$

其中：C 表示污染物的实测浓度，C_{low}和C_{high}为污染物所在区间的浓度上下限，I_{low}和I_{high}为对应的 AQI 区间的上限和下限。

在本文中对所给附件 2 中空气质量数据进行了校验与核查，首先查阅国家标准获得各污染物的浓度对应的 AQI 区间，取 24 小时平均值而非 1 小时平均值，核对的物理量的平均值后，代入上述公式计算得到 AQI_i 值。将五项最大值与所给的 AQI 进行比对，发现存在一定的偏差。考虑到 AQI 的计算臭氧（O_3）也要纳入考察范围而未提供相关数据，并且题目要求中将 AQI 与细分的污染物并列作为因变量，来探求量化关系。故本文中采用的处理是将 AQI 与 $PM_{2.5}$、PM_{10}、NO_2 等细分污染物并列在处理，暂时忽略其间的相关性关系。

5.1.2. PCA 主成分分析处理

首先，考虑到第二个问题中做处理的因变量数据均以天为最小时间单位，而进行量

化关系分析的 ABLH 则以小时为最小时间单位，故在此需要以一天的 24 个 ABLH 值为整体，对六个不同的因变量进行线性回归分析。在删除 2025 年 1 月份的数据之后，考虑到高维数据可能会带来多重共线性、过拟合以及计算复杂度高等问题，在此选择采用主成分分析（PCA）进行降维处理。相较于直接对着 24 个值进行均值，PCA 可以尽可能避免对时间序列动态特征的损失。如图 3 中所示，ABLH 在一天范围内具有较强的规律特征，如果直接去平均值或是类似简洁操作，会导致数据的特征损失较严重，不利于后续的拟合处理。

故在此需要计算数据集两两变量之间的协方差矩阵$\boldsymbol{R}=(r_{jk})_{n\times n}$，其中$r_{jk}$为第 j 个评价指标与第 k 个评价指标的协方差：

$$r_{jk}=\frac{1}{n-1}\sum_{i=1}^{n}\frac{(x_{ij}-\bar{x}_j)^2\cdot(x_{ik}-\bar{x}_k)^2}{s_j\cdot s_k}$$

然后求出相关系数矩阵的 n 个特征根与特征向量，确定主成分的个数，由特征方程式可以求解得到n个特征值，从大到小进行顺序排列：

$$|\lambda\boldsymbol{I}_n-\boldsymbol{R}|=0$$

$$\lambda_1\geqslant\lambda_2\geqslant\cdots\geqslant\lambda_n\geqslant 0$$

其中特征根的大小描述了每个主成分在评价中所起作用的大小。每一个特征根对应一个特征向量，记为$\boldsymbol{u}_1,\boldsymbol{u}_2,...,\boldsymbol{u}_n$，求得各主成分为：

$$z_{ij}=\boldsymbol{u}_j^T\boldsymbol{x}_i,\ \boldsymbol{x}_i=(x_{i1},x_{i2},...,x_{in})^T$$

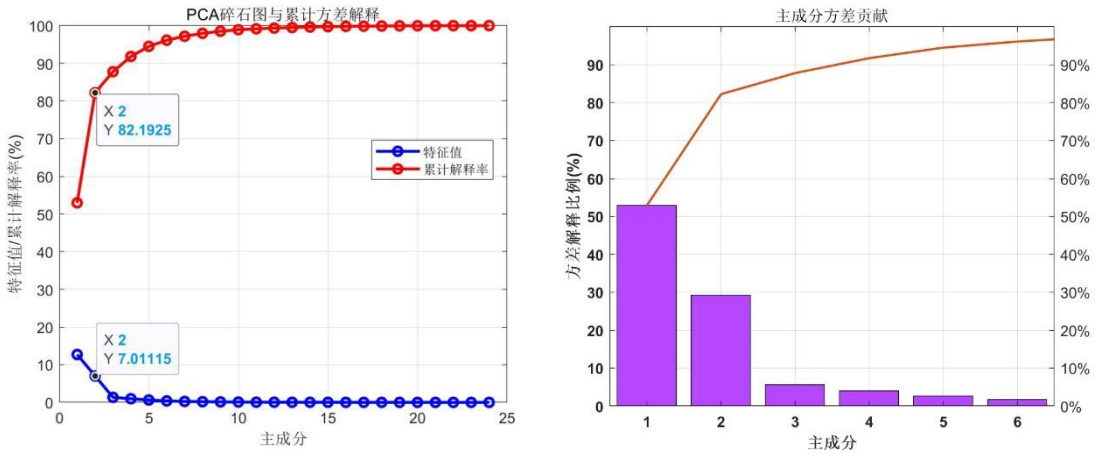


图 8：PCA 碎石图（左）以及主成分方差贡献图（右）

提取的主成分特征根应大于所有主成分特征根的平均值，在此由于进行了标准化处理。分析上图可知，当 X≤2 时相应的特征值已经均满足解释率大于 80%的条件，故选取前两个维度作为核心主成分解释值来代表。此外，在此还呈现一张 PCA 特征特征值对应的特征向量热力图，如图 9。

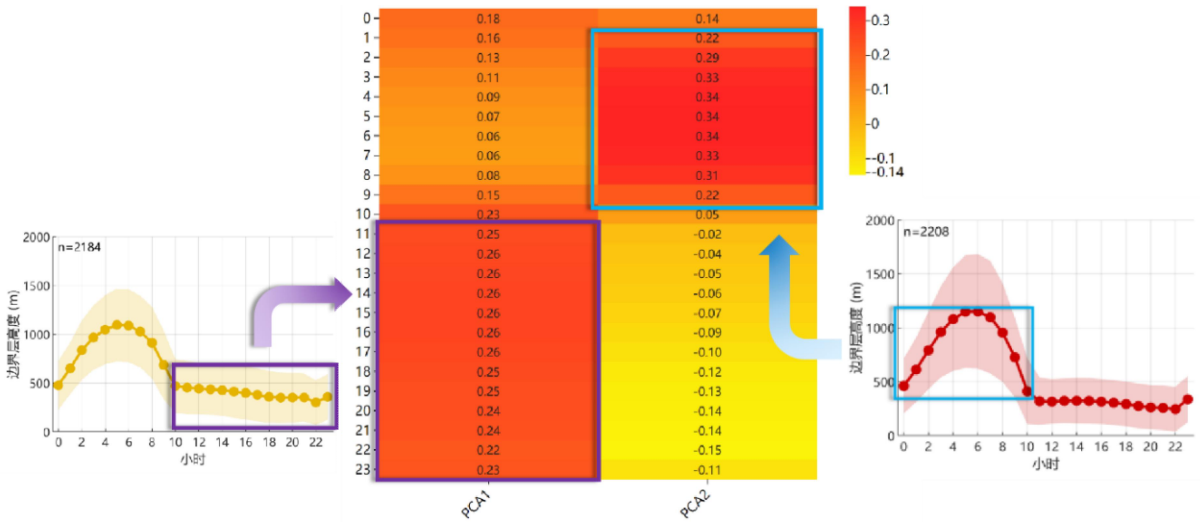


图 9：主成分特征向量热力图

上述热力图展示了 PCA1 和 PCA2 对应的特征向量分量值（-0.14 至 0.34），反映流量数据的主成分模式。PCA2 高值特征（如第 4—8 列，值 0.34 左右）对应左右图 0-8 小时高度激增（最高可达 1500m），其特征值的峰值前后分量的变化趋势与折线图趋势相似。PCA2 的阶段稳定特征（如第 12-20 行，值 0.26 左右）对应左右图 12-20 小时大气层高度基本稳定（500m 至 400m）。PCA1 和 PCA2 和原数序列在阶段划分节点上一致性较强，前者主要反映的是第二阶段的平稳特征，后者主要反映的第一阶段的波动特征，共通作用体现了特征向量对动态数据的解释力。

5.2. 自回归模型构建

5.2.1. 时间序列概述

在时间序列分析中，向量自回归（VAR）模型作为一种多变量动态建模工具，因其能够有效捕捉变量间的交互作用而备受关注。VAR 模型通过将每个内生变量表示为自身及其他变量滞后项的线性组合，突破了传统单变量模型的局限性，尤其适用于金融学、气象学等含有多变量系统的领域的动态分析。其核心特点有以下四点：

① **自回归结构**：变量的当前值由其自身的滞后值和其他变量的滞后值共同解释，本研究中的气象数据并不会出现一直增长或一直下降的异常情况；

② **无约束性**：不施加气象理论上的先验约束，让数据自身决定变量之间的关系，本研究为探究性实验，并非对相关结论进行佐证；

③ **滞后阶数**：模型需要选择特定的滞后结束，可一通过相应的信息准则来确定，在本研究中可以依据实际情况动态调整，加科学合理；

在本研究中，已知的可作为自变量的数据有：① 当日及之前若干天的大气层高度（ABLH）数据，经过前文 PCA 压缩后由 24 维变成 2 维；② 当日之前若干天的六项空气质量指标。这两类数据均暗含了时间序列的属性，**本模型的核心任务与目标即是依据这两组时间序列的诸多数据，来推导预测当日的六种空气质量指标数值，分析并给出 ABLH 与空气质量相关指标的量化关系。**下面将以 1 月份的数据为例，阐述模型的整

体实现过程。

5.2.2. 确定类型划分

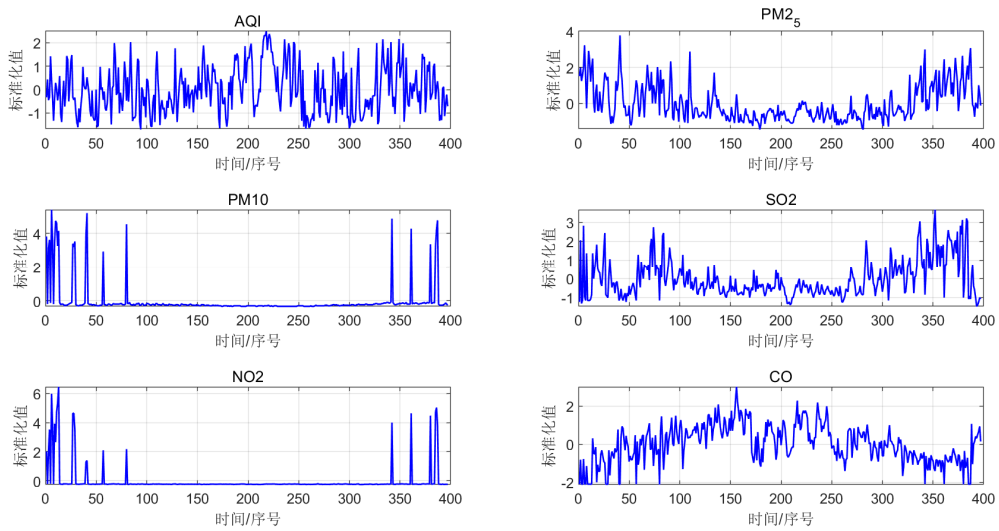


图 10：空气质量指标年度变化趋势图

在图 10 中本文对附件二中的数据进行了时间序列下的可视化呈现，发现数据在不同时间段内呈现极为明显的差异性，又考虑到 ABLH 在一年的阶段内的变化特征同样过于复杂，如果直接以一年的为整体进行拟合推断，会因为特征损失过多导致拟合效果很差，拟合优度值较小，经过实践尝试，在将全年的 AQI 直接代入后文中阐述的模型，其拟合优度R^2只有 0.3 左右。故又选择聚类的方法试图进行类似季节性的分类处理，但是发现会存在日期间隔不一致导致的时间序列失真现象。故最终选择依照每个月份进行分类拟合处理，故一共划分为 12 个类，分别进行后续模型的实现。

5.2.3. 确定滞后阶数p

确定 VAR 模型的滞后阶数有很多种方法，在此由于数据样本较小（仅有一年的数据），不便于采用“似然比检验法”，故选择使用“信息准则法”这一更具均衡性与普适性的方法，此方法会关注 AIC、HQIC、SBIC、FPE 四种准则，通过平衡模型的拟合优度与简洁性来确定最优的滞后阶数。在此呈现其理论公式：

$$AIC(p)=\ln|\widehat{\sum}^{p}|+\frac{2}{T}\times(k^2p)$$

$$\mathrm{HQIC}(p)=\ln|\widehat{\sum}^{p}|+\frac{2\ln(\ln(T))}{T}\times(k^2p)$$

$$\mathrm{SBIC}(p)=\ln|\widehat{\sum}^{p}|+\frac{\ln(T)}{T}\times(k^2p)$$

$$\mathrm{FPE}(p)=\left(\frac{T+kp+1}{T-kp-1}\right)^{k}\times|\widehat{\sum}^{p}|$$

其中：k 表示变量个数，p 表示滞后阶数，T 表示样本量。上述不同判断指标各有倾向，AIC 倾向于选择较大的滞后阶数（惩罚项较小），适用于预测但对小样本可能会过拟合；HQIC 惩罚项介于 AIC 与 BIC 之间，适用于中等样本量的数据；SBIC 的惩罚项最强，倾向于选择较小的滞后阶数，适用于大样本，可抑制过拟合；FPE 主要基于回归误差，适用于预测任务。

在本文中，由于模型目标是希望能够尽可能提高拟合精度，故可以适当放宽松对于模型复杂度的要求，所以在不同的拟合方程中，**均取上述四种准则之中的数据最小值所对应的阶数**，作为最终该条件下的实际阶数，所以对于上述 12 个类型分别确定 12 个阶数，在此仅将将滞后阶数呈现如下，见表 4：

	1 月	2 月	3 月	4 月	5 月	6 月
滞后阶数	4	4	4	3	4	4
	7 月	8 月	9 月	10 月	11 月	12 月
滞后阶数	4	4	4	4	4	3

表 4：不同月份的滞后阶数标注

5.2.4. 数据平滑处理

在本模型中出于对时间序列处理的基本假设，客观物理指标不会再时间很短的范围内有相对极大地突变，所以需要对随时间变化的序列进行平滑性检验。在此采取主流的 AFD 平滑性检验。其核心思想是通过评估数据的频域特性或局部波动性来判断其平滑程度。原假设 H_0 认为信号是平滑的($R \leqslant \delta$)，备择假设 H_1 则认为信号不平滑的($R > \delta$)。当计算得到的高频能量占比 R 值超过阈值时，就可以在给定的显著性水平下拒绝原假设，判定信号具有显著的非平滑特征。

对于序列检验通过的月份，则直接进行后续操作，对未通过的月份，则进行平滑性处理，以 1 月为例，得到统计量 $Z(t)$ 取值为 0.1425，小于 0.05，即原假设不成立。故将自变量与因变量均替换成差分的形式，即以 $d(PC_1^{(t)})$ 和 $d(PC_2^{(t)})$ 作为自变量，而以 $d(Y_{ij}^{(t)}) = Y_{ij}^{(t)} - Y_{ij}^{(t-1)}$ 作为因变量，通过类似“降次”的方式以增强序列的平滑性。

	1 月	2 月	3 月	4 月	5 月	6 月
是否平滑处理	是	是	否	否	是	是
	7 月	8 月	9 月	10 月	11 月	12 月
是否平滑处理	是	是	否	是	是	否

表 5：不同月份的平滑性处理标注

5.2.5. 模型核心表达式

基于上文中谈到的传统 VAR 模型代数式，以及聚类分析后的结果，构建如下一组

代数表达式：

$$Y_{ij}^{(t)}=[{}^1a_{ij}\ \ {}^2a_{ij}\ \ {}^3a_{ij}]\begin{bmatrix}Y_{ij}^{(t-1)}\\PC_1^{(t)}\\PC_2^{(t)}\end{bmatrix}+[{}^1b_{ij}\ \ {}^2b_{ij}\ \ {}^3b_{ij}]\begin{bmatrix}Y_{ij}^{(t-2)}\\PC_1^{(t-1)}\\PC_2^{(t-1)}\end{bmatrix}+\cdots+\varepsilon_{ij}$$

$$i\in[1,N],j\in[1,6],\text{ 上式的项数由滞后阶数}p\text{ 决定}$$

其中变量与上下标有如下含义：

1、$Y_{ij}^{(t)}$表示第t个时间步中的污染物指标，下标从j从 1 到 6 表示六种污染指标；

2、$PC_1^{(t-1)},PC_2^{(t-1)}$表示利用 PCA 压缩出的两项 ABLH 特征在$t-1$时间步的值；

3、a,b表示拟合表达式中的权重，不同列示中不相同；

4、ε_{ij}表示等式末尾的偏置项；

5、N为类型数量，在本实验中暂时取 12，即按照月份进行分类处理；

故结合以上信息，可以得到 12 个类型，每类 6 个等式，一共 72 个等式，每一个等式中的$Y_{ij}^{(t)}$均由前若干个时间步中的污染物指标与之对应（滞后阶数由“信息准则法”确定），同时还受到当前以及前一个时间步中 ABLH 的 2 维主成分的影响，充分利用了关联性较强的空气质量以及自变量 ABLH 数据，符合时间序列的处理需求。随后对每个式子分别进行拟合与回归处理。

在此同样以 1 月为例进行阐述，分析上述表达式可知，对于同一类型的 PC_1 或 PC_2 数据，由于滞后阶数取 4，故应存在$2\times4=8$个系数，在此呈现如下表：

	第一项	第二项	第三项	第四项
PC1 系数	-4.8217	-1.9869	1.1924	-2.1916
PC2 系数	-16.9756	-7.3822	6.8545	4.1781
AQI 自相关系数	-0.4764	-0.3745	-0.0970	0.3512

表 6：1 月份模型系数呈现

表 6 中第三行为因变量时间序列的自相关系数，可以判断拟合模型的残差是否已为白噪声，其四项p值均满足了显著性，趋近于 0，可以认为模型较充分地提取出了数据的时间序列特征。同样有上表中两主成分系数可知，**ABLH 与 AQI 污染指数大体长呈现负相关的趋势**，即当大气层高度越高，空气中污染物分子的扩散作用越强，相对的污染指数也就会下降。在拟合方程确定之后，本文还对方程进行 Granger 因果检验，其目的是判断一个时间序列变量（X）是否对另一个变量（Y）具有预测能力，X 的滞后项必须对 Y 的当前值有统计显著性贡献。当以dAQI 为因变量时，其余的自变量 p 值分别为 0.008 与 0.001，均具有显著性，说明拟合到位。

5.2.6. 模型整体拟合效果

为衡量模型对整体数据的拟合效果，在此将 12 个月份的拟合优度R^2呈现如下，其数值越大越靠近 1 说明模型的拟合效果越好：

	1 月	2 月	3 月	4 月	5 月	6 月
拟合优度R^2	0.7516	0.6612	0.6350	0.4663	0.7527	0.5713
	7 月	8 月	9 月	10 月	11 月	12 月
拟合优度R^2	0.3665	0.4391	0.6539	0.7153	0.6580	0.4538

表 7：各月份 VAR 模型拟合优度

分析表 7 中数据可知，本模型在不同月份中的拟合优度值最高为 0.7527（5 月），最低为 0.3665（7 月），**平均水平约 0.57**，表明模型整体拟合效果中等偏上。考虑到自然环境下的诸多耦合关系影响复杂，以及测量设备方法可能产生的误差，使得数据的规律性特征较难以提取，本模型的**拟合系数已达到较高水平。**

5.3. 自回归模型总结

本研究通过构建基于 VAR 的向量自回归模型，深入分析了大气层高度（ABLH）与空气质量指标之间的量化关系，展现了时间序列分析在环境数据建模中的应用价值。针对空气质量指标（AQI 及细分污染物）的复杂特性，研究采用按月份分类的策略，将先前时间步的数据引入

从整体表现看，模型拟合效果呈现出一定的波动性，但整体上表现出较强的解释力，某些月份可能会受到数据特征复杂性或外部环境耦合效应的限制。研究通过主成分特征向量的分析，揭示了 ABLH 变化模式与空气质量指标的阶段性关联，为理解污染物浓度变化的驱动因素提供了新视角。创新性上，模型突破了传统单变量分析的局限，充分利用时间维度上的连续性关系，对环境的适应性较强，为空气质量预测和环境管理提供了更可靠的理论支持。

6. 模型三：基于贝叶斯估计的正态序列融合模型

6.1. 目标分析

由题目可知，本模型需要处理的主要任务是由天气预报数据来预测次日的 ABLH 值，由前文提及的模型假设可知，本模型假设已知如下三类数据：

1、次日、当日以及先前除 ABLH 所有的气象观测数据（每小时）

2、次日、当日以及先前的六项污染物数据（每天）

3、当日以及先前的所有的 ABLH 数据（每小时）

由于本模型已知的数据条件与前两个模型所利用的原始数据重合度较高，故选择调用前两个模型的核心理念与公式推导，即包括：首先利用模型一正向推导得到次日的 24 小时 ABLH 数据，在此可视为第一个 24 维序列数据；其次利用模型二的矩阵线性关系，反解出次日相应的 2 维 ABLH 数据；最后利用 PCA 的逆过程将 2 维样本对应回到原先 24 维的 ABLH 数据，是为第二个序列数据。故在此需要选用一种方法将两组时间序列进行融合，本模型在此选用的是基于贝叶斯估计的正态序列参数融合方法，详细过程见下。

6.2. 正向序列处理

本文依据模型一的结论进行数据处理，将次日的诸多天气预报数据代入模型一，可以**得到第一组 24 维度的 ABLH 数据，称之为“正序列$\overrightarrow{V_{正}}$”**，假设其拟合优度为R_1^2。在此，本模型利用假设条件“预测误差满足正态分布$\varepsilon \sim N(0,\ \delta^2)$”，则由拟合优度的定义关系：

$$R_1^2 = 1 - \frac{SSE}{SST},\ \textbf{a.k.a.}\ \delta^2 = \frac{SSE}{n} = \frac{(1-R_1^2)SST}{n}$$

其中 n 为样本个数，在此可去 8787，SST 为总平方和，SSE 为残差平方和：

$$SST = \sum_{i=1}^{n}(y_i - \bar{y})^2,\ SSE = \sum_{i=1}^{n}(\hat{y}_i - y_i)^2$$

δ^2为预测误差呈现的正态分布的方差，可以由 SSE 推导得到：

$$\delta^2 = \sum_{i=1}^{n}(\hat{y}_i - y_i - 0)^2 \Big/ n$$

6.3. 反向序列处理

1、模型二的反解

当我们进行模型二的推导时，是指是利用全序列的 ABLH 与前日的 AQI 来推导当日的 AQI，故在模型三条件下，已知前日的 ABLH 与全序列的 AQI，在每一个分类之中（每一月份内）皆有 6 个方程、2 个未知数，采用最小二乘法一定可以反解得到相应的 2 维 ABLH 序列。

在此先假设模型二的复杂方程组可以等价为一下矩阵式相乘，即只把两个 2 维的主成分视为自变量：

$$\boldsymbol{Ax} + \boldsymbol{\epsilon} = \boldsymbol{b}, \textbf{a.k.a.} \begin{bmatrix} w_{11}^i & w_{12}^i \\ w_{21}^i & w_{22}^i \\ \vdots & \vdots \\ w_{61}^i & w_{62}^i \end{bmatrix} \cdot \begin{bmatrix} PC_1^{(t)} \\ PC_2^{(t)} \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_6 \end{bmatrix} = \begin{bmatrix} Y_{i1}^{(t)} + C_1 \\ Y_{i2}^{(t)} + C_2 \\ \vdots \\ Y_{i6}^{(t)} + C_6 \end{bmatrix}$$

其中w_{11}^i表示第 i 个月份，主成分$PC_1^{(t)}$在第 t 个时间步上的权重系数，$\boldsymbol{\epsilon}$为误差项。

由于实际情况复杂，基本可以假设权重矩阵是列满秩的，即$\boldsymbol{A}^T\cdot\boldsymbol{A}$是可逆的。本模型采用**最小二乘法求解**相应的$PC_1^{(t)}$和$PC_2^{(t)}$，即找到目标$\boldsymbol{x}$使得残差平方和最小，即$\hat{\boldsymbol{x}}=\arg\min_{\boldsymbol{x}}||\boldsymbol{b}-\boldsymbol{A}\cdot\boldsymbol{x}||^2$，利用矩阵求导方法可以得到目标的$\hat{\boldsymbol{x}}$：

$$\hat{\boldsymbol{x}}=(\boldsymbol{A}^T\cdot\boldsymbol{A})^{-1}\boldsymbol{A}^T\boldsymbol{b}=\begin{bmatrix}\widehat{PC_1^{(t)}}\\ \widehat{PC_2^{(t)}}\end{bmatrix}$$

由此，即可得到模型二 PCA 处理之后的二维主成分向量，随后，为了与前文正向序列进行维度与时间步匹配，**进行 PCA 的逆过程反推出对应的原始 24 维度的 ABLH 数据**。由模型二可知：

$$\overrightarrow{\boldsymbol{V}_{逆}}=\widehat{PC_1^{(t)}}\cdot\vec{\boldsymbol{x}}_1+\widehat{PC_2^{(t)}}\cdot\vec{\boldsymbol{x}}_1$$

其中，$\vec{\boldsymbol{x}}_1$和$\vec{\boldsymbol{x}}_2$分别为两个主成分对应的特征向量，由特征值分解的定义可知进行逆过程后即得到了一个 24 维度的 ABLH 向量，称之为**“逆序列$\overrightarrow{\boldsymbol{V}_{逆}}$”**

6.4. 参数融合过程

综合前述过程，此刻需要将“正序列”和“逆序列”进行融合，本模型在此采取了“基于贝叶斯估计的正态序列参数融合”方法。具体步骤如下：

Step 1：正序列标准差计算

首先考察正序列，沿用先前对于残差的正态分布假设，我们可以延伸至 24 维 ABLH 数据，即每一个维度数据均可以认为处在各自正态分布的概率分布最高点，于是其残差的标准差δ也是正序列每项数据的标准差。由于是由同一个拟合方程的拟合优度R^2计算得到，故这 24 个标准差相等：

$$\overrightarrow{\boldsymbol{V}_{正}}=\begin{bmatrix}\mu_1\\ \mu_2\\ \vdots\\ \mu_{24}\end{bmatrix}，\text{其标准差向量为 }\vec{\boldsymbol{\delta}}=\begin{pmatrix}\delta\\ \delta\\ \vdots\\ \delta\end{pmatrix}$$

Step 2：逆序列标准差计算

其次对于逆序列，由于模型二中对于 6 项空气质量数据$Y_{ij}^{(k)}$分别进行了拟合，共得到六项拟合优度$R_1^2\sim R_6^2$，故相应可以计算得到六项标准差$\delta_1\sim\delta_6$（方差$\delta_1^2\sim\delta_6^2$）。后续由于经历了 PCA 的逆过程，24 维逆序列标准差的计算过程体现如下：

$$\delta_i\cdot\vec{\boldsymbol{x}}_1+\delta_i\cdot\vec{\boldsymbol{x}}_2=\vec{\boldsymbol{\delta}}_i',\ i\in\{1,2,3,4,5,6\}$$

$$\vec{\boldsymbol{\delta}}_i=\vec{\boldsymbol{\delta}}_i'\Big/\sqrt{82.1925\%}=\begin{pmatrix}\delta_{i1}\\ \delta_{i2}\\ \vdots\\ \delta_{i24}\end{pmatrix},\ \overrightarrow{\boldsymbol{V}_{正}}=\begin{bmatrix}\nu_1\\ \nu_2\\ \vdots\\ \nu_{24}\end{bmatrix}$$

其中$\vec{\boldsymbol{x}}_1$和$\vec{\boldsymbol{x}}_2$分别为两个主成分对应的特征向量，$\vec{\boldsymbol{\delta}}_i'$为逆序列的伪标准差（24 维），由于前两个主成分的方差累计贡献率为 82.1925%，将其开根后即可用于构造逆序列的真实标准差向量$\vec{\boldsymbol{\delta}}_i'$（24 维）。于是模型得到了另一组 24 维向量对应的 24 条正态分布曲线。

Step 3：贝叶斯似然融合

所谓“贝叶斯似然估计”，即通过似然函数和先验分布来估计参数的后验分布。它的核心思想是利用观测数据的似然性更新参数的先验信念，从而得到更符合数据证据的参数分布。相较于传统频率学方法，贝叶斯似然估计能够融入先验知识，适用于小样本或复杂模型的推断。

$$P(\Theta_M|D,M)=\frac{P(D|\Theta_M,M)\cdot P(\Theta_M|M)}{P(D|M)}$$

其中M为宏观的体系空间，Θ_M为体系的“超参数”（真实的 24 维 ABLH 值）。本模型在此将为了将两组序列进行融合，采取似然（Likelihood）融合的方法，由贝叶斯理论可知，在连续的θ参数空间内，分母$P(D)$的表达式可写为为：

$$P(D)=\int P(D|\theta)P(\theta)\cdot d\theta$$

故可以认为$P(D)$与$P(\Theta_M|M)$无关，可以认为分母为定值。所以与$P(D|\Theta_M,M)$成正比，其系数起到标准化的作用，可以认为不影响正态分布的大体结构。

$$P(\Theta_M|M)\propto P(D_1|\Theta_M,M)\cdot P(D_2|\Theta_M,M)$$

所以结合本模型得到的“正序列”、“逆序列”，即为两种数据D_1,D_2，所以在此将两序列的概率分布函数相乘，并尝试化简指数项为新的正态分布函数：

$$e^{-\frac{(x-\eta_j)^2}{2\sigma_j^2}}=e^{-\frac{(x-\mu_j)^2}{2\delta^2}}\times e^{-\frac{(x-\nu_j)^2}{2\delta_{ij}^2}}\quad i\in\{1,2,\cdots,6\},\ j\in\{1,2,\cdots,24\}$$

考察指数项，进行配方法，可以得到 24 维中每一维度最终所处的正态分布参数：

$$\sigma_j=\sqrt{\frac{\delta^2+\delta_{ij}^2}{\delta^2\cdot\delta_{ij}^2}}$$

$$\eta_j=\frac{\frac{\mu_j}{\delta^2}+\frac{\nu_j}{\delta_{ij}^2}}{\frac{1}{\delta^2}+\frac{1}{\delta_{ij}^2}}=\frac{\mu_j\cdot\delta_{ij}^2+\nu_j\cdot\delta^2}{\delta^2+\delta_{ij}^2},\ i\in\{1,2,\cdots,\ 6\},\ j\in\{1,2,\cdots,24\}$$

由此，模型就得到了融合之后的最终预测序列。将上述过程进行可视化效果如图 11。

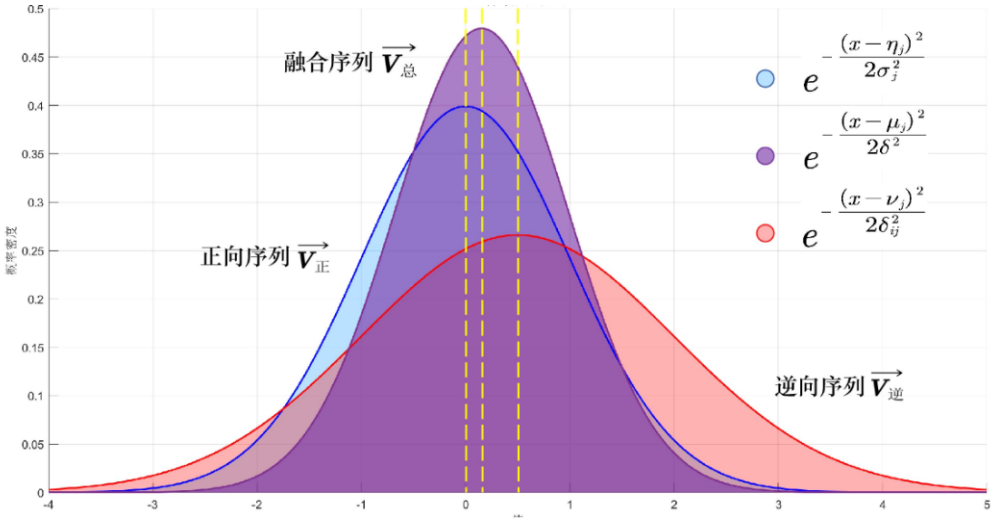


图 11：基于贝叶斯估计的融合模式图

6.5. 模型拟合效果呈现

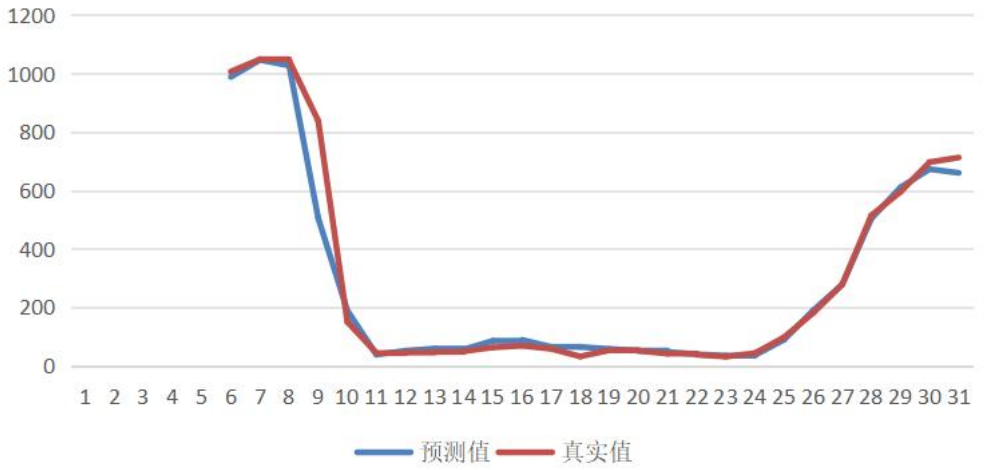


图 12：模型三拟合效果呈现图（以 1 月份数据为例）

由图可知，本模型在时间序列的预测上有较突出的精确度与泛化能力，拟合效果较好，由于进行了平滑处理以及 4 阶滞后阶数，故暂无 1 月 5 日之前的数据。

7. 总结

7.1. 模型总体评价评估

7.1.1. 优势分析

1、首先，本文采用了**机器学习中的 XGBoost 决策树模型**，能够充分挖掘多个影响因子之间的非线性关系，并捕捉不同特征对边界层高度（ABLH）变化的复杂作用机制。决策树模型具有较强的特征选择能力和模型可解释性，有助于分析各输入变量在预测中的相对重要性，从而提升预测的可靠性与科学性。

2、模型中引入了**向量自回归（VAR）模型**来处理空气污染物数据的时间序列特征。通过考虑污染物之间以及其自身在不同时刻的相互影响，自适应地计算出最优滞后阶数，从而有效捕捉污染物浓度变化对 ABLH 的动态影响。这种方法弥补了静态特征分析对时序特征忽视的不足，使预测结果更符合实际大气演变过程的规律性。

3、本模型融合了**贝叶斯信息融合方法**，通过对不同模型或数据源预测结果的概率加权整合，实现了 ABLH 的协同预测。贝叶斯融合不仅能够兼顾多个模型或数据的预测信息，还能自动调节各部分的权重分配，以最小化总体不确定性，提高预测精度和鲁棒性。整体而言，该模型在结构设计上兼顾了数据驱动与物理机理的统一，为复杂气象环境下的边界层高度预估提供了一种有效且可靠的手段。

7.1.2. 劣势分析

1、首先，贝叶斯估计过程中假设误差服从正态分布，这一前提在实际大气边界层高度（ABLH）预测中可能并不完全成立。大气系统具有高度的非线性与不确定性，误差分布可能呈现偏态或厚尾特性，若强行使用正态分布假设，可能导致对不确定性的低估，从而影响预测置信度的准确性。

2、其次，模型默认天气预报信息完全准确。这种假设忽略了天气预报本身存在的误差和不确定性，在一些时候会产生一定的影响。未来研究中可引入气象预测误差模型或不确定性传播机制，更真实地反映整体系统的预测能力与可信度。

7.2. 现实意义与思考

本研究在现实意义方面具有重要价值，为空气质量预报提供了更精准的科学依据，有助于提升城市环境管理水平。通过深入分析大气边界层高度（ABLH）与气象要素及污染物浓度的关系，本研究为决策者预测空气污染事件提供了可靠工具，使其能够及时采取应对措施，保护公众健康。

在模型应用拓展方面，本研究所构建的预测模型展现了广泛的适用性，不仅限于研究区域，还可推广至其他城市或地区的空气质量预报。通过动态调整参数，融合已知数据，本模型能够适应不同地理环境下的边界层动态变化。未来，通过结合遥感技术和高分辨率数值模拟，模型性能有望进一步优化，支持实时监测和预警大气污染事件。

最后，针对模型中体现出的核心思想，本文在此做适当外延，类似的时间序列问题，如农业中的农作物生长状况、播种时机以及农田环境监测问题；如金融领域中分析市场数据，预测股票价格和货币汇率，帮助投资者做出更明智的决策；亦如医疗领域中对医疗数据的分析，可以预测疾病的发病率和死亡率，为医疗机构制定预防和治疗措施提供支持。上述诸多领域均可以参考本文模型进行化用，将已知信息进行高维特征提取、贝叶斯融合等操作，以实现更精准的决策，实现更好的延伸与拓展。

8. 参考文献

[1] 雷久侯, 李若曦, 张顺荣, 等. 汤加火山喷发中重力波与Lamb波对热层大尺度响应的作用机制[J]. AGU Advances, 2025, 6(2): e2024AV001470.
[2] 徐祥德, 王寅钧, 赵天良, 等. 高原东南缘大气近地层湍能特征与边界层动力、热力结构相关特征[J]. 气象, 2014, 40(10): 1165-1173.
[3] 黄鹤. 白洋淀地区水陆非均匀下垫面上大气边界层特征的数值模拟研究[D]. 兰州: 兰州大学大气科学学院, 2007.
[4] 潘亮, 吴俊石, 张燕燕, 等. 上海早晨边界层的稳定度特征及其对 $PM_{2.5}$ 峰值浓度的影响[J]. 环境科学学报, 2020, 40(4): 1351-1360.
[5] Garratt J R. The atmospheric boundary layer [M]. Cambridge: Cambridge University Press, 1992.
[6] 张宏昇，张小曳，李倩惠，等. 大气边界层高度确定及应用研究进展[J]. 气象学报，2020, 78(3): 522-536.
[7] Stull R B. An introduction to boundary layer meteorology [M]. Dordrecht: Kluwer Academic Publishers, 1988.
[8] Monin A S, Obukhov A M. Basic laws of turbulent mixing in the atmosphere near the ground［J］. Trudy Geofizicheskogo Instituta AN SSSR, 1954, 24(151): 163–187.
[9] Zhang Y, Gao Z, Li D, et al. Quantifying the relative importance of factors controlling the spatiotemporal variability of the atmospheric boundary layer height [J]. Journal of Geophysical Research: Atmospheres, 2021, 126(8).

9. 附录

1.Spearman

```
% 读取 CSV 文件
filename = '3-附件 1-2025 校赛第 2 轮 A 题边界层高度与天气数据（原始）.csv';
data = readtable(filename);

% 选择需要的列
variables = {
    'U_wind_component',...
    'V_wind_component',...
    'air_temperature_2m',...
    'surface_pressure',...
    'ground_temperature',...
    'latent_heat_flux',...
    'sensible_heat_flux',...
    'relative_humidity',...
    'boundary_layer_height'
};

% 提取数据
```

```
selectedData = data(:, variables);

% 计算斯皮尔曼相关系数
corrMatrix = corr(table2array(selectedData), 'Type',
'Spearman');

% 创建变量名标签（处理下划线转义）
labels = strrep(variables, '_', '\_');

% 创建热力图
h = heatmap(labels, labels, corrMatrix);

% 设置热力图属性
h.Title = '斯皮尔曼相关系数矩阵（冷→暖渐变）';
h.ColorLimits = [-1, 1]; % 固定颜色范围

% 自定义冷→暖渐变颜色映射（参考示例图的配色）
n = 256; % 颜色总数
cool_part = cool(128);    % 获取冷色调部分（蓝→青）
hot_part = hot(128);      % 获取暖色调部分（红→黄）

% 构建渐变（深蓝→浅蓝→白→浅红→深红）
custom_map = [
    [linspace(0.1, 0.5, 64)', linspace(0.1, 0.8, 64)',
linspace(0.8, 1, 64)']; % 深蓝→浅蓝
    [linspace(0.5, 1, 64)', linspace(0.8, 1, 64)',
linspace(1, 1, 64)'];        % 浅蓝→白
    [linspace(1, 1, 64)', linspace(1, 0.8, 64)', linspace(1,
0.5, 64)'];        % 白→浅红
    [linspace(1, 0.8, 64)', linspace(0.8, 0.1, 64)',
linspace(0.5, 0.1, 64)']   % 浅红→深红
];

h.Colormap = custom_map;

% 设置单元格标签
h.CellLabelFormat = '%.2f'; % 显示 2 位小数
h.CellLabelColor = 'auto';  % 自动文字颜色（深色背景白字，浅色
背景黑字）
```

```
% 调整图形大小
fig = gcf;
fig.Position(3:4) = [800, 700];
colorbar('Ticks', -1:0.2:1); % 添加详细颜色刻度
```

2.PCA

```
function PCA()
    % 读取数据文件
    try
        opts = detectImportOptions('边界层高度与空气质量数据_按天.csv');
        data = readtable('边界层高度与空气质量数据_按天.csv', opts);
    catch ME
        error('文件读取失败: %s', ME.message);
    end

    % 提取前 24 列数据
    if width(data) < 24
        error('数据表列数不足 24 列');
    end
    X = table2array(data(:, 1:24));

    % 获取列名
    column_names = data.Properties.VariableNames(1:24);

    % 数据标准化
    X_standardized = zscore(X);

    % 执行 PCA 降维到 6 维
    [coeff, score, latent, ~, explained] = pca(X_standardized, 'NumComponents', 6);

    % 创建 6 维结果表格
    pc_labels = {'PC1','PC2','PC3','PC4','PC5','PC6'};
    reduced_data = array2table(score, 'VariableNames', pc_labels);

    % 保存 6 维数据
    writetable(reduced_data, 'PCA_6D_Results.csv');
```

```
    disp('6 维降维结果已保存为 PCA_6D_Results.csv');

    % 创建 5 个可视化图形
    create_visualizations(coeff, score, latent, explained,
column_names);

    % 保存工作区变量
    save('PCA_6D_Workspace.mat', 'coeff', 'score', 'latent',
'explained', 'reduced_data');

    % 显示前 5 行结果
    disp('降维结果前 5 行:');
    disp(reduced_data(1:5,:));
end

function create_visualizations(coeff, score, latent,
explained, column_names)
    % 图 1: 碎石图
    fig1 = figure('Name','PCA 碎石图');
    plot(latent, 'bo-', 'LineWidth', 2);
    hold on;
    plot(cumsum(explained), 'ro-', 'LineWidth', 2);
    title('PCA 碎石图与累计方差解释');
    xlabel('主成分');
    ylabel('特征值/累计解释率(%)');
    legend({'特征值','累计解释率'},'Location','best');
    grid on;
    savefig(fig1, 'PCA_ScreePlot.fig');

    % 图 2: 主成分系数热图
    fig2 = figure('Name','主成分系数热图');
    heatmap({'PC1','PC2','PC3','PC4','PC5','PC6'},
column_names, coeff);
    title('主成分系数热图');
    savefig(fig2, 'PCA_Heatmap.fig');

    % 图 3: 前 3 个主成分 3D 散点图
    fig3 = figure('Name','前 3 主成分 3D 视图');
    scatter3(score(:,1), score(:,2), score(:,3), 'filled');
    xlabel('PC1'); ylabel('PC2'); zlabel('PC3');
```

```
    title('前 3 主成分 3D 分布');
    grid on; rotate3d on;
    savefig(fig3, 'PCA_3DView.fig');

    % 图 4: 主成分系数曲线
    fig4 = figure('Name','主成分系数曲线');
    plot(coeff(:,1:6), 'LineWidth', 2);

legend({'PC1','PC2','PC3','PC4','PC5','PC6'},'Location','b
est');
    title('主成分系数变化');
    xlabel('原始变量'); ylabel('系数值');
    xticks(1:length(column_names));
    xticklabels(column_names);
    xtickangle(90);
    grid on;
    savefig(fig4, 'PCA_CoefficientCurves.fig');

    % 图 5: 方差解释比例
    fig5 = figure('Name','方差解释比例');
    pareto(explained);
    xlabel('主成分');
    ylabel('方差解释比例(%)');
    title('主成分方差贡献');
    grid on;
    savefig(fig5, 'PCA_VarianceExplained.fig');

    % 保持所有图形打开
    disp('5 个可视化图形已保持打开状态，可直接编辑');
end
```

3.XGBoost_model

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.preprocessing import StandardScaler
import xgboost as xgb
import matplotlib.pyplot as plt

# 读取数据
```

```
data = pd.read_excel('3-附件 1-2025 校赛第 2 轮 A 题边界层高度与天气数据.xlsx')

# 数据预处理
# # 将日期列转换为时间戳（如果尚未处理）
# data['date'] = pd.to_datetime(data['date'])

# # 提取时间特征（可选，可以增加时间相关的特征）
# data['hour'] = data['date'].dt.hour
# data['day'] = data['date'].dt.day
# data['month'] = data['date'].dt.month

# # 删除原始日期列
# data = data.drop(columns=['date'])

# 检查缺失值
print("缺失值统计：")
print(data.isnull().sum())

# 如果有缺失值，可以填充或删除
data = data.dropna()  # 删除缺失值

# 保存第一列数据，以便后续在结果中使用
first_column_name = data.columns[0]
first_column_data = data.iloc[:, 0]

# 定义特征和目标变量
X = data.drop(columns=['大气边界层高度/m'])
y = data['大气边界层高度/m']

# 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

# 数据标准化
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

# 初始化 XGBoost 回归模型
model = xgb.XGBRegressor(
    objective='reg:squarederror',  # 回归任务
    n_estimators=200,              # 树的数量
    learning_rate=0.1,             # 学习率
    max_depth=8,                   # 树的最大深度
    subsample=0.8,                 # 样本采样比例
    colsample_bytree=0.8,          # 特征采样比例
    random_state=42
)
```

```
# 训练模型
model.fit(X_train, y_train)

# 预测
y_pred = model.predict(X_test)

# 评估模型
mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
r2 = r2_score(y_test, y_pred)

print(f"均方误差 (MSE): {mse:.2f}")
print(f"均方根误差 (RMSE): {rmse:.2f}")
print(f"R² 分数: {r2:.2f}")

# 将预测结果保存到 Excel 文件
# 创建一个包含测试数据、预测值和实际值的 DataFrame
results_df = pd.DataFrame(X_test, columns=X.columns)
results_df['预测值'] = y_pred
results_df['实际值'] = y_test
results_df['误差'] = results_df['预测值'] - results_df['实际值']

# 获取测试集对应的索引，以便提取对应的第一列数据
test_indices = y_test.index

# 检查第一列是否已经存在于 DataFrame 中，如果不存在则插入
if first_column_name not in results_df.columns:
    results_df.insert(0, first_column_name,
first_column_data.iloc[test_indices].values)

# 保存结果到 Excel 文件
output_file = "new_xgb_model_predictions.xlsx"
results_df.to_excel(output_file, index=False)
print(f"预测结果已保存到 {output_file}")

# 特征重要性
feature_importance = model.feature_importances_
features = X.columns
importance_df = pd.DataFrame({'Feature': features, 'Importance':
feature_importance})
importance_df = importance_df.sort_values(by='Importance', ascending=False)

print("\n 特征重要性：")
print(importance_df)

# 可视化特征重要性
plt.figure(figsize=(10, 6))
plt.barh(importance_df['Feature'], importance_df['Importance'])
plt.xlabel('Importance')
```

```
plt.title('Feature Importance')
plt.show()

# 可视化预测结果
plt.figure(figsize=(10, 6))
plt.scatter(y_test, y_pred, alpha=0.5)
plt.plot([y.min(), y.max()], [y.min(), y.max()], 'r--')  # 对角线
plt.xlabel('Actual Values')
plt.ylabel('Predicted Values')
plt.title('Actual vs Predicted Boundary Layer Height')
plt.show()


# 读取 1 月数据并进行预测
january_data = pd.read_excel('1 月数据.xlsx')  # 假设 1 月数据文件名为'1 月数
据.xlsx'

# 应用相同的预处理
january_data = january_data.dropna()
january_first_column_name = january_data.columns[0]
january_first_column_data = january_data.iloc[:, 0]

X_january = january_data.drop(columns=['大气边界层高度/m'])
y_january_true = january_data['大气边界层高度/m']

# 应用相同的标准化
X_january_scaled = scaler.transform(X_january)

# 使用训练好的模型进行预测
y_january_pred = model.predict(X_january_scaled)

# 创建包含预测结果的 DataFrame
january_results = pd.DataFrame(X_january, columns=X.columns)
january_results['预测值'] = y_january_pred
january_results['真实值'] = y_january_true
january_results['误差'] = january_results['预测值'] - january_results['真实值']

# 添加第一列数据
if january_first_column_name not in january_results.columns:
    january_results.insert(0, january_first_column_name,
january_first_column_data.values)

# 保存 1 月预测结果
january_output_file = "1 月预测结果.xlsx"
january_results.to_excel(january_output_file, index=False)
print(f"1 月预测结果已保存到 {january_output_file}")
```

4.AQI_zscore

```
% 清除工作区和关闭所有图形窗口
clear;
close all;

% 读取 CSV 文件
filename = '4-附件 2-2025 校赛第 2 轮 A 题嘉兴空气质量数据.csv';
data = readtable(filename);

% 选择需要标准化的列
columns_to_normalize = {'AQI', 'PM2_5', 'PM10', 'SO2', 'NO2',
'CO'};
data_selected = data(:, columns_to_normalize);

% 将表格转换为数组以便计算
data_array = table2array(data_selected);

% 对每列进行 z-score 标准化
data_normalized = zscore(data_array);

% 将标准化后的数据转换回表格
normalized_table = array2table(data_normalized,
'VariableNames', columns_to_normalize);

% 将标准化后的数据写入 Excel 文件
output_filename = 'normalized_air_quality_data.xlsx';
writetable(normalized_table, output_filename);

% 添加时间列（假设原始数据有时间列，如果没有可以创建序号）
if ismember('Time', data.Properties.VariableNames)
    time = data.Time;
else
    time = (1:height(data))';
end

% 创建 6 个单独的图形窗口，每列一个
for i = 1:length(columns_to_normalize)
    figure;
    plot(time, data_normalized(:, i));
    title(sprintf('%s - 标准化数据',
columns_to_normalize{i}));
```

```
    xlabel('时间/序号');
    ylabel('标准化值');
    grid on;
end

% 创建一个图形窗口显示所有 6 列数据（堆叠图）
figure;
plot(time, data_normalized);
title('空气质量指标 - 标准化数据堆叠图');
xlabel('时间/序号');
ylabel('标准化值');
legend(columns_to_normalize, 'Location', 'best');
grid on;

% 创建一个图形窗口显示所有 6 列数据（子图）
figure;
for i = 1:length(columns_to_normalize)
    subplot(3, 2, i);
    plot(time, data_normalized(:, i));
    title(columns_to_normalize{i});
    xlabel('时间/序号');
    ylabel('标准化值');
    grid on;
end
% 创建一个图形窗口显示所有 6 列数据（堆叠区域图）
figure;
area(time, data_normalized); % 使用 area 函数绘制堆积图
title('空气质量指标 - 标准化数据堆积图');
xlabel('时间/序号');
ylabel('标准化值');
legend(columns_to_normalize, 'Location', 'best');
grid on;
sgtitle('空气质量指标 - 标准化数据子图');

disp('处理完成！标准化数据已保存到
normalized_air_quality_data.xlsx');
```