参赛承诺书

提交包含此承诺书的 pdf 文件，表明所有此文件的作者共同承诺：

我们完全清楚，在竞赛开始后参赛队员不能以任何方式，包括电话、电子邮件、“贴吧”、QQ 群、微信群等，与队外的任何人（包括指导教师）交流、讨论与赛题有关的问题；无论主动参与讨论还是被动接收讨论信息都是严重违反竞赛纪律的行为。

我们以中国大学生名誉和诚信郑重承诺，严格遵守竞赛章程和参赛规则，以保证竞赛的公正、公平性。如有违反竞赛章程和参赛规则的行为，我们将受到严肃处理。

我们授权北京理工大学数学建模竞赛组织方，可将我们的论文以任何形式进行公开展示（包括进行网上公示，在书籍、期刊和其他媒体进行正式或非正式发表等）。

2025.7

“形界之辨”——基于 Canny 边缘检测与深度学习语义分割优化的活动轮廓模型

摘要：

本文针对传统活动轮廓模型（ACM）在复杂场景下分割精度与效率不足的问题，提出了两种改进方案。首先，为全面评估各类 ACM 变体的性能，构建了包括相似性（精确率、召回率、Hausdorff 距离）、鲁棒性（轮廓敏感性）与高效性（总迭代时长）在内的多维评价体系，并采用熵权法与层次分析法融合确定指标权重，结合 TOPSIS 法对模型进行排序与筛选，为最优模型选择提供了科学依据。

针对 BSDS500 数据集中模糊边界与拓扑结构复杂的挑战，提出了**基于 Canny 边缘检测与区域模型融合的 CiSC 模型**。该方法首先通过 Canny 算子提取初始轮廓先验，再利用高斯模糊预处理增强弱边缘信息，最后在 Chan–Vese 能量泛函框架下迭代优化轮廓。实验结果表明，相较于经典 ACM 模型，CiSC 在模糊精确率、召回率及平均迭代耗时方面均有显著改进。

为进一步提升全局语义理解能力与分割效率，本文**在 CiSC 基础上引入 Transformer 语义分割网络，构建了 CiSTN 模型**。该模型利用预训练语义分割掩膜替代 Canny 先验，结合 Transformer 注意力机制提取全局特征，并在能量驱动框架中实现轮廓初始化与迭代优化的深度融合。对比实验显示，CiSTN 在复杂拓扑、背景干扰与弱边缘条件下，模糊精确率达到 0.2858、模糊召回率达 0.5644，平均单张处理时长仅 3.24 秒，轮廓敏感性降至 0.0054，表现优于 CiSC 及其他变体。

综上所述，本研究通过多维评价体系指导模型筛选，并分别引入边缘先验与语义先验，提出了 CiSC 与 CiSTN 两种高效、鲁棒的 ACM 改进方案，显著提升了复杂场景图像分割的精度与效率。未来工作将聚焦于模型参数自适应优化与并行化加速，并探索在医学影像、自动驾驶等应用领域的迁移与推广。

关键词：活动轮廓模型、图像分割、Canny 边缘检测、Chan-Vese 模型、语义分割

“形界之辨”——基于 Canny 边缘检测与深度学习语义分割优化的活动轮廓模型

1. 问题背景与重述

1.1. 问题背景

图像分割作为计算机视觉领域的核心任务之一，旨在将图像划分为具有一致属性的若干区域，为图像理解、对象识别、场景重建等后续任务提供结构化输入。当前常用的图像分割方法包括基于阈值的分割、统计建模方法、模糊聚类、深度学习方法以及活动轮廓模型（Active Contour Model, ACM）等。其中 ACM 由于其能够较为精准地对复杂目标边界进行轮廓描述，成为众多分割任务中的重要工具。其基本思想是以一个初始轮廓为起点，在图像梯度信息或区域特征驱动下，通过最小化某类能量泛函，使轮廓逐步演化贴合目标边界，最终实现前景与背景的有效分离。

然而，标准 ACM 模型在处理边界模糊、拓扑复杂或背景干扰强烈的图像时存在明显局限。故本文提出了这些问题的改进模型，利用到了包括基于区域信息的 Chan-Vese 模型、结合边缘与区域信息的混合评估以及基于 Canny 边沿检测的先验处理等。进一步地，在研究过程中还发现一些常规方法难以解决的识别问题，故又考虑将 ACM 与深度特征提取相结合，探索融合传统模型与现代学习范式的有效方向。

1.2. 问题重述

1、图像分割的活动轮廓模型(ACM)的改进模型很多，需要建立一种数学评价模型用以筛选评估性能最佳的 ACM 改进模型。

2、分析并参照 BSDS500 数据集中的典型图像的特征，筛选出一种最适合的 ACM 改进模型（本文自创了种改进模型 CiSC）。基于 BSDS500 数据集，对比 CiSC 模型与经典 ACM 模型的实际分割效果，验证改进模型的有效性。

3、针对前两问中出现的问题，进一步考虑将深度学习方法与第 2 问中构建的 ACM 改进模型 CiSC 结合，建立一种更加高效的图像分割模型。

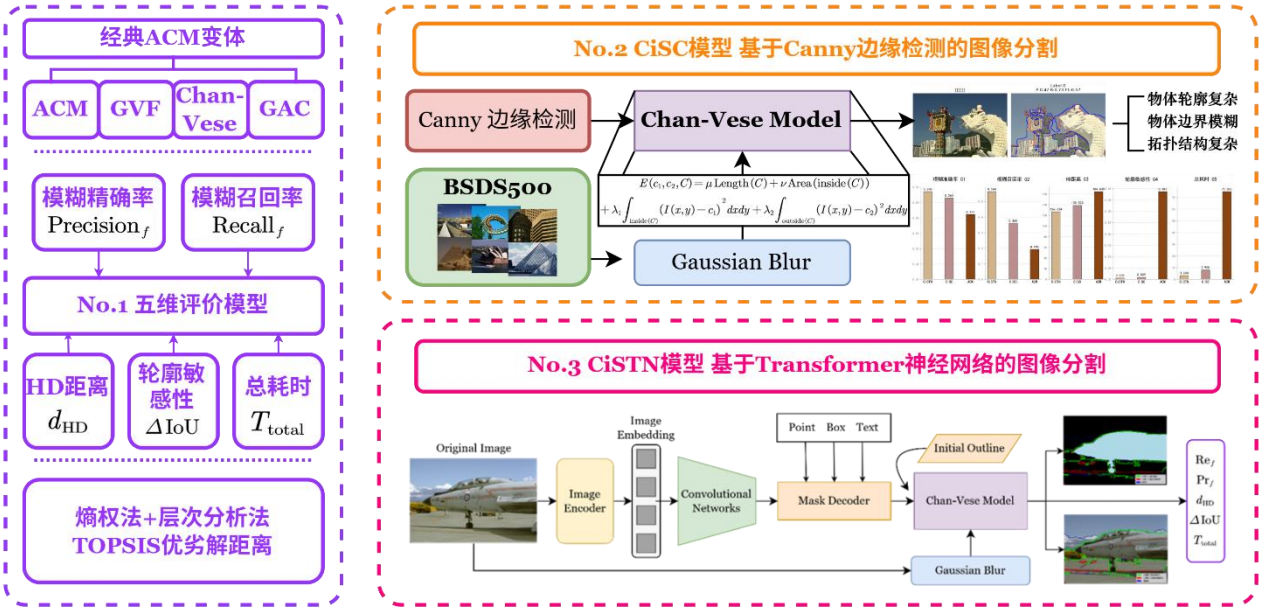


图 1 建模工作流程图

2. 问题分析

2.1. 针对问题一的分析

活动轮廓模型（ACM）作为图像分割的重要方法，其众多改进模型（如 GVF Snake、Balloon Snake、GAC、Chan-Vese 模型等）在不同类型图像中的分割表现存在差异。因此，如何科学、系统地筛选出最优 ACM 改进模型，成为解决该问题的关键。

① 首先需要了解这些众多 ACM 改进模型的各自实现原理以及相对传统 Snake 的有点在哪，解决了哪些问题。

② 其次需要建立一套多维度的评价体系，并设计统一的实验流程，结合分割相似性（如 IoU、Dice 系数）、高效性（如迭代次数与时间开销）、鲁棒性（对初始轮廓、噪声、模糊等的敏感性）等等指标，构建一个多目标优化的综合评分函数，对各类改进模型进行具体详细地量化评估，对比各模型在标准测试图像集上的表现，为实现自动化选择最优模型。

2.2. 针对问题二的分析

BSDS500 数据集以自然场景图像为主，存在目标边界复杂、轮廓非封闭、物体嵌套与包含关系显著、弱边缘普遍及背景纹理复杂等特点，给传统活动轮廓模型（ACM）带来严峻挑战。经典 Snake 模型依赖封闭初始轮廓与强梯度，难以适应非规则、模糊或稀疏边界，且易陷入局部极小。

为应对这些挑战，本文提出改进模型 **CiSC（Chan-Vese image Segmentation based on Canny detection）**，通过引入 Canny 边缘检测构建更合理的初始曲线，缓解初始化敏感与收敛低效问题；以 Chan-Vese 区域模型为主干，脱离对梯度的依赖，适应模糊边界与复杂拓扑变化；同时辅以高斯模糊预处理，抑制纹理噪声干扰。该模型结合边缘引导与区域驱动，兼顾边界定位与拓扑表达能力，适配 BSDS500 复杂特性。本文将通过定量指标与可视化对比，验证 CiSC 模型在边界完整性、细节保留及分割鲁棒性方面的改进效果。

2.3. 针对问题三的分析

尽管 CiSC 模型在处理模糊边界与复杂轮廓方面表现出色，但其依赖的 Canny 算子本质为局部梯度检测器，缺乏全局语义理解能力，易受光照、纹理等非目标强边缘干扰，导致生成的初始轮廓常偏离真实语义边界。

为弥补该缺陷，本文提出融合深度语义建模能力的 **CiSTN 模型（Chan-Vese image Segmentation based on Transformer Network）**，引入具备全局语义感知的 Transformer 分割模型（如 SAM）以替代 Canny 模块，生成高质量分割掩膜并提取其边界作为 Chan-Vese 模型的初始化轮廓。该方法融合语义引导与能量驱动双重机制，既可显著提升初始轮廓的准确性与拓扑表达能力，避免陷入局部最优，又可缩短后续水平集演化的收敛时间，提升整体分割效率。本文将通过在 BSDS500 数据集上的对比实验，验证该融合策略在准确性与计算效率方面的综合优势。

3. 模型假设与公式符号

评价体系适用性假设：假设基于相似性（模糊精确率、模糊召回率、Hausdorff 距离）、鲁棒性（轮廓敏感性）和高效性（总迭代时长）的多维评价体系，能够全面、客观地量化比较 CiSC、CiSTN 与经典 ACM 模型的分割性能，适用于 BSDS500 数据集的复杂特性。

数学符号	符号含义
$\mathbf{V}(s)$	曲线参数方程
$I(x,y)$	图像像素方程
$E_{\text{int}}, E_{\text{image}}$	内部能量、图像能量
Pr_f	模糊精确率
Re_f	模糊召回率
d_{HD}	HD 距离
ΔIoU	轮廓敏感性
T_{total}	总迭代时长

表 1. 本文公式中重要符号注释

4. ACM 改进模型评价

4.1. 经典轮廓分割模型 ACM 的原理分析

活动轮廓模型（Active Contour Model, 简称 ACM），又称“Snakes”，是一种基于能量最小化思想的轮廓检测方法，广泛应用于图像分割、边缘检测与运动目标跟踪等计算机视觉任务中。其核心思想是通过最小化定义在曲线上的能量泛函，使初始轮廓在**图像力（外力）和约束力（内力）**的共同作用下收敛到感兴趣的图像边缘。其详细流程呈现如下：

4.1.1. 整体表达式

首先，对于一张特定的照片数据源，通常先对其像素点进行二维建系编码，于是相应的轮廓曲线可以表示为一条参数化曲线：

$$\mathbf{v}(s)=(x(s),y(s)),s\in[0,1]$$

于是可以定义出对于这条特定曲线上的相应总能量函数，可以拆分成以下是三个部分之和：

$$E_{\text{snake}}=\int_0^1 (E_{\text{int}}\mathbf{v}(s)+E_{\text{image}}\mathbf{v}(s)+E_{\text{con}}\mathbf{v}(s))\,ds$$

其中，E_{in} 表示曲线的内部能量，用于维持轮廓的连续性与光滑性；E_{im} 表示图像能量，驱动轮廓向图像中的边缘、线条等特征靠近；而 E_{ex} 为额外约束能，可由用户交互或高层语义引导提供。

4.1.2. 内外部能量分析

详细来看，内部能量项可以定义为曲线的一阶与二阶导数的加权平方和，用以控制曲线的张力与柔性：

$$E_{\text{int}}(v(s)) = \alpha(s)\cdot\left\|\frac{d\mathbf{v}}{ds}\right\|^2 + \beta(s)\cdot\left\|\frac{d^2\mathbf{v}}{ds^2}\right\|^2$$

其中，一阶导部分通过惩罚曲线的局部变形来保持其弹性，确保曲线在拉伸或收缩时不会过度扭曲；二阶导部分则通过惩罚曲率变化来维持曲线的刚性，使整体形状更加平滑。相应系数$\alpha(s)$用以控制轮廓的弹性张力，$\beta(s)$用以控制其柔性程度。该项保证了曲线在演化过程中的平滑性与物理可行性。

$$E_{\text{image}}(x,y) = -\|\nabla(G_\sigma * I(x,y))\|^2$$

此外，对于由图像梯度所决定的外力，可以实现吸引轮廓贴合图像中的显著特征，在此通常将其处理为为原图像$I(x,y)$与标准差为σ的高斯核G_σ的卷积，用于平滑图像以减弱噪声影响。偏导数梯度算子作用在卷积之后，由于其范数在图像边缘处达到局部极大，从而使E_{image}在边缘位置取极小值，使得 Snake“被吸引”贴近边缘。

当然，在某些特殊的图像识别与分割领域中，可以用户自行定义额外的外部约束项E_{con}用于满足特殊要求。

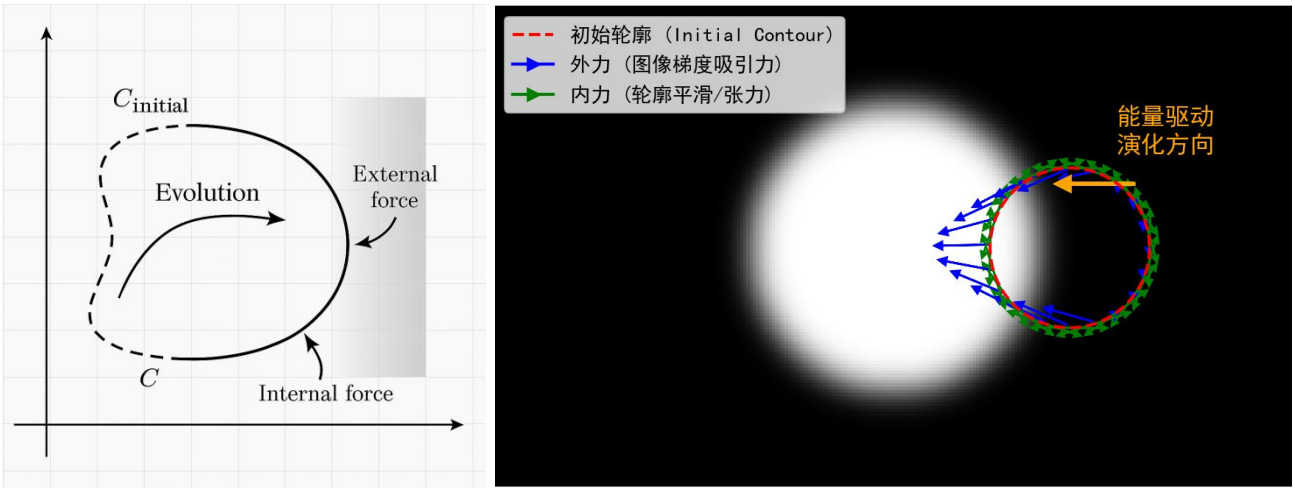


图 2 经典 ACM 分割模型原理图

图 2 中展示了 Snake 活动轮廓模型的基本原理，虚线C_{initial}代表初始轮廓，其在内部力与外部力共同作用下逐步演化至实线 C。内部力保障轮廓的平滑与连续，维持合理形态；外部力引导轮廓向图像目标边缘移动，如梯度、亮度等特征区域。二者协同驱动初始轮廓迭代优化，使总能量最小化，最终贴合目标边界，实现图像分割中轮廓对感兴趣区域的精准捕捉，是理解主动轮廓模型能量驱动变形机制的直观示意 。

4.2. ACM 变体模型分析

表 2. 传统 ACM 的缺陷及相应改进策略

缺点	变体模型
初始化敏感，初始化要求高 容易陷入局部最优	引入气球力、引入梯度矢量流
弱边缘难处理	基于区域的方法
曲线的拓扑结构难以变化	基于水平集的方法
分割目标的形状难以改变	引入形状先验

由于传统 Snake 模型在图形分割上有其固有的劣势与不足，相应的诞生出许多针对其劣势进行改进的 ACM 变体，如上表所示：

4.2.1. GVF 梯度矢量流模型

为了克服传统 Snake 模型在边界凹陷处易陷入局部极小值、对初始轮廓依赖性较强等局限，Xu 和 Prince 于 1998 年提出了**梯度矢量流（GVF）活动轮廓模型**[1]。该模型通过在图像域内定义一个向量场，使得轮廓能在更大范围内被边缘吸引，从而有效提高了轮廓对目标边界的捕捉能力。

GVF 通过最小化下列能量泛函来获得平滑且边缘引导性强的向量场：

$$E=\iint \mu(u_x^2+u_y^2+v_x^2+v_y^2)+|\nabla f|^2\cdot|\mathbf{v}-\nabla f|^2\,dxdy$$

其中，$f(x,y)$是图像的边缘强度函数，∇f是其梯度，μ为正的正则化系数，控制平滑项与数据项之间的权衡。该泛函的第一项促进矢量场的空间平滑性，第二项则使矢量场在边缘附近趋向图像梯度。求解该泛函的最优解可通过 Euler-Lagrange 方程迭代实现。

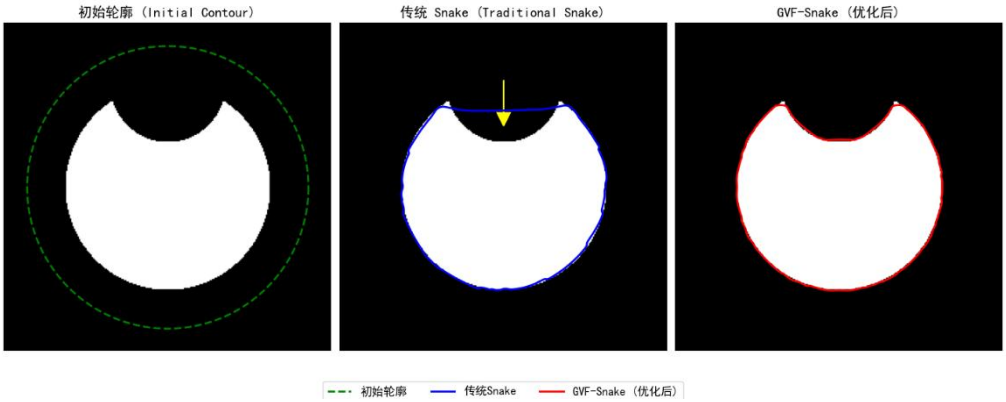


图 3 传统 Snake 模型和 GVF-Snake 模型在凹陷与尖角处的分割效果

如上图所示，红色曲线对于偶见区域的拟合效果远好于经典分割，且平滑性明显较好，据此分析 GVF 模型的优势在于：其外力场能够向边缘方向扩展到边界附近较远的区域，并在边界凹陷处形成正确的吸引力方向，从而极大拓宽了初始轮廓选择的自由度，提高了分割鲁棒性。

4.2.2. GAC 测地线活动轮廓

为了在复杂背景和弱边缘环境下实现稳健分割，Caselles 等人于 1997 年提出了**测地线活动轮廓（GAC）模型**[2]。该模型将轮廓演化视作在图像导引的黎曼流形上寻找最短测地线，通过以下能量泛函定义轮廓$C(s)$的长度：

$$E(C)=\int_0^1 g\big(|\nabla I(C(s))|\big)\cdot|C'(s)|\,ds$$

其中$I(x,y)$为原始图像灰度，∇I为其梯度，$g(.)$是边缘指示函数，常取

$$g(|\nabla I|)=\frac{1}{1+|\nabla(G_\sigma * I)|^2}$$

其优势在于本模型的数学框架严谨，曲率平滑项保证轮廓光滑无锯齿，并且能自适应强度变化，在噪声、断裂或凹陷区域精准停留，实现精确地定位于分割。当然，其劣势在于其对高斯核尺度σ及时间步长敏感，需经验调参，同时由于数值迭代计算量大，收敛速度相对较慢。

4.2.3. Chan-Vese 区域模型

为了在无明显边缘或弱边缘图像中实现精确分割，Chan 和 Vese 于 2001 年提出了一种基于区域的能量最小化框架[3]。其核心思想在于把图像分成“内”、“外”两个区域，假设这两个区域各自有一个平均灰度值（c_1和c_2），然后调整轮廓，使得“内区域”像素值尽量接近c_1，“外区域”像素值尽量接近c_2 。其能量泛函定义为：

$$E(c_1,c_2,C)=\mu\,\mathrm{Length}(C)+\nu\,\mathrm{Area}(\mathrm{inside}(C))$$

$$+\lambda_1\int_{\mathrm{inside}(C)}(I(x,y)-c_1)^2dxdy+\lambda_2\int_{\mathrm{outside}(C)}(I(x,y)-c_2)^2dxdy$$

其中：

① 第一项鼓励轮廓更短、更平滑，避免出现锯齿或杂乱；

② 第二项可以控制分割出区域的面积大小；

③ 第三和第四项则度量内外区域与它们各自平均灰度c_1, c_2的差距，差距越小能量越低。找到能量最低的轮廓，就意味着分割效果最好。

为了方便数学运算，本模型通常选用“水平集函数”技巧，把轮廓当作一条等高线（$\phi(x,y)=0$）。随着算法迭代，这条等高线会慢慢“蜕变”到最优位置。所以本变种方法不依赖清晰边缘，能处理噪声多、纹理复杂或低对比度的图像，尤其是轮廓可以自动分裂或合并，即发生拓扑变化。不过同样其参数需要调试，计算量较大，收敛速度相对较慢。

4.3. 图像分割评价模型构建

分割算法的有效性依赖于采用稳健且全面的评价指标，这些指标需捕捉空间精度、边界精确性及与真实标注一致性的细微差别。本研究提出一个多维评价框架，包含三个个维度：①相似性、②鲁棒性、③高效性，同时细分为五项具体量化指标：精确率C_1、召回率C_2、Hausdorff 距离C_3、轮廓敏感性C_4及总迭代时长C_5。

$$\mathcal{L}=\sum_{i=1}^{5}w_iC_i$$

这些指标共同提供对分割质量的全面评估，涵盖几何和计算性能两个方面，下面将详细展开论述。

4.3.1. 相似性

关于分割得到的轮廓曲线与实际轮廓曲线之间的相似性是衡量模型效果的关键之一，在此采用三个核心数据来进行衡量，分别是精确率C_1、召回率C_2和 Hausdorff 距

离C_3。其中精确率与召回率是是基于预测结果所构成的**混淆矩阵**（包括真正例 TP、假正例 FP、真反例 TN 及假反例 FN）定义的统计量。

1、**精确率**：表示在所有被预测为正样本的实例中，真正正确的比例，它反映了模型的“判为正”输出中有多少是可信的，适用于对**误报率敏感**的场景，如医学诊断中的误诊代价高时，其数学定义为：

$$\text{Precision} = \frac{TP}{TP + FP}$$

2、**召回率**：表示在所有真实为正样本中，模型正确识别出来的比例，适合衡量模型“发现”真实正样本的能力，适用于错过正例后果严重的任务，如安全监测中的漏检。其数学定义为：

$$\text{Recall} = \frac{TP}{TP + FN}$$

3、在多数实际应用中，精确率与召回率往往存在权衡关系：提升精确率可能会降低召回率，反之亦然。在某些时候常使用 F1-Score 指标来作为评判，此时精确率与召回率的权重相同，不过本模型考虑到了被评估使用情景的多样性与广泛性，并不采取 F1-Score 的策略，而改用加权求和的方式进行$\mathcal{L} = w_1 C_1 + w_2 C_2 + ...$

此外在图像分割任务中，评估模型预测结果不仅需考虑平均性能（如 IoU），更需关注极端边界偏差。为此，Hausdorff 距离成为一种关键的边界对齐评价指标，在本文中为参考指标C_3，其定义如下。设预测轮廓和真实分割结果分别对应点集X, Y。点$x \in X$到集合Y的距离与方向性的 Hausdorff 距离分别定义为：

$$d(x,Y) = \inf_{y \in Y} d(x,y),\ d(X,Y) = \sup_{x \in X} d(x,Y) = \sup_{x \in X} \inf_{y \in Y} d(x,y)$$

故完整的 Hausdorff 距离定义为：

$$d(X,Y) = \max\{d(X,Y), d(Y,X)\}$$

在语义分割评估中，HD 衡量的是预测边界与真实边界之间的**最远距离偏差**，直观地突出最坏匹配错误，因此对捕捉边界漏检、假阳或错位极端错误特别敏感。若 HD 值小意味着最大的边界误差也被控制在较小范围内，适用于对边界精度有严格要求的任务，如医学图像分割、器官或病灶轮廓测量等 。

4.3.2. 鲁棒性

为评估活动轮廓模型对**初始轮廓敏感性**的稳健程度，本文采用基于交并比（Intersection-over-Union, IoU）的可重复性评估方法。具体方法如下：在固定图像和模型参数设置下，对初始轮廓位置进行多次随机扰动（如随机平移、缩放或旋转），每次迭代运行分割，得到对应的输出掩码M_i。与标准标签掩码G比较，分别计算第i次试验的 IoU 值：

$$\text{IoU}_i = \frac{|M_i \cap G|}{|M_i \cup G|}, i = 1, 2, ..., N$$

统计所有IoU_i的最大值$\text{IoU}_{\max}$、最小值$\text{IoU}_{\min}$以及平均值$\overline{\text{IoU}}$，并定义敏感性指标如下：

$$\Delta \mathrm{IoU} = \frac{\mathrm{IoU}_{\max} - \mathrm{IoU}_{\min}}{\overline{\mathrm{IoU}}}$$

该指标衡量因初始条件随机扰动而导致分割结果的相对波动幅度。若ΔIoU 较高，则意味着模型对初始轮廓极端敏感，即在不同随机初始化下输出结果差异显著；反之，若ΔIoU 接近于 0，则表明分割过程具有较好的稳健性和可重复性，在本评价模型中，此值构成指标C_4。

这种基于扰动的评估方法可量化描述模型的收敛可信度，并与其他分割精度指标（如平均 IoU 或 Dice）共同使用，以全面分析 ACM 在实际应用中面临的不确定性和鲁棒性问题。该方法直观且易于实现，能够揭示模型对参数与初始化的依赖性，提供重要的诊断参考。

4.3.3. 高效性

在类似于 ACM 这种迭代循环的图像分割算法中，常常以“迭代步数×单次迭代时间”评估算法的时间效率与实时性。该指标定义如下：

$$T_{\text{total}} = N \times t_{\text{iter}}$$

其中N表示算法完成收敛或达到停止条件所需的总迭代次数，t_{iter}为每次迭代的平均时长（以秒计）若定义收敛条件为某时刻曲线能量变化率小于阈值ϵ，则总体评估可以写成：

$$T_{\text{total}} = N \times \left(\frac{1}{N} \sum_{i=1}^{N} t_i \right)$$

这一乘积反映了算法实际运行所需的时延，用于评价模型的时间复杂度在真实环境中的表现，在那本模型中，此数据构成评价指标$C_5 = 1 \big/ T_{\text{total}}$。

4.4. 评价指标的权重构建

4.4.1. 熵权法与层次分析法的融合

在多指标综合评价问题中，合理确定各指标的权重是确保评价科学性与准确性的关键步骤。常用的权重确定方法主要包括主观赋权法与客观赋权法。其中，层次分析法（Analytic Hierarchy Process, AHP）属于典型的主观赋权方法，依赖专家经验判断；而熵权法（Entropy Weight Method, EWM）则是一种基于样本信息离散程度的客观赋权方法。本文结合两种方法的权重结果进行融合，以实现主客观权重的统一协调，从而提升模型的鲁棒性与可信度。

Step 1：客观权重与熵权法

熵权法利用信息熵衡量指标数据的离散程度，其离散性越大，指标提供的信息越多，其权重应相应较高。假设评价对象有m个，评价指标有n项（在此$n=5$），院士数据矩阵为$X = (x_{ij})_{m \times n}$，经过无量纲化处理后得到归一化矩阵$P = (p_{ij})$：

$$p_{ij} = \frac{x_{ij} - \min(x_j)}{\max(x_j) - \min(x_j)},\ i = 1, 2, ..., m,\ j = 1, 2, ..., n$$

计算第j个指标的信息熵e_j为：

$$e_j = -k\sum_{i=1}^{m} p_{ij}\ln(p_{ij}),\ 其中 k = \frac{1}{\ln(m)}$$

熵值越小说明信息量会相应越大，据此可以计算冗余度$d_j = 1 - e_j$，再归一化得到相应的客观权重值w_j：

$$w_j = \frac{d_j}{\sum_{j=1}^{n} d_j}$$

Step 2：主观权重与层次分析法

层次分析法通过构建判断矩阵

$$A_{ij} = \begin{pmatrix} 1 & a_{12} & \cdots & a_{1k} \\ 1/a_{12} & 1 & \cdots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1/a_{1k} & 1/a_{2k} & \cdots & 1 \end{pmatrix}$$

其表达了专家对于指标相对重要性的主观评价。判断矩阵需满足一致性条件，通常采用 1~9 标度进行赋值。特征向量w作为指标权重向量，可通过如下公式计算：

$$Aw = \lambda_{\max} w$$

其中$\lambda_{\max}$为判断矩阵的最大特征值，然后计算一致性指标 CI 与已执行比例 CR：

$$\mathrm{CI} = \frac{\lambda_{\max} - n}{n-1},\ \mathrm{CR} = \frac{\mathrm{CI}}{\mathrm{RI}}$$

当 CR<0.1 时认为一致性可接受。

Step 3：加权融合策略

为兼顾主观判断与客观数据特征，可将 AHP 与 EWM 进行加权融合。设w_j^{AHP}与w_j^{EWM}分别表示两种方法计算的第j项权重，则综合权重可表示为：

$$w_j^{\mathrm{total}} = \alpha \cdot w_j^{\mathrm{AHP}} + (1-\alpha)\cdot w_j^{\mathrm{EWM}},\ 0 \leqslant \alpha \leqslant 1$$

其中为融合参数，表示主客观权重所占的比例。可依据具体图像分割的问题背景设定或通过熵法结果对专家权重做修正，进一步引入一致性度量和加权偏差项实现自适应融合。既可以充分利用到本情境中分割不同目标的需求差异，以及众多数据点的客观条件。

4.4.2. TOPSIS 优劣解距离法

多属性决策方法 TOPSIS（Technique for Order Preference by Similarity to Ideal Solution）是一种经典的排序型决策方法[4]，其基本思想是：最优方案应当是距离正理想解最近、距离负理想解最远的方案。该方法不依赖于属性之间的分布特性，适用于处理具有多个评价指标的问题，近年来逐渐被引入图像分割模型的性能评价及多阈值分割权重计算等领域。其求解步骤呈现如下：

1、构造归一化决策矩阵

给定有 m 个方案，n 个评价指标构成的决策矩阵$X = (x_{ij})_{m\times n}$，由于不同指标量

纲、数量级差异大，需要归一化消除影响。通过下面公式，可以将原始评价值转化为无量纲的相对值，使得个指标出于同一个可比较的尺度，便于后续分析。

$$r_{ij}=\frac{x_{ij}}{\sqrt{\sum_{i=1}^{m}x_{ij}^{2}}}$$

2、引入指标权重，构建加权归一化矩阵

在此处参考前文叙述的“层次分析法+熵权法”所构造的权重列表（w_1~w_5）利用公式$v_{ij}=w_j\cdot r_{ij}$构建加权矩阵，让会议华后的数据融入权重信息，突出关键指标对方案评价的影响，使得后续理想解的计算更加符合实际需求。

3、确定正理想解与负理想解

正理想解是各指标“最优值”的集合，负理想解则相反，是各指标“最劣值”集合，以之作为参照，衡量方案与“最优”“最劣”的接近程度。

$$A^{+}=\{\max v_{ij}|\ j\in J^{+};\ \min\ v_{ij}|\ j\in J^{-}\}$$

$$A^{-}=\{\min\ v_{ij}|\ j\in J^{+};\ \max\ v_{ij}|j\in J^{-}\}$$

4、计算方案到正负理想解的距离

随后利用欧式距离公式计算第i个方案到正理想解的距离D_i^{+}和到负理想解的距离D_i^{-}。此距离反映方案与理想状态的偏离程度，D_i^{+}越小、D_i^{-}越大，说明方案月接近最优，其效果越好。

$$D_i^{+}=\sqrt{\sum_{j=1}^{n}(v_{ij}-v_j^{+})^{2}},\ D_i^{-}=\sqrt{\sum_{j=1}^{n}(v_{ij}-v_j^{-})^{2}}$$

5、计算相对贴近度并排序

相对贴近度的定义式如下：

$$C_i=\frac{D_i^{-}}{D_i^{+}+D_i^{-}}$$

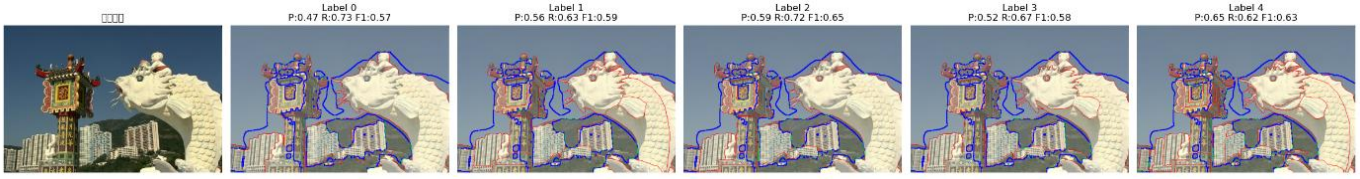
它可以综合考量方案与正负理想解之间的距离关系，取值在[0,1]间。C_i越大，说明方案越接近正理想解，远离负理想解，据此指标对所有方案排序，既可以筛选出最优的决策方案。

5. 基于数据集 BSDS500 的模型比对评估

5.1. 数据集特征分析

5.1.1. BSDS500 数据集

BSDS500 包含 500 张真实的自然场景图片，每张图片由平均五位被使者手工分割标注，行程高质量的多样性人工标注“groundtrue”边界。这些标注覆盖不同视觉语义层面，包括主要物体的轮廓、内部解耦边沿以及北京纹理边缘。相较于传统的单物体的目标检测边界分割问题，可能会**有边界形状多样、图像最外侧轮廓不存在、边沿曲线不**



封闭、物体包含于嵌套关系等等问题。对于传统的 ACM 活动轮廓问题会存在诸多不变，故本文尝试了一种全新的改进方式，以及针对本数据集的标签特征，进行评价指标的修正，使得在这种情境下可以更好地对不同模型进行比对与分析。

图 4 数据集的五种不同标注

5.1.2. 相似性模糊化处理

考虑到数据集的标签多为人工标注的线条，而并非严格封闭闭合的曲线，故考虑将问题一中提出的评价模型做适当更正，即保留原先召回率与精确率的原始定义，但将所考虑的原始 Positive 区域定义为有一定像素宽度的边界线，利用一定模糊数学的处理办法，即“模糊图像分割”。

在模糊图像分割中由于边缘线条的宽度有限，一些微小的偏移并不影响整体上的框选效果，但是由于重合像素点过小，会很大程度上导致评价指标发生异常的变化从而影响判断。故在进行精确率与召回率的判断之前，对于每一个像素点，定义其到目标或一直边界曲线的**曼哈顿距离**为：

$$d=\min\{|x_0-x_i|+|y_0-y_i|,(x_i,y_i)\in\Gamma\}$$

根据此距离的大小，阶梯式定义像素点隶属于相应图形的概率值，即在过大程度上可以认为此点属于图像，若$d\leqslant 2$，则$\eta=100\%$，若$2<d\leqslant 4$，则$\eta=50\%$，若$4<d\leqslant 6$，则$\eta=25\%$。由此若令不属于图像的像素点取 0，属于图像的像素点取 1，边界的模糊区域取相应的概率值，则构成了两幅新的灰度化图像。在此处记真实图像为$G(x)$，预测结果为$P(x)$，其中x为像素位置。则此时考虑模糊真阳性TP_f、模糊假阳性FP_f、模糊假阴性FN_f分别取如下值：

$$TP_f=\sum_x\min\{G(x),P(x)\}$$

$$FP_f=\sum_x\max\{0,P(x)-G(x)\}$$

$$FN_f=\sum_x\max\{0,G(x)-P(x)\}$$

此时类比经典公式得到模糊精确率和模糊召回率，使得像素贡献是渐进的，不再粗糙的划分为有/无。

$$C_1=\text{Precision}_f=\frac{TP_f}{TP_f+FP_f},\ C_2=\text{Recall}_f=\frac{TP_f}{TP_f+FN_f}$$

5.2. 基于 Canny 检测的先验 ACM 改进模型

5.2.1. 模型构建思路与原因分析

本文选择自创一种新的 ACM 改进模型（CiSC, Chan-Vese image Segmentation based on Canny detection），其思路与原因分析如下：

首先，在观察本研究所采用的数据集时可以发现，数据标注方式以**稀疏的边缘曲线为主，而非标准的闭合边界**。这使得传统基于封闭轮廓初始化的活动轮廓模型（如采用圆形或矩形初始区域的 Snake 模型）在处理非规则物体（如飞机、树木或动态人物姿态）时，会出现迭代路径难以迅速收敛、初始化区域覆盖错误等问题，影响分割效果和计算效率。因此，**本文采用 Canny 边缘检测算法作为先验辅助工具**，对目标

区域进行初步轮廓提取，并基于检测到的边缘信息进行初始轮廓的构建与放缩。这种以“形状先验”引导活动轮廓演化的策略，使初始曲线更贴近真实目标轮廓，从而有效提高分割模型的收敛速度和精度。

其次，本文并未采用传统 Snake 模型进行基础架构的扩展与微调，而是选择在**Chan-Vese 模型**基础上进行改进，其原因在于以下两个方面：

（1）通过对数据集中图像样本的观察可知，许多目标物体与背景之间的**灰度梯度变化不明显**，例如天空、草地、水面等场景中存在大量模糊边界，导致以梯度驱动的 Snake 或 GAC（Geodesic Active Contour）模型难以准确捕捉到实际边界，而分割效果远低于人眼识别结果。

（2）此外，传统 ACM 模型往往假定目标具有规则拓扑（如单连通圆形区域），而数据集中大量目标具有**复杂拓扑结构**，如带孔洞的物体、交叉的枝叶、伸展的人体轮廓等。为处理这类多拓扑情形，本文采用基于水平集方法的 Chan-Vese 模型作为分割主干，其在处理非规则、非同构结构目标方面具备天然优势，能自动处理拓扑变化，无需手动调整轮廓结构。

最后，正如图 3063.png 中所示（图 10），在该图中前景飞机的结构与背景蓝天、白云之间具有显著的语义差异与形状对比。然而，从图像梯度信息角度分析，背景中的云层与天空边缘会因亮度变化产生强梯度响应，这极易导致传统基于梯度的模型将背景部分错误纳入目标区域。因此，**本文在分割前对原始图像引入一次高斯模糊操作**，使远景背景中的细碎边缘被抑制，提升目标边缘的相对显著性。这种预处理手段有助于降低伪边缘的干扰，让模型更专注于近景主体的主要轮廓，从而提高整体分割质量。

5.2.2. CiSC 模型改进思路

Step 1：基于 Canny 先验检测

本模型首先采取 Canny 边缘检测这一种经典的图像边缘提取算法作为初始化的先验信息，可以噪声抑制、边缘定位准确性和单响应性之间取得最佳平衡。其基本流程如下：

① 首先对图像进行高斯滤波，抑制噪声：$I_s(x,y)=G(x,y)*I(x,y)$。其中$G(x,y)$是高斯核，$*$表示卷积操作。

② 使用 Sobel 算子估计图像在水平与垂直方向的梯度：

$$G_x=\frac{\partial I_s}{\partial x},\quad G_y=\frac{\partial I_s}{\partial y}$$

其中梯度幅值为$M=\sqrt{G_x^2+G_y^2}$，方向为$\theta=\arctan\left(\frac{G_x}{G_y}\right)$。

③ 随后进行非极大值抑制，即在梯度方向上仅保留局部最大值，细化边缘。

④ 应用双阈值法筛选强边缘与弱边缘，保留高于高阈值的像素作为“强边缘”，低于低阈值的剔除，中间值视为“候选边缘”。

⑤ 最后一步为边缘连接，将与强边缘相连的弱边缘保留，形成完整连续的边缘。

综合以上步骤即可以得到一个与分割物体具有一定相似度的一个初始轮廓，以此作为后续 ACM 变体的初始值。

Step 2：图像高斯模糊处理

同上所述，当图片背景中细节丰富，如草地、树叶、砖墙等，这些区域在梯度计算

中会产生大量的“假边缘”，高斯模糊通过平滑图像，削弱这些高频细节，从而降低误检测率，让前景目标的边界在相对光滑的背景中更突出。其中二维高斯核的参数σ越大，相应的模糊效果就越强。在本模型的实操中应适当选择σ以平衡“去纹理”与“保边缘”这两种操作效果。

Step 3：Chan-Vese 区域模型

在本模型中，出于先前几点原因考虑，选用基于区域的 Chan-Vese 进行改进。承接上文，在此本模型将 Canny 检测识别得到的目标物轮廓作为先验轮廓信息输入，随后将其依照进行了高斯模糊处理的原图像进行活动轮廓分割，详细理论推导见第四大点的论述

5.3. 结果分析与呈现

沿用上述模型构建思路，接入 BDCS500 数据集进行分割尝试，得到的示意图部分呈现如下，其中四张子图分别为原数据集提供的标注、经典 ACM 模型运行得到的轮廓、Caany 边缘检测效果以及本文 CiSC 模型的分割效果示意图，在此依据运行结果，观察并选用三组图片（2018.png、8068.png、35028.png），分别反映本模型相对经典 Snake 的三种明显优势。其中 CiSC 模型分割效果的子图中，蓝色为标注片段、绿色为模型分割与标注“模糊重合”的片段（即像素点到标注曲线的曼哈顿距离小于等于 4），红色为模型分割与标注“不模糊重合”的误差片段。依据这三种颜色部分所含像素点的个数可以计算得到相应的模糊精确率、模糊召回率，本文亦在此将其与前述诸多模型进行对比分析如下。

5.3.1. 优势一：对复杂轮廓物体的分割到位

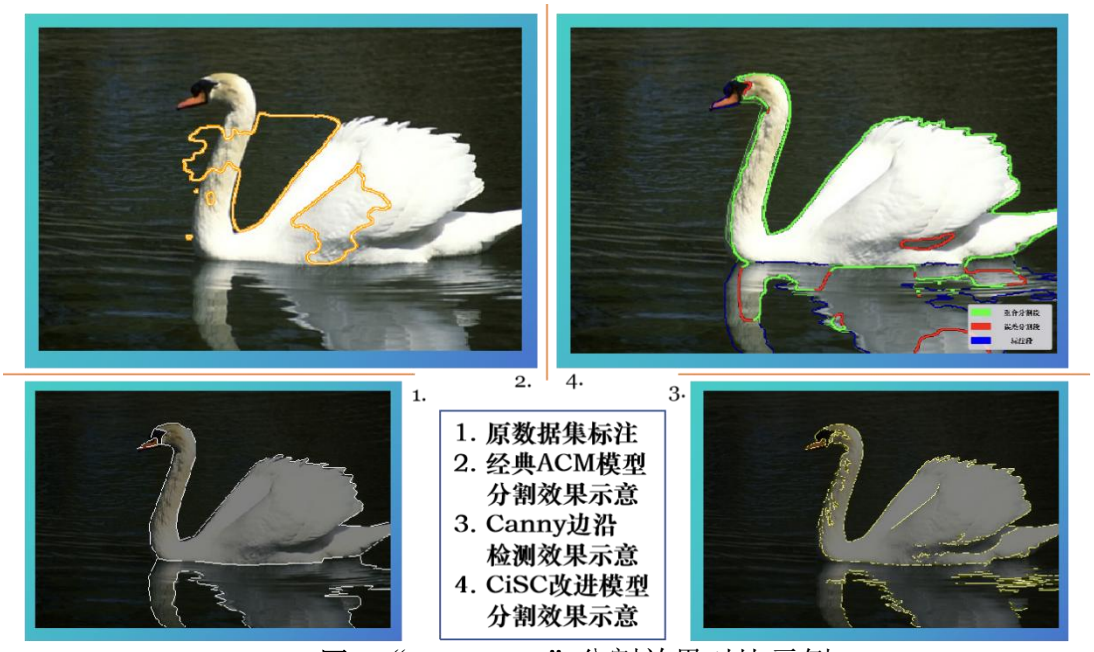


图 5 “8068.png”分割效果对比示例

如图 5 所示，图像左下角展示了数据集中提供的人工标注结果。本文在多个标注版本中，选取对近景目标物体描绘最清晰、边界最合理的一组标注，作为分割性能评价的

参考基准。可以明显观察到，**CiSC 模型相较于传统 Snake 模型的主要改进体现在其对初始轮廓的先验性利用，从而对复杂轮廓物体有很好的分割效果**，显著提升了模型的适应性与收敛效率。

如子图 2 所示，当以传统 Snake 模型中的圆形结构作为初始化轮廓时，因其无法准确对齐目标物体的实际位置与结构形态，常导致轮廓框选出现偏移甚至错位，最终引发明显的分割误判。此外，面对目标物复杂、不规则的边界结构，从规则几何形状（如圆形）出发进行轮廓的膨胀与收缩，会引发大量冗余迭代，造成收敛速度下降和计算资源浪费，严重影响分割的效率与精度。相比之下，CiSC 模型借助 Canny 算子获取一定程度上更接近真实边界的初始轮廓，从而在模型演化初期即具备较高的几何一致性与空间对齐性，具体的性能对比与迭代耗时分析详见后文的数据统计与评估结果。

同时，我们也发现，CiSC 模型在水面之上的物体分割效果极好，在水面之下相对模糊的部分仍然存在一定不足，经过观察可以明显发现其收到光线的影响极大，水下亮色部分可以很好的分割，暗色部分由于与水面本身颜色相近，虽然人肉眼容易判断其轮廓，但分割模型难以辨别，故仍存在一定缺陷。

5.3.2. 优势二：对于边界模糊的目标物辨别准确

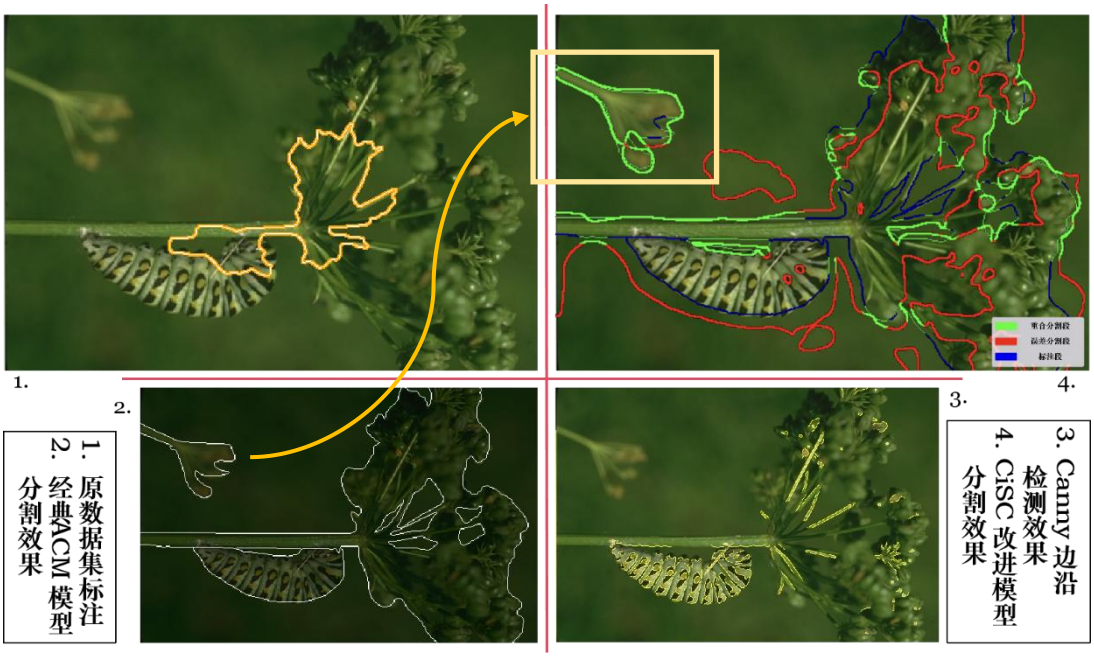


图 6 “35028.png”分割效果对比示例

相比之下，本文提出的 CiSC 模型在处理该类图像时表现出更强的适应能力。**模型基于 Chan-Vese 的水平集结构，对于模糊边界过渡辨别良好。使得即使在梯度信息微弱的区域，也能维持边界能量驱动的连续性，从而有效避免因边缘信号不明显而导致的目标遗漏。**如子图 3 所示，CiSC 成功检测并分割了左上角的模糊物体区域，展现出其对弱边界结构的鲁棒性。

此外，从子图 4 中“小虫子”区域的分割细节也可以发现，该模型在迭代次数设置上的灵敏性较高。由于图像整体灰度差异较小，导致模型中基于梯度的“外力项”作用值偏弱，从而使得轮廓演化速度下降。子图中红色分割轮廓虽展现出良好的轮廓趋势，但由于迭代轮数不足，尚未完全收敛至目标边界，提示在该类图像中应适当延长演化过程以获得更精确的分割结果。

5.3.3. 优势三：对复杂拓扑结构分割准确

如图 7 所示，子图 1 展示了原始数据集中提供的标注结果，本文特意选取其中一组具有显著拓扑复杂性的样本作为分割效果评估的标准。该标注中不仅存在外部主轮廓与多个内部子轮廓之间的嵌套关系（典型的父子拓扑结构），且由于目标物体为鞋类，具有明显的镂空结构，其轮廓边界存在多个孔洞和不规则的闭合区域，增加了分割的难度。子图 2 展示了传统 Snake 模型在该图像上的分割表现。可以观察到，由于图中边缘数量密集，梯度方向变化剧烈，传统模型在处理初始轮廓受到的外力时表现出明显不稳定，导致轮廓演化过程受干扰显著，虽然理论上 Snake 模型支持一定



1. 原数据集标注　2. 经典ACM模型分割效果　3. Canny边沿检测效果　4. CiSC改进模型分割效果

的拓扑演化能力，但在本案例中，其实际表现较差，结果呈现明显误分割与边界偏移现象。

图 7 “2018.png”分割效果对比示例

相比之下，**本文提出的 CiSC 模型在子图 4 中对复杂拓扑结构表现出更强的适应能力与边界对齐能力。**这得益于其基于 Canny 边缘检测所构建的初始轮廓形状先验，在空间上更贴合真实目标的位置与形态，显著降低了初始化误差。同时，得益于对原始图像应用的高斯模糊操作，有效削弱了背景中冗余细节与伪边缘的干扰，保证了近景目标的清晰分割。在子图 4 中还能观察到图像远处的高山轮廓被模型检测出来，说明 CiSC 对像素灰度变化具备较高敏感性。但与此同时也暴露出该模型缺乏对图像语义层次与整体结构趋势的理解能力，这一问题将在本文后续提出的第三阶段模型中加以改进与解决。

5.3.4. 评价指标数据呈现

表 3. CiSC 模型与 ACM 模型运行效果数据

模型\指标	模糊准确率 C1	模糊召回率 C2	HD 距离 C3	轮廓敏感性 C4	总耗时 C5
CiSC	0.2646 ↑	0.3598 ↑	138.5228 ↓	0.0095 ↓	7.95 s/张 ↓
ACM	0.2106	0.1921	164.6363	0.3871	≈ 75 s/张

增/降幅比例	25.64%	87.30%	15.86%	97.54%	89.40%

综合上述分析，本模型的优势与特点均在数据上得到体现：其中 CiSC 模型的模糊准确率Pr_f为 0.2646，高于 ACM 模型的 0.2106，**增幅约为 25.87%**。这表明 CiSC 模型预测的分割轮廓中，正确的像素比例更高。模糊召回率Re_f为 0.3598，高于 ACM 模型的 0.1921，增幅约为 87.30%，说明 CiSC 模型能更全面地找出所有真实的目标边界，查全能力接近 ACM 模型的两倍。此外，HD 距离、轮廓敏感性与迭代总耗时的大幅度减小，均得益于 Canny 边缘检测带来的先验轮廓，用更精确地初值来帮助减少迭代次数、提高分割效率。

6. 融合深度学习网络的 CiSTN 模型构建”

6.1. CiSTN 模型构建

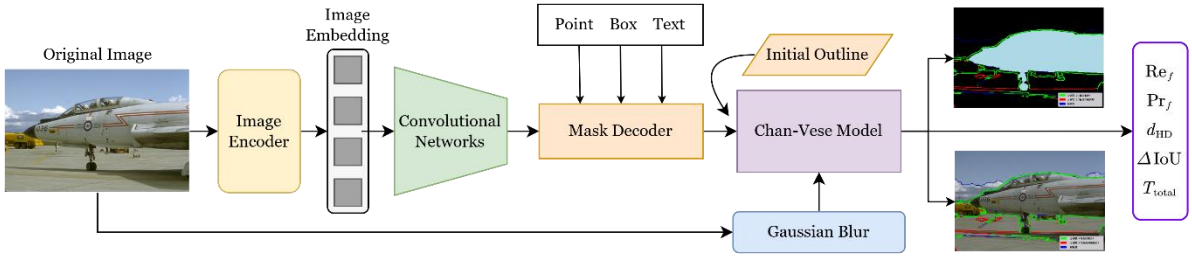
6.1.1. 建模思路分析

由问题二中的分析可知，Canny 边沿检测虽然对于图像中的快速梯度下降边沿有较强的敏感性，但是其突出的缺陷在于缺乏对于物体宏观特性以及从语义层面上来整体理解目标去提的能力，导致前文中生成的图像轮廓多是单纯描绘特征突出的曲线，而非分割具有完整语义的物体。故本文在此，考虑引入具有语义分割能力的 Transformer 神经网络辅助 Chan-Vese 模型进行活动轮廓的拟合与演化，用神经网络运行得到的掩膜替代 CiSC 中使用的 Canny 检测算法，并将提供给 Chan-Vese 模型，利用同样经过高斯模糊的图像，对初始轮廓进行膨胀与缩放。值得一提的是，借助于 Transformer 的自然语言处理的特性，本模型还可以实现人为提示下对于掩膜的精确提取，即获得的目标是满足我的提取任务需求的，这也是一种对于 BSDS500 数据集多目标多主体的特点的补充应对。

6.1.2. 网络模型结构分析

为了满足上述图像分割任务中对于目标整体性与完整性的需求，本文设计了一个具备高扩展性与语义完整性的深度学习 transformer 网络模型 CiSTN（Chan-Vese image Segmentation based on Transformer Network）。**核心思想是利用 SAM 模型基于用户提示生成的掩膜作为轮廓初始化的结构性先验，以此引导 ACM 模型更稳定、高效地向真实目标边界演化。**

该模型中的神经网络结构由三个关键组件组成：图像编码器、提示编码器与掩膜解码器，其设计遵循模块解耦、交互高效、结构可组合的原则。其中，图像编码器通过一个 MAE（Masked Autoencoder）预训练 ViT 结构对整幅图像进行一次性全局特征提取，生成高维嵌入图用于后续提示融合[5]；提示编码器则将用户提供的提示信息



（点、框、掩膜）转化为空间嵌入向量，与图像特征共同输入到解码器中进行交叉融合；掩膜解码器则以双向 Transformer 注意力结构为核心，通过 prompt-to-image 与 image-to-prompt 的交互注意力机制生成分割掩膜，支持多候选输出与 IoU 预测评分。

图 8 CiSTN 模型结构框图

通过对 SAM 生成的高质量掩膜进行边界提取与轮廓变换，即可获得一组紧贴真实目标边缘、形状结构合理的初始轮廓线，该轮廓不仅包含拓扑结构信息，还具备较强的空间一致性，显著优于传统 ACM 中使用的手动圆形或矩形轮廓。进一步地，这一轮廓还由于神经网络模型的语义功能能够更加精确地识别完整的物体。另外由于神经网络在预训练之后进行运行具有极快的速度，相较于 Canny 利用算子处理图像的复杂运算过程，更加快速高效，所以说在水平集演化框架中直接嵌入相应掩膜后，可显著缩短轮廓收敛时间，提升能量泛函优化效率，并减少模型在局部极小点陷入的可能性。即实现所谓模型的**“高效性”**。

此外，SAM 模型对低对比度图像、边界模糊区域也具有较好的处理能力，这使得其作为“初始化器”特别适用于 BSDS500 等复杂图像数据集。实验结果亦验证：融合 SAM 结构作为先验的 CiSTN 模型，在迭代次数、边界 IoU 指标及误分割率等方面，均优于未引入结构先验的传统 ACM 方案。

6.2. 模型分割效果呈现

6.2.1. 模型分割实例分析

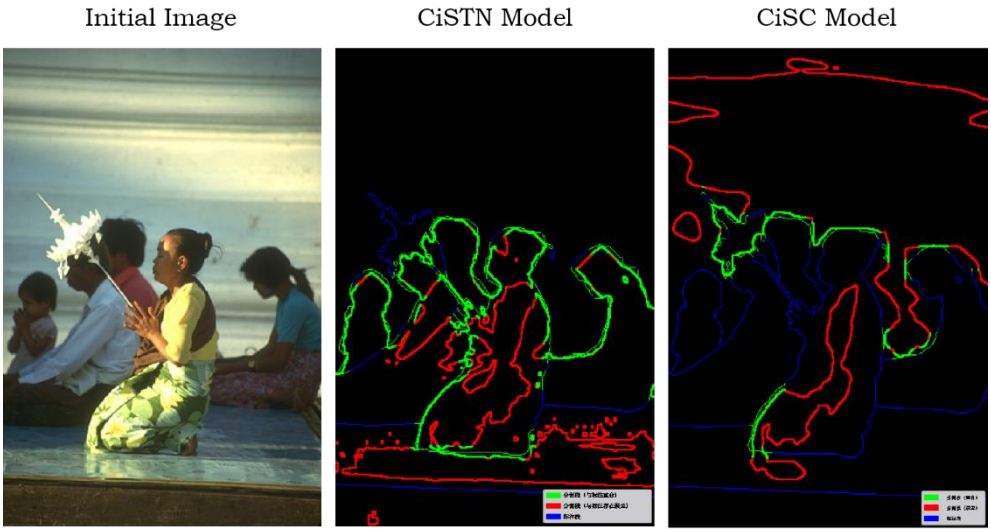


图 9 “20069.png”分割效果示例

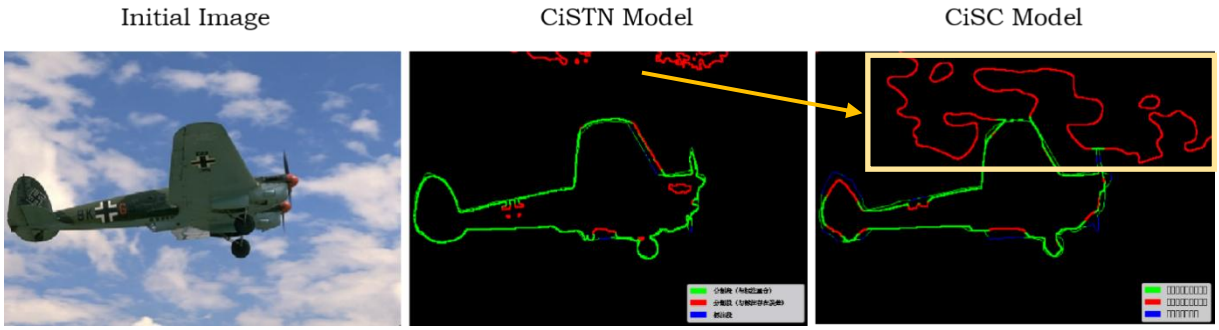


图 10 “3063.png”分割效果示例

如图 10 所示，本文对比了所提出的两种改进模型 CiSC 与 CiSTN 在实际图像分割任务中的表现。以图像样本 3063.png 为例，该图像中近景目标物体轮廓清晰且结构突出，两种模型均能准确提取目标边界，实现较为理想的分割效果。然而，进一步分析显示，CiSTN 在处理背景中具有类似梯度特征的无关图像元素（如天空中的白云）方面表现更具优势。CiSC 模型依赖于 Canny 边缘检测获取初始轮廓，虽然对前景边界具有良好响应，但也可能错误提取背景中光照变化较强的区域，如蓝天与白云交界处，导致模型误将非目标区域划入前景，出现分割偏差。相比之下，CiSTN 模型基于深度学习结构，具备一定语义理解能力，其初始轮廓由语义嵌入控制生成，能有效区分具备实体语义的目标与缺乏结构完整性的背景元素。因此，**所以说本模型可以较好地处理复杂环境中近景目标物的轮廓分割，最大限度地减少背景中杂乱边缘的干扰。**

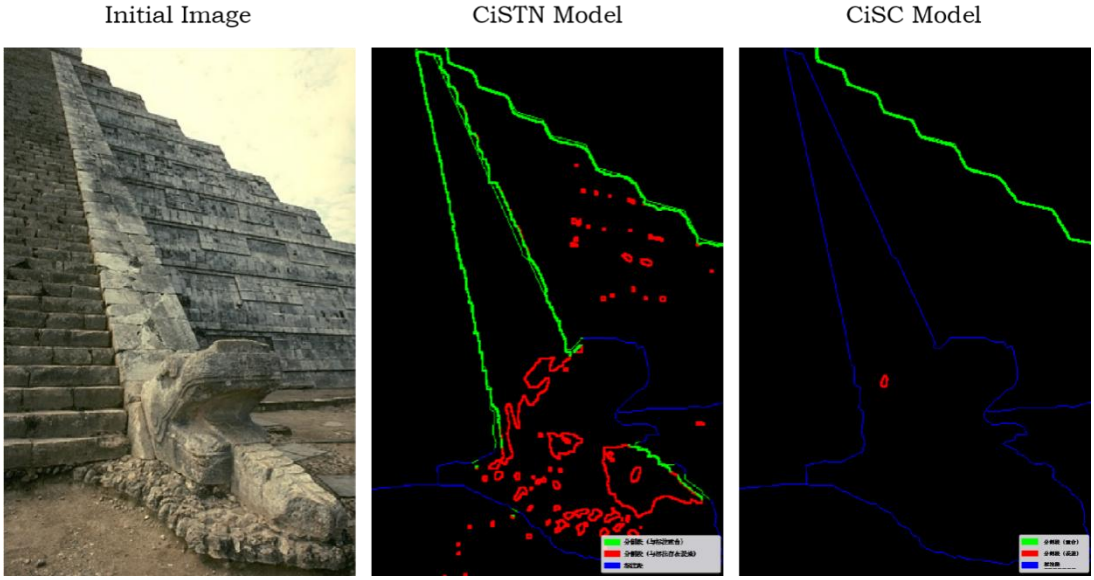


图 11　“33044.png”分割效果示例

如图 11 所示，在处理近景目标中存在模糊边界或轮廓不明显区域的图像时，CiSTN 模型展现出优于 CiSC 的分割性能。这一优势主要得益于 CiSTN 模型在结构上融合了深度语义理解能力，使其不仅依赖于局部像素梯度变化，还能结合全局语义信息对目标边界进行推理与补全。例如在图中金字塔结构的边缘区域，虽然局部灰度变化缓慢、边界模糊，传统的基于梯度的 CiSC 模型未能完整检测目标，但 CiSTN 仍准确描绘出其结构轮廓，表明其对于模糊目标的感知能力更为精细。该特性使得**本模型在实际应用中更适用于处理边界不清晰、轮廓连续性差的复杂目标。**

6.2.2. 数值数据呈现

表 4.　CiSTN 模型与前两种模型运行效果数据比对

模型\指标	模糊准确率 C1	模糊召回率 C2	HD 距离 C3	轮廓敏感性 C4	总耗时 C5
CiCTN	0.2858	0.5644	126.6342	0.0054	3.2400
CiSC	0.2646	0.3598	138.5228	0.0095	7.9500
ACM	0.2106	0.1921	164.6363	0.3871	75.0000

在本研究中，我们提出的 CiSTN 模型相较于 CiSC 和 ACM 模型展现出了显著的高效性。这种高效性主要体现在处理速度和分割精度上。首先，CiSTN 模型的总耗时仅为 3.24 秒每张图像，远低于 CiSC 的 7.95 秒和 ACM 的 75 秒，这表明 CiSTN 在计算效率上具有明显优势。这种高效率得益于 CiSTN 模型中深度学习网络的引入，该网络能够快速生成高质量的分割掩膜，从而显著缩短了轮廓收敛时间。

其次，在分割精度方面，CiSTN 的模糊准确率和召回率分别为 0.2858 和 0.5644，均高于 CiSC 和 ACM 模型。这意味着 CiSTN 能够更准确地识别和分割图像中的目标物体，同时减少漏检和误检。此外，CiSTN 的 Hausdorff 距离为 126.6342，低于 CiSC 和 ACM，进一步证明了其在边界精度上的优势。

最后，CiSTN 的轮廓敏感性为 0.0054，远低于 CiSC 和 ACM，表明其对初始轮廓的敏感性更低，从而具有更好的稳健性和可重复性。这种低敏感性使得 CiSTN 在面对不同初始条件时，能够保持稳定的分割性能，这对于实际应用中的模型部署尤为重要。

综上所述，CiSTN 模型通过融合深度学习和传统图像处理技术，实现了在图像分割任务中的高效性和高精度，为复杂图像数据集的处理提供了一种新的解决方案。

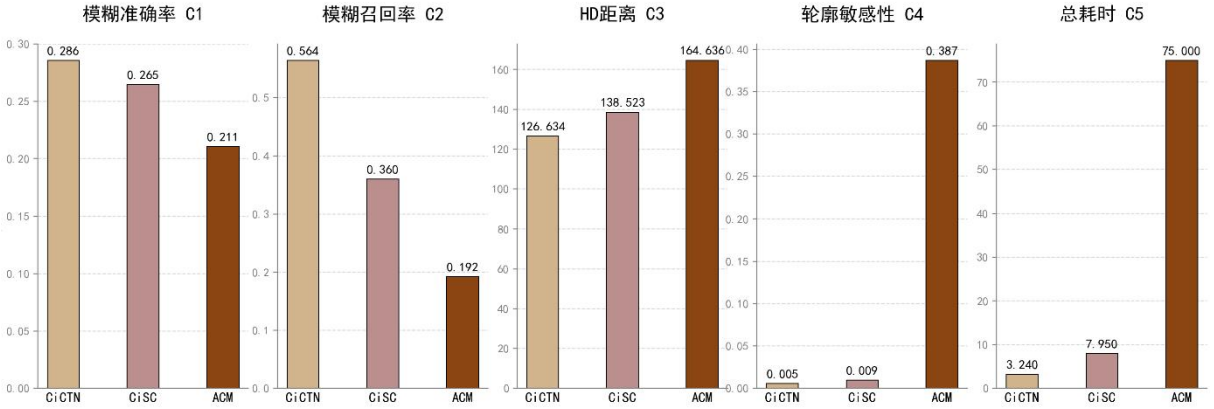


图 12 三种模型在五个不同指标下的数值对比

7. 总结与展望

7.1. 评估与评价

7.1.1. 模型优势

在此综合前文所述，本模型具备以下的三点独特的优势：

首先，依托于深度学习强大的语义提取能力，模型**具备完整的语义理解能力，能够对图像中的目标物体进行宏观层面的准确分割**，即使在存在复杂背景或光照变化干扰的情况下，也能有效避免由独立边缘误导造成的轮廓失真问题。

其次，模型**对于梯度变化缓慢的模糊边界具有较高的识别能力**，能够模拟人眼的视觉感知机制，从视觉连续性和上下文信息中提取出真实的前景与背景分界，尤其在低对比度图像中表现出色。

最后，通过引入具备结构先验的轮廓作为活动轮廓模型的初始化，**显著提升了模型在处理复杂拓扑结构目标时的表现能力**。借助这一轮廓先验，模型能够在迭代过程中快速收敛于真实边界，不仅提高了轮廓拟合的精度，还显著减少了演化所需的计算时间，整体分割效率更优。模型劣势

7.1.2. 模型劣势

1、模型对图像噪声极为敏感，噪声存在时易导致轮廓偏差或断裂；

2、模型语义识别能力不足，对于纹理相似或语义复杂区域难以准确区分，需引入更强的上下文感知机制以进一步提升精准度。

7.2. 拓展与应用

本文提出 CiSC 与 CiSTN 模型，在复杂场景图像分割中表现出卓越性能。医学影像处理中，CiSTN 能精确分割模糊边界及复杂拓扑，实现 CT/MRI 肿瘤与器官轮廓的高效提取，提升诊断准确性。自动驾驶场景下，两模型可在光照变化与背景干扰条件下实时分割道路标识、行人及障碍物，具备良好鲁棒性。遥感影像分析中，模型精准分割非规则地物边界，助力土地利用分类与灾害监测。未来，将通过轻量化网络结构与参数优化，实现边缘设备部署，并结合多模态数据扩展至三维及视频序列分割。通过开源模型与行业标准对接，CiSC 与 CiSTN 有望在智能制造、虚拟现实及安防监控等领域广泛应用，为复杂图像分割提供高效、可靠的解决方案。

8. 参考文献

1. Xu C Y, Prince J L. Gradient vector flow: A new exteral force for active contour modelsUl. ComputerVision and lmage Understanding, 1998, 71(1): 66-80.
2. Caselles v, Kimmel R, Sapiro G. Geodesic active contoursU].international Journal of ComputerVision,1997,22(1):61-79.
3. Chan T F, Vese L A. Active contours without edgesUl. lEEE Transactions on lmage Processing, 200110(2): 266-277.
4. Hwang C L, Yoon K. Multiple attribute decision making: Methods and applications[Ml. Beijing:Tsinghua University Press, 1981.
5. Kirillov A, Mintun E, Ravi N, et al. Segment Anything[J/OL]. 2023, arXiv:2304.02643 [2025 - 07- 06]. DOI:10.48550/ARXIV.2304.02643.