“防患未然”——基于分组拟合与风险惩罚优化的NIPT最佳检测时间预测模型

摘要：

本文针对**NIPT检测**中因个体差异导致的胎儿染色体浓度预测不准、检测时点选择不佳及胎儿异常判定困难等核心问题，整合**相关性分析、分式建模、聚类算法、XGBoost集成学习与多目标优化**等方法，构建了一套覆盖检测全流程的综合模型体系，为临床实现早发现、低风险的个性化产前筛查提供了科学依据。

为保障数据可靠一致，在完成传统数据预处理步骤（重复行检查、缺失值剔除、基于IQR的异常值筛选）的基础上，本文进一步展开针对性清洗预处理：①关键数据“BMI”与“GA”复算检验；②针对同一孕妇多次检测中的不一致静态指标（如年龄、怀孕次数等），采用众数填充进行修正，无法修正者予以剔除。经上述处理，最终男胎、女胎有效数据保留比例分别为 **96.12%** 与 **84.30%**，为后续建模提供了高质量的数据基础。

针对问题一，本文首先对“Y染色体浓度”“BMI”“GA”进行相关性分析，依据斯皮尔曼相关系数得知Y染色体浓度与BMI呈显著负相关（相关系数=**-0.15**）；在此基础上，针对“GA”引入**Fisher's Z** 变换的分组整合相关性分析法，得知Y染色体浓度与GA呈显著正相关（相关系数=**+0.51**）。同时，基于生理学意义完成模型构建，模型与相关性分析结果相符。此后，交替分组求解参数。从拟合结果看，**R^2=0.8169**，残差呈现均值为零的典型正态分布，拟合效果极佳。最后，通过**Meta分析法**（包括加权整合、Z检验和异质性检验）对模型进行显著性检验，结果均通过，模型高度显著（$p<0.01$），反映出模型的拟合效果优异。

针对问题二，本问模型构建基于问题一模型反解的理论最优检测时点，引入“Y染色体浓度”预测残差的标准差量化不确定性；利用融合 “过早检测准确率低”、“过晚检测风险高” 两因素的分段损失函数与惩罚项std，构建**风险最小化目标函数**。此后，模型求解采用层次聚类确定孕妇最佳分组数为3组；确定组数后，利用 **K-Means 算法**确定分组边界: [20.7,32.2]，(32.2,38.2]，(38.2,46.9]；确定边界后，利用添加约束条件的差分进化算法解得各组最佳检测时点为 GA=[68,69,72] 天。最后，敏感性分析基于**TOPSIS熵权法与变异系数**，计算个人扰动标准差并施加相应的扰动，决策结果变化仅为**7.6%**，可见模型稳健。

针对问题三，为综合考虑多因素，采用 **XGBoost** 集成学习算法，引入年龄、操作误差等多维度特征，拟合第一问预测“Y染色体浓度”所得残差，计算得到每个个体残差算术平均值，进而得到“纠偏后”的每人“Y染色体浓度预测值”，带入第一问模型反解GA，后续操作与问题二完全一致，所得结果显示：拟合效果更好（风险函数收敛值减小**15.81%**）、稳健性增强（扰动对决策结果影响减小**2.79个百分点**）、平均收敛速度加快（提升**26.67%**）。可见优化模型多方面性能优异。

针对问题四，首先，对特定数据进行整合处理。之后，运用**PCA**取解释性排名前十的主成分，运行**XGBoost**拟合预测“染色体的非整倍数”。最后，对混淆矩阵进行计算分析，得到预测结果，总体准确率为99.41%，效果极佳。

本模型连贯性强，敏感性分析方法独特，风险损失函数设计科学，后续可集成至妇幼健康智能诊疗平台，为产前筛查提供个性化决策支持，其核心方法还可推广至肿瘤早筛、慢性病管理等健康风险管理领域，具备广泛的临床应用前景。

关键词：Meta分析，XGBoost集成学习，风险最优化，斯皮尔曼相关系数，PCA

1. 问题背景与概述

1.1. 问题背景

在当前的产前检测技术中，NIPT（Non-invasive Prenatal Test，即无创产前检测）是一种通过采集母体血液、检测胎儿游离的 DNA 片段、分析胎儿染色体是否存在异常的技术方案，目的是通过早期检测确定胎儿的健康状况。

而本文面临问题的核心是解决临床实践中的一对关键矛盾：一方面，NIPT 检测过完会增加治疗风险；另一方面，检测过早可能因胎儿游离 DNA 浓度不足（如男胎 Y 染色体浓度低于 4%）而导致结果不准确。因此，本题要求我们围绕“潜在风险最小化”这一目标，同时考虑孕妇 BMI、怀孕周数、Y 染色体浓度等诸多实际影响因素，对于 NIPT 检测时间点与检测效果，构建数学模型进行量化分析与讨论。

1.2. 题目信息与问题目标

综合题目的诸多信息与要求，可以总结概括为**五大核心信息点**与**四项任务目标**:

信息 1：无创产前检测（NIPT）技术可以通过分析母体血液中的胎儿游离 DNA，旨在早期确定胎儿是否存在染色体异常，以评估其健康状况；

信息 2：NIPT 主要可以检测唐氏综合征、爱德华氏综合征和帕陶氏综合征，分别由 21、18 和 13 号染色体的浓度异常所决定；

信息 3：NIPT 结果的准确性依赖于胎儿性染色体浓度，包括男胎的 Y 染色体浓度需达到或超过 4%、女胎的 X 染色体无异常，才认为结果基本准确；

信息 4：问题的核心矛盾在于存在“早期低风险发现”与“晚期高风险发现”的矛盾 。尽早检测可降低治疗窗口缩短的风险，但可能因浓度不足导致检测不准 。

信息 5：男胎 Y 染色体浓度与孕妇的孕周数及身体质量指数（BMI）紧密相关，且个体差异性大，需要进行合理分组与时点选择；

目标 1：在反映必要的数据特征后，建立胎儿染色体浓度与孕妇孕周数、BMI 等指标之间的定量关系模型，并进行统计显著性检验；

目标 2：针对男胎，以 BMI 为主要分组依据，寻找各组使孕妇潜在风险最小化的最佳 NIPT 检测时点，并分析误差影响；

目标 3：在男胎模型中综合考虑身高、体重、年龄等多重因素及浓度达标比例，给出更精细化的分组与最佳 NIPT 时点，并进行误差分析；

目标 4：针对女胎，综合利用 Z 值、GC 含量、BMI 等多种数据，建立一个能够有效判定胎儿 13、18、21 号染色体是否异常的科学方法；

1.3. 流程图

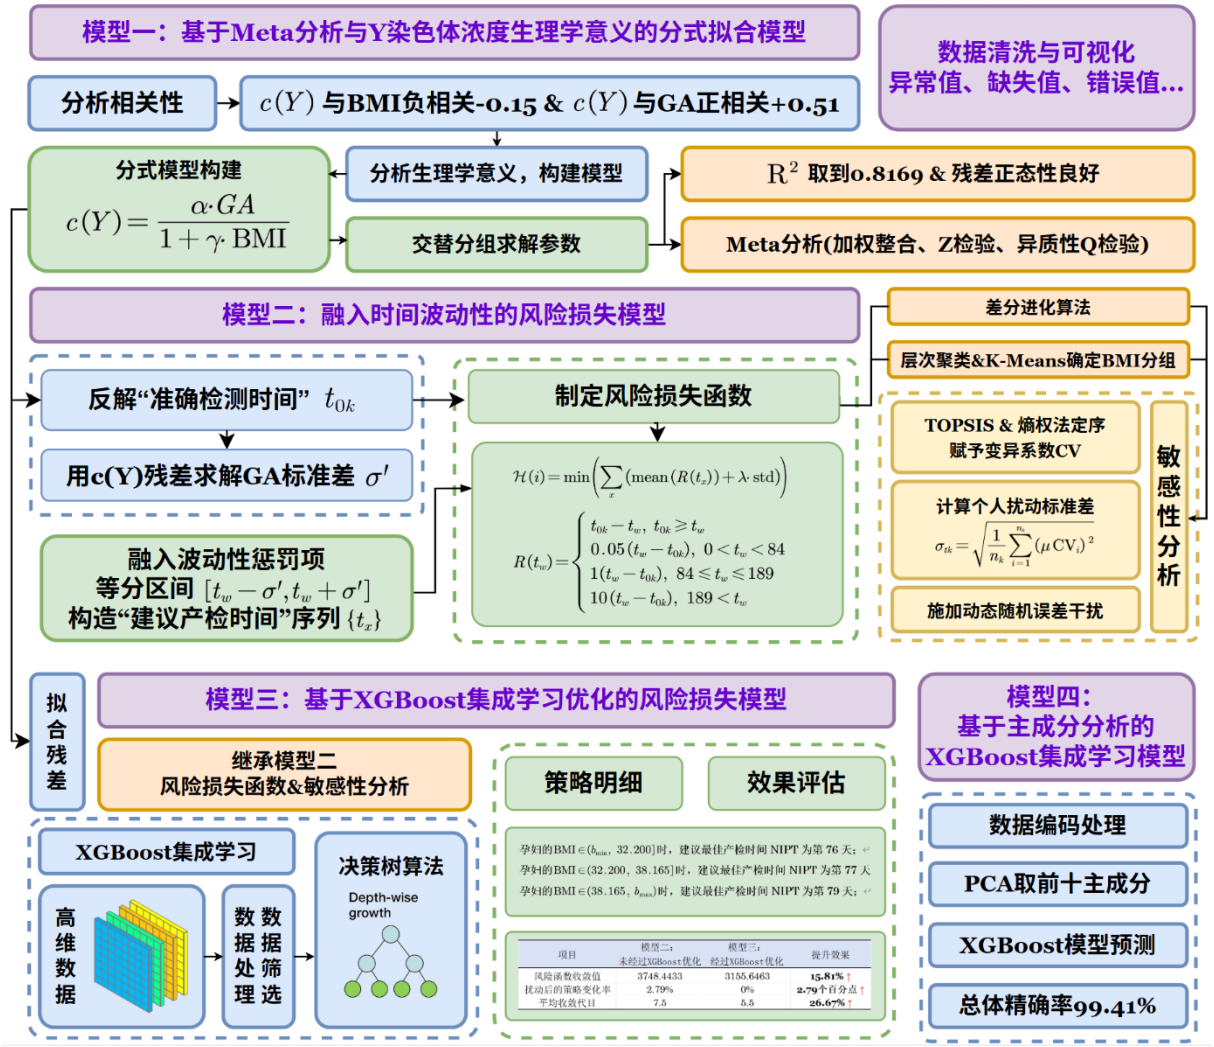


图1 全文整体模型流程图

2. 问题分析

2.1. 针对问题一的分析

由题目信息可知，在正确进行数据预处理的基础上，本题需要解决的任务有三：**首先**，我们需要选用合适的方法，对 Y 染色体浓度和怀孕周期、孕妇 BMI 之间的相关性进行定量的描述分析，结合其生理学含义进行描述与验证；**其次**，我们需要结合相应的数据知识与理论知识构建一个科学的、具有较高可解释性的量化模型，将这三者之间的正负相关关系进行合理的呈现，与染色体浓度$c(Y)$进行拟合；**最后**，还需要针对模型的整体思路和每个参数进行显著性的检验，以确认模型构建与求解的合理性

2.2. 针对问题二的分析

由题目中要求可知，本题的总任务目标是希望寻找到合适的阈值组合，对于每个孕妇个体，能够依照 BMI 数据进行组别的划分。在每一个 BMI 的组别中，希望能为组内用户提供一个最优的的产检时间，能够尽可能平衡解决并避免“早检测的准确性不

足”与“晚检测的治疗风险加剧”两者的矛盾点。

故而模型的构建需要充分考虑到风险函数的定义，相应的算法与优化方向则是希望能够找到最合适的阈值标准组合，并且输出每一个 BMI 组别中最优的的产检时间（孕周 GA 时间），使得对于整体而言的风险损失函数可以实现最小化。

2.3. 针对问题三的分析

由题目信息可知，在本问中的最大特点在于对于数据的综合考量，除了模型二中使用到的 BMI 和孕周时间 GA 数据，还需要额外考虑添加一些其他因素对 BMI 分组判断的影响，例如年龄、升高、体重等等。故需要重新拓展构建新模型或是对原有模型进行补充，使之能够同时容纳多元的影响变量。本文在此选用 XGBoost 决策树模型对任务一中的分式模型进行补充，拟合其预测的残差，使得模型能够更精确地预测得到 Y 染色体浓度，从而得到更精准的预测时间，随后将其再与模型二中的风险损失进行整合，实现多元变量考量下的的更科学的分组阈值确定。

2.4. 针对问题四的分析

本任务是顺延前三个模型所解决的任务而来，具有一定的延展性与探索性，希望能够将前几问中所述的模型进行迁移，尝试解决对于女胎检测数据的染色体异常状况分析。此外，由题目要求，我们需以女胎孕妇的 21 号、18 号和 13 号染色体非整倍体为判断和模型的拟合指标。更重要的是，本文在此需要对前置所有的指标进行尽可能完整的综合考量，所以本问中将化用模型三中复杂度较高的 XGBoost 模型，对相关多维度数据进行独热编码的处理与主成分分析的特征提取，最终实现准确地染色体整合优化。

3. 模型符号汇总与模型假设

3.1. 公式符号汇总

表1 重要公式符号汇总

符号	含义	符号	含义
$c(Y)$	Y 染色体浓度	t_{0k}	第 k 个人的精确检测时间
$\mathrm{sp}_1,\mathrm{sp}_2$	不同对象间斯皮尔曼相关系数	t_{wj}	第 j 组内的建议检测时间
α_i,γ_i	分组参数	σ_Y	残差分布标准差
α_0,γ_0	总参数	σ'	GA 可信标准差
$\delta_{\alpha_0},\delta_{\gamma_0}$	总参数方差	CV_i	变异系数
n_k	第 k 个人的数据点个数	σ_{tk}	数据扰动标准差
Q_α	异质性检验统计量	σ_{tki}	个人扰动标准差
δ_i	效应量方差（Q 检验权重）	$\mathcal{L}^{(k)}$	XGBoost 损失函数
$\mathcal{H}(i)$	完整风险损失函数	ω_j^*	XGBoost 叶子上的权重
$R(t_x)$	风险函数	$(r_{jk})_{n\times n}$	协方差矩阵

3.2. 模型假设

1、假设一：假设本数据集中所有不健康的胎儿都是因为相应的 13\18\21 号染色体片段出现染色体浓度异常所导致；

2、假设二：所有$c(Y)$的测量都存在一定的误差，数据集中的取值表示的是检测得到误差范围内的最优值，可以近似理解为测量操作的平均值；

3、假设三：模型的检测误差可以完全由“总体读段数”等染色体检测指标反映，即相关染色体片段采样质量越高，可以认为检测误差越小；

4. 数据清洗与可视化呈现

4.1. 医学指标概念理解

首先，对于附件中的多主体高维度数据，我们发现存在许多科学性、专业性较强的指标，出于严谨与为后续分析铺垫的目的，我们充分调研查询了其中医学相关术语概念的含义与意义。其中指标一共 31 项，除去序号、身高体重 BMI、检测时间等基础指标外，其余医学采样数据可以划分为以下三类，见下表：

表2 医学专业指标的含义整理

分类	指标	含义解释
测序质量与数量指标	**原始读段数**	原始测序数据中包含的 DNA 片段的总数量
	在参考基因上比对的比例	在全部 DNA 片段中，能够成功定位到人类参考基因组上的片段所占的比例
	重复读段比例	因技术原因产生的重复计算的 DNA 片段占总数的比例
	唯一比对的读段数	能够被唯一、无歧义地定位到参考基因组上的 DNA 片段数量
	过滤读段比例	因质量不佳等原因被过滤掉的 DNA 片段占总数的比例
	GC 含量	评估测序数据质量的重要指标，正常范围在 40%~60%之间
染色体核心指标	**Y 染色体浓度**	男胎的 Y 染色体游离 DNA 片段占总胎儿游离 DNA 的比例
	X 染色体浓度	通过生物信息学方法估算出的 X 染色体浓度，数值可能为负
	若干染色体 Z 值	统计学指标，用于判断特定染色体的数量是否异常
检测结果	**染色体非整倍体**	明确检测出的 13、18、21 号染色体数量异常情况，空白无异常
	胎儿是否健康	婴儿出生后得到的最终健康结果，用于验证 NIPT 检测的准确性

4.2. 数据清洗流程

其次，综合上述对于指标概念的理解，我们对数据进行相应的清洗处理。一共包含六项内容，详细、严谨、周密地清理了数据中不当的成分：重复行、缺失值、BMI 计算、异常极值、错误值与末次月经验算，详细流程呈现如下。

1、重复行检查：

经过筛选比对，发现附件中不存在数据内容完全重复的两行。

2、缺失值剔除：

经过对表格中所有数据的检索和查询，发现“男胎检测数据”中存在 12 个缺失项，“女胎检测数据”中亦存在 8 个缺失项，均为“末次月经时间”。考虑到在后续问题中末次月经时间可能会与怀孕周期有关联需要进行使用，故选择剔除这些缺失值所在行，

3、BMI 值检验：

此外，由于表格中同时提供了身高体重和 BMI 数据，所以也选择基于 BMI 计算公式进行检验，经过单位转换与计算，发现表格中的数据与求得的数据之差在 ± 0.02 的范围内，故可认为无异常值。

4、基于四分位间距 IQR 的异常值筛选：

首先，基于前文中对数据生理学意义的考察，我们发现

①“原始读数段”数值过低说明检测的数据量缺乏，检测结果易失效，同时“唯一比对的读段数”则与“原始读段数”之间的关联性较强，前者取决于后者的数量基数，所以只需要对后者进行异常值筛查；

②“在参考基因上比对的比例”数值过低说明与基因库的重合率低，无效的基因序列过多，故要筛去过低的异常值；

③“重复读段比例”较高说明因技术原因导致的数据冗余会对后续分析有较大干扰，应剔除过高的异常值；

④“过滤读段比例”较高说明有效数据保留过低，应剔除过高的异常值；

⑤“GC 含量”在一定范围内正常[1]，故应同时剔除过高过低的异常值；

针对以上五种指标进行基于四分位间距（IQR）的统计方法，其数学表达式如下：

$$\mathrm{IQR} = Q_3 - Q_1$$

异常值判定阈值为：$[Q_1 - k \cdot \mathrm{IQR}, Q_3 + k \cdot \mathrm{IQR}]$

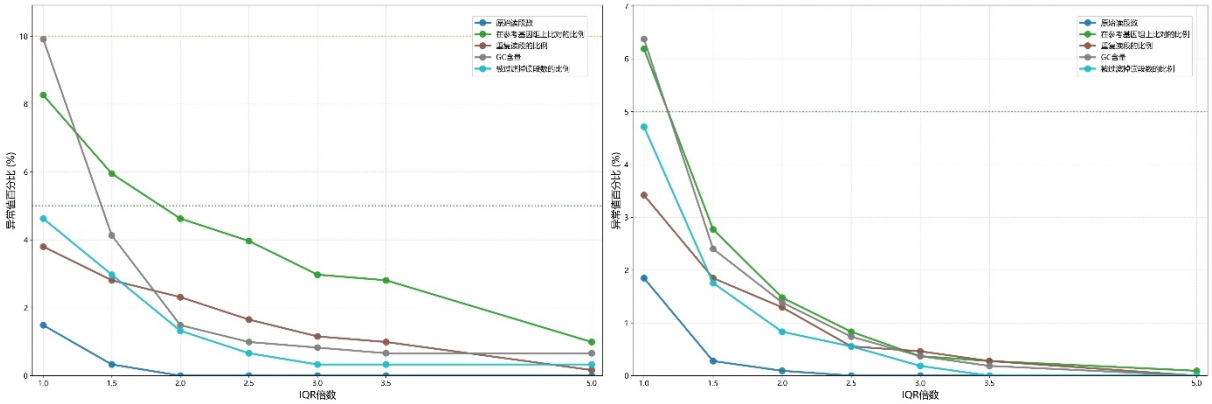


图2 异常值百分比随 IQR 倍数的变化趋势（男胎/女胎）

由上图可知，考虑到折线图取值时普遍使用的肘部法与数据保留量的合理性，本文在此取 IQR 倍数 $k = 3$，删去此时的五种指标的异常值所在行，此时折线图处于肘部位置且异常值比例合理，其中 sheet1(男胎检测数据)删去了 14 行，sheet2(女胎检测数据)删去了 27 行，异常值占比各自为 1.12%和 1.38%，相对科学合理。

5、错误值排查修正：

经过仔细地观察分析，发现男胎检测数据表中检测孕周出现了“16W+1”数据，而非正常的“13w+1”字样，大写的 W 易被代码识别为 NaN 导致后续数据错位，需要在此进行更正。

随后出于严谨性考量，我们检查了相同孕妇代码的多次测验中是否存在一些谬误值，经过细致分析与厂里判断，发现一共有七列可能存在不一致的问题，分别是“年龄”、“末次月经时间”、“IVF 妊娠”、“怀孕次数”、“生产次数”和“胎儿是否健康”。

其中“IVF 妊娠”与“胎儿是否健康”并无错误值出现，不过其余四者均有错误。例如：在一段怀孕的时间内，不同产检间末次月经时间、怀孕次数和生产次数出现有差异，显然不符合常理，需要进行修正或是剔除，考虑到实际情况的多样性与复杂性，以及数据记录时可能出现的失误，本文在此**选择利用同一孕妇代码对应的几个数据的众数作为标准，替代其余错误的数据，若无法找到众数或是众数不少于两个，则直接删去此孕妇的所有数据。**此外，对于年龄，由于在孕期内有年龄的增长属于正常状况，但却不利于后文对孕妇进行分类与分组，此外还出现了一些特殊情况，如孕妇 A009 其年龄随着产检时间的增加从 24 岁变化至 23 岁，故在此选择与前面三者进行同样的处理方法。如此进行处理，可以最大程度上减少错误数据对于后续结论的验证以及模型的拟合预测的干扰，实现了对模型的清洗和不合理之处的规避。

6、末次月经时间比对

经过信息调研与比对，在数据集中我们可以发现怀孕时间 GA 可以由末次月经时间和产检时间推算得到，故本文在此从产检时间处反推得到“理论上的”末次月经时间，此时发现理论与实际的末次月经时间相差较少，只有极少数的孕妇有一定的相差时间（占比 1.92%）。

此时考虑到实际妇产科中的操作方法，衡量怀孕时间会同时考虑末次月经时间与 B 超的形态学图像所分析得出的时间，当两者之间的差异小于一周时往往不进行调整，如果差异大于一周时则会多拍摄几次 B 超，利用多次形态学分析找到最准确的怀孕周期，并以此为准，往往不会更改先前记录的末次月经时间。所以本文在此选择忽略这些少数数据，不进行剔除。而且后文中的模型也并未涉及到将末次月经直接纳入量化指标的操作，故此举可行。

表3 数据清洗最终结果

数据表	修正个数	删除个数	剩余数据行数	剩余数据比例
男胎检测数据	13	4	1040	**96.12%**
女胎检测数据	30	18	510	**84.30%**

4.3. 数据可视化分析

在对数据进行分析与模型的迭代计算之前，应当对数据的呈现与分布规律进行详细地了解与探知，故本文在此有目的性地，将数据集中相关关键数据的分布规律与分布特性进行可视化呈现与分析。

4.3.1. 人物特征描述性统计

表4 描述性统计图（男胎）

指标	均值	标准差	最小值	中位数	最大值	总人数
年龄	28.9231	3.6149	21	29	43	260
身高	161.0885	5.1525	144	161	175	260
体重	82.7457	9.8537	53	81.22	130	260
孕妇 BMI	31.8375	2.9816	20.7031	31.2746	46.8750	260

表5 描述性统计图（女胎）

指标	均值	标准差	最小值	中位数	最大值	总人数
年龄	29.9606	4.2991	20	30	44	127
身高	161.1008	5.6904	135	162	173	127
体重	82.0720	9.7288	56	81	116	127
孕妇 BMI	31.5720	2.9066	25.5937	30.8012	44.2006	127

在上表中集中展示了孕妇相关特征的描述性统计。孕妇年龄与 BMI 指标分布相对集中，年龄中位数约 32 岁，BMI 指标中位数接近 28，符合样本高 BMI 的特点。检测孕周高度集中于 12-20 周，符合 NIPT 的常规检测窗口。印证了上述数据清洗的合理性与科学性。

4.3.2. 第 13,18,21 号染色体 Z 值分布

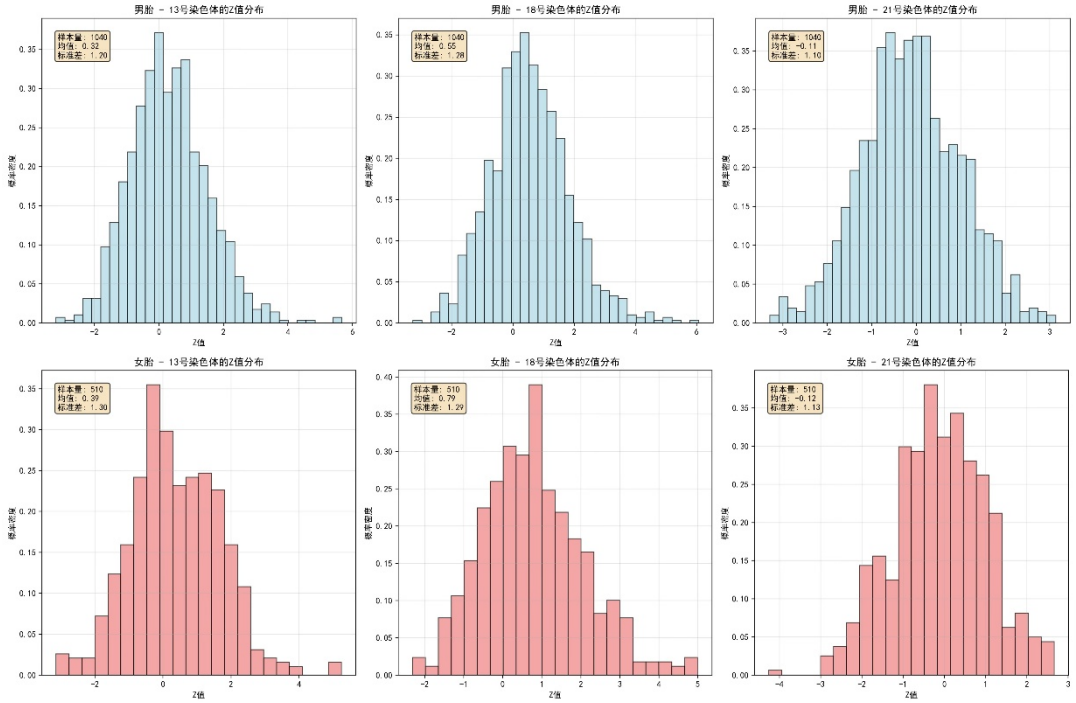


图3 男胎/女胎孕妇三段染色体片段的 Z 值分布图

在上图中按照颜色分别呈现出男胎/女胎孕妇在三段受关注染色体片段上的 Z-score 值分布。此处 Z 值的计算方法为：

$$Z = \frac{X - \mu}{\sigma}$$

其中μ和σ分别为正常对照群体中该染色体计数比例的均值和标准差。在上图中，若某项染色体的 Z 值取值接近于 0，说明该孕妇的此项染色体浓度接近正常群体的水平，若偏离较大（如达到$\pm 3, \pm 4$）可能说明此项染色体出现了非整数倍的异常情况。经观察发现，男胎/女胎孕妇的 18 号染色体 Z 值分布整体有偏向正数的趋势，其余四组数据则相对标准。

4.3.3. 检测准确的条件界定

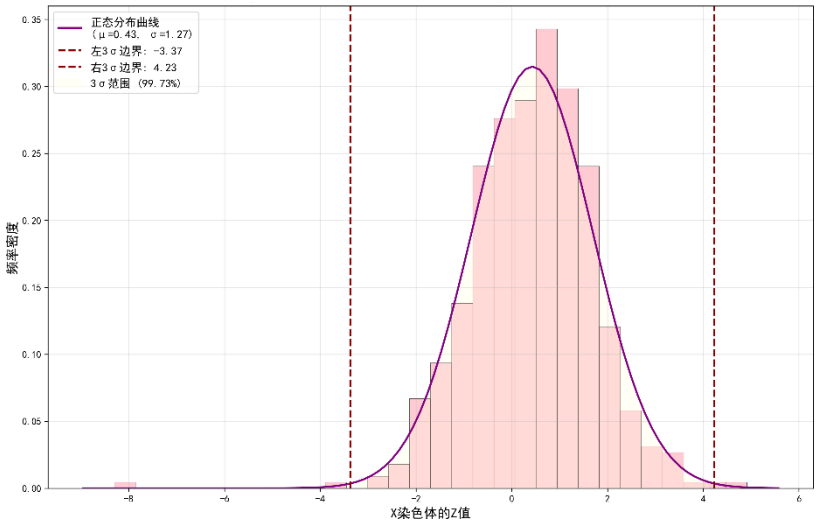


图4 女胎孕妇 X 染色体频率分布直方图与正态分布拟合图

由题目中信息可知，女胎的 X 染色体浓度没有异常，则可认为 NIPT 的结果是基本准确的，在上图中，由于女胎孕妇的 X 染色体 Z 值频率分布通过了正态分布的 SW 检验，所以我们将其位于3σ范围内的部分认定为“X 染色体无异常”。本文采取的 SW（Shapiro-wilk）检验是一种针对小样本量（≤ 5000）数据的正态检验方法，且对于异常状态的敏感性较高。

4.3.4. 胎儿健康比例分析

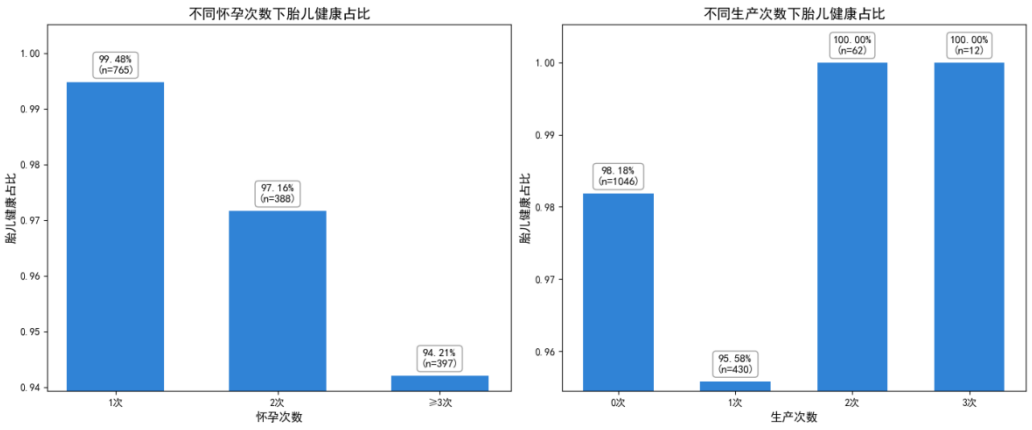


图5 不同怀孕次数和生产次数下的胎儿健康

由上图中数据可以直观发现，随着怀孕次数的上升，胎儿健康的占比有所下降，但是生产次数较大时，胎儿健康的比例却反而明显高于初次和二次生产的情况，如 Aliyu 在论文中所述[2]。此结果反映出，怀孕次数和生产次数会成为影响胎儿健康率的影响因素，在后文中会涉及相应的量化与分析。

4.3.5. 胎儿染色体 GC 含量比对分析

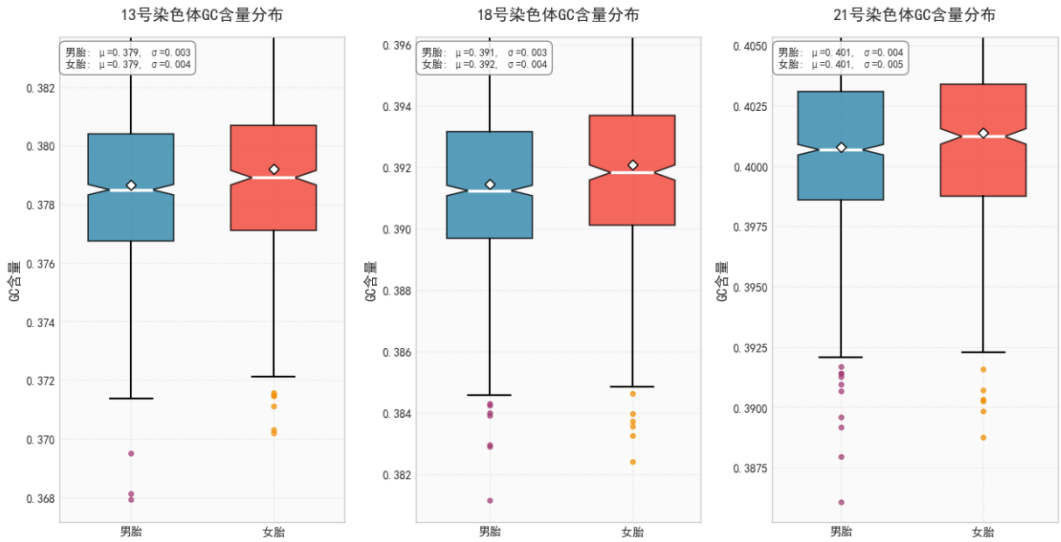


图6 胎儿染色体 GC 含量对比分析

综合题目信息与 Mariya Shtumpf 等人研究表明，健康人群 cfDNA 的平均 GC 含量比人类基因组平均水平低约 3%[1]。由图中数据可发现，女胎孕妇的三段染色体平均值与中位数均高于男胎孕妇，并且几乎所有的数据点，染色体 GC 含量均高于 0.37，只有极少数点会位于 0.37 以下。

5. 模型一：基于 Meta 分析与 Y 染色体浓度生理学意义的分式拟合模型

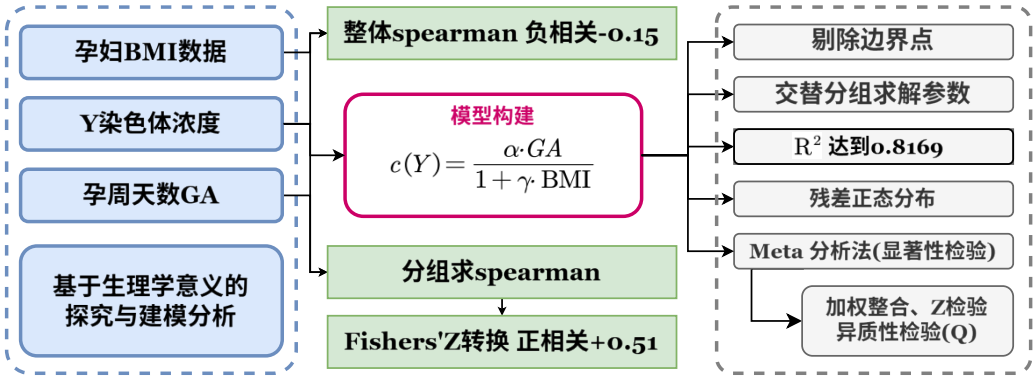


图7 模型一核心流程图

5.1. 任务目标分析

由题目信息可知，模型在此需要解决的任务有三：

1、首先，我们需要选用合适的方法，对 Y 染色体浓度和怀孕周期、孕妇 BMI 之间的相关性进行定量的描述分析，结合其生理学含义进行描述与验证；

2、其次，我们需要结合相应的数据知识与理论知识构建一个科学的、具有较高可解释性的量化模型，将这三者之间的正负相关关系进行合理的呈现，与染色体浓度$c(Y)$进行拟合；

3、最后，还需要针对模型的整体思路的必要性进行检验（异质性检验），以及对每个参数的数值进行显著性的检验，以确认模型构建与求解的合理性；

5.2. 相关性分析

在本模型中，首先需要对 Y 染色体浓度与孕妇怀孕天数和孕妇 BMI 值的相关性关系做出定量判断，便于构建基于 Y 染色体生理学含义的模型方程。对于前者我们选用了基于Fishers′Z 变换的加权斯皮尔曼相关性分析，后者则直接对于整体 BMI 和 Y 染色体浓度进行相关性系数的划分，详细论述与原理如下。

5.2.1. 基于Fishers′Z 变换的加权斯皮尔曼相关性分析

本文发现同一孕妇有多组数据，如何处理统一孕妇在时间序列上的若干次数据点是解决的关键之一。故首先，我们考差了每一位孕妇对应的若干行中 Y 染色体浓度与怀孕天数的 spearman 相关系数：

$$\rho = 1 - \frac{6\sum d_i^2}{n(n^2-1)}$$

其中，d_i表示第i个数据对的位次值之差，n表示总的观测样本数。得到的结果如下表中所示，其各组相关系数的平均值已经达到了 0.72，超过 60%的相关系数通过了显著性检验，呈现出出了明显也较好的正相关性。故后续我们需要对这 241 个离散的相关系数进行综合与汇总。

表6　　各组 spearman 相关系数分布统计表

相关系数	-1~-0.5	-0.5~0	0~0.5	0.5~1
数量	10	17	23	191
占比	4%	7.00%	10%	80%

在确定整合方法时，我们发现了一个重要的问题，即不同个体之间由于体质特点的差异过大，例如孕妇 A113 与孕妇 A246，两人均在怀孕 12 周零 2 天时进行产检，前者的 Y 染色体浓度为 0.02，后者却已达到 0.11。所以说直接整合不同人的数据段时不科学且不合理的，所以我们选择针对不同人的 spearman 相关系数进行整合。

关于不同人的相关系数权重，本文参考了 Bonett 等人在一篇论文中[3]所提出的权重赋值方法，即每一项的权重取$\omega_i = n_i - 3$，其中n_i表示每一名孕妇的采样数据个数。对于基于数据点个数的操作，原因在于如果一个组中计算 spearman 系数所以来的数据点较多，其相关系数的可信度与可靠性会相应的提高，故其权重也会随之增大；对于减去 3 这一操作，则源自于对于Fishers′Z 变换的拓展，一般在处理 spearman 相关系数时，由于其自由度不便于衡量，会普遍将其与具有三自由度的 pearson 相关系数相关联。此种方法尤其适合在样本量较大，有上千条数据时进行近似处理。综合表达式为

$$\mathrm{sp}_1 = \sum w_i \cdot \mathrm{spearman}_i$$

对于整合方法，本文**主要采用了**Fishers′Z **变换的拓展**，如同 Bonett 等人在输出处理时用到的[4]，我们首先进行Fishers′Z 变换将非正态的分布转换为正态分布，此步操作可以将相关系数 r 从有限区间[-1,1]拉伸到整个实数轴，使其采样分布近似对称、方差稳定，从而可以用常规的 z 检验进行推断。公式如下：

$$z = \tanh^{-1}(r) = \frac{1}{2}\ln\frac{1+r}{1-r}$$

最终模型的计算结果呈现如下，可以分析发现 Y 染色体浓度与孕妇的怀孕周数之间呈现显著的正相关性，说明随着孕期时间的增大，相应的母体外周血中 Y 染色体浓度也会有所上升，这一结论非常准确地印证了 Kazemi 等人在论文中的结论[5]，“随着孕周增加，胎盘逐渐发育，胎盘体积和代谢活动增加，向母体循环中释放的胎儿 DNA 也越来越多”。

表7 Y 染色体浓度与怀孕周数的相关性分析结果

分析项目	合并相关系数	Z 统计量	p 值	显著性
检测孕周(天数) vs Y 染色体浓度	**0.5822**	8.3679	0.0000	显著

5.2.2. Y 染色体浓度与孕妇 BMI 的斯皮尔曼相关性分析

不同于前者处理 Y 染色体浓度与怀孕周数时使用的先分组再汇总的方法，在处理 BMI 数据时需要充分考虑到该数据的分布与数值特点。由于以下两点原因，本文在此选择直接对全体男胎孕妇的 Y 染色体浓度和孕妇 BMI 数据进行 spearman 相关性系数sp_2的计算。

1、首先经过比对分析，发现对于同一孕妇代码的数据，因为产检周期位于 12~20 周内，其 BMI 数值在的变化幅度上很小，最大差距不会超过 4%，再使用前文中提到的分组整合的思路是不合适的，每一组内不具有那么良好的相关性。故更应该比较的是不同个体之间的差异型而非特定组别内部的变化。

2、其次从 BMI 作用于 Y 染色体浓度的生理学意义上来讲，高 BMI 的孕妇通常由更大的血容量喝脂肪组织，这会导致相同量的胎儿游离 DNA 在母体血浆中被稀释，从而检测到胎儿 DNA 中染色体相对浓度降低。此外，高 BMI 可能盘随着慢性低度验证的代谢改变，可能影响胎盘功能，从而简介影响胎儿 DNA 的释放量和检测水平[6]。

综上所述，本文在此直接对 Y 染色体浓度与孕妇 BMI 进行相关系数的计算，详细数据表格如下。由此不难发现，**Y 染色体浓度与孕妇 BMI 数值呈现显著的负相关性。说明体重基数越大的孕妇，其 Y 染色体浓度会有越低的趋势。**

表8 Y 染色体浓度与孕妇染色体浓度的相关性分析结果

分析项目	相关系数	p 值	方法	显著性
BMI vs Y 染色体浓度（整体）	-0.1507	0.0000	Spearman	显著

5.3. 模型构建与分析

5.3.1. 模型构建流程

综合上述关于 Y 染色体浓度的生理学意义与相关性的分析可知，在表达式中的怀孕周数（后文中以 GA 简写，Gestational Age）应与之呈正相关、BMI 数值阈值应与之呈负相关。本文在此将比例模型的构建逻辑呈现如下：

Step 1：假设单位时间胎盘释放的胎儿 cfDNA 总量 F 与孕周 GA 成正比，即 $F = a \cdot GA$；假设母体背景 cfDNA（以及血浆稀释效应）随 BMI 近似线性增长，故将其拆解为常数项与线性项的求和，即 $M = b \cdot (1 + \gamma \cdot \mathrm{BMI})$。

Step 2：Jia Ju 等人在论文中描述[7]，胎儿背景的 cfDNA 相对母体背景的 cfDNA 占比大约 5%~10%，在本模型可以暂时忽略其影响，故有下列等式：

$$c(Y) = \frac{F}{F+M} = \frac{a \cdot GA}{a \cdot GA + b \cdot (1 + \gamma \cdot \mathrm{BMI})} \approx \frac{\alpha \cdot GA}{1 + \gamma \cdot \mathrm{BMI}}$$

其中α和γ为模型的两个核心参数，沿用前文中关于相关性的陈述，此处这两者应为大于零的值，具体计算与求解方法如下。

Step 3：对于参数的确定，此处仍然沿用前文中对于孕周 GA 和 BMI 不同的处理方法来处理各自的前置系数，即对于前者α仍然采用“按照孕妇代码划分组别”的思路进行处理，每一组得到一个合适的α值，后者γ则是对于整体确定一个固定的值。详细求解方式见下文。$c(Y) = \dfrac{\alpha \cdot GA}{1 + \gamma \cdot \mathrm{BMI}}$

Step 4：最后也是最关键的一步，我们会处理整合所有的α_i值，**利用 Meta 分析，一种基于方差的加权求和方法**汇总得到最终的α_0和γ_0，由此即可得到最终针对所有孕妇的完整拟合模型。

5.3.2. 模型求解与结果呈现

模型的求解主要选择的方法是**交替优化算法**，其主要用于目标函数设计多个变量组且联合优化困难的问题，其核心思路是将变量分组，先固定其中一部分，优化另一部分，然后交换角色、交替进行直至收敛。在本模型中代数表达式如下：

$$\text{目标为: } \min f(\alpha, \gamma) = \min \left(c(Y) - \frac{\alpha \cdot GA}{1 + \gamma \cdot \mathrm{BMI}} \right)$$

选择先固定$\gamma^{(k)}$，求解：

$$\alpha^{(k+1)} = \arg\min_{\alpha} f\left(\alpha, \gamma^{(k)}\right)$$

再固定$\alpha^{(k+1)}$，求解：

$$\gamma^{(k+1)} = \arg\min_{\gamma} f\left(\alpha^{(k+1)}, \gamma\right)$$

值得注意的一点是，因为模型是存在两个需要拟合求解的参数的，所以如果对于某一个人其数据点只有两个，则失去了其拟合的意义，故选择删去只有两个数据点的用户

数据。剔除前一共 1040 行，移除了 32 行（3%），一共对 241 名孕妇数据进行拟合，得到的部分系数呈现如下：

表9 部分拟合参数呈现表

孕妇代码	数据点数量	alpha	gamma
A001	4	0.000516584	0.011496915
A002	5	0.000463597	0.011496915
A003	6	0.000668811	0.011496915
…	…	…	…
A267	4	0.001606740	0.011496915

详细地模型拟合评判指标呈现如下，其中R^2达到 0.8169，RMSE 达到 0.0144，说明模型的拟合效果很好：

表10　模型整体拟合效果

指标名称	数值	说明
整体 R2	**0.816943755**	所有预测值与实际值的整体决定系数
整体 RMSE	0.014411096	所有预测值与实际值的整体均方根误差
整体 MAE	0.009595667	所有预测值与实际值的整体平均绝对误差

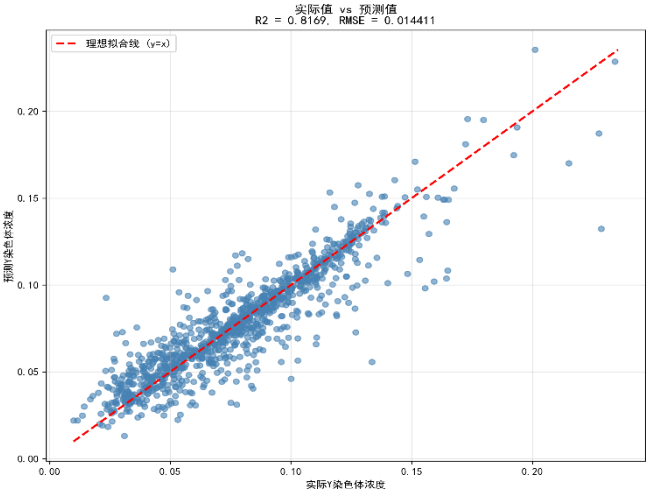


图8 拟合结果分布散点图

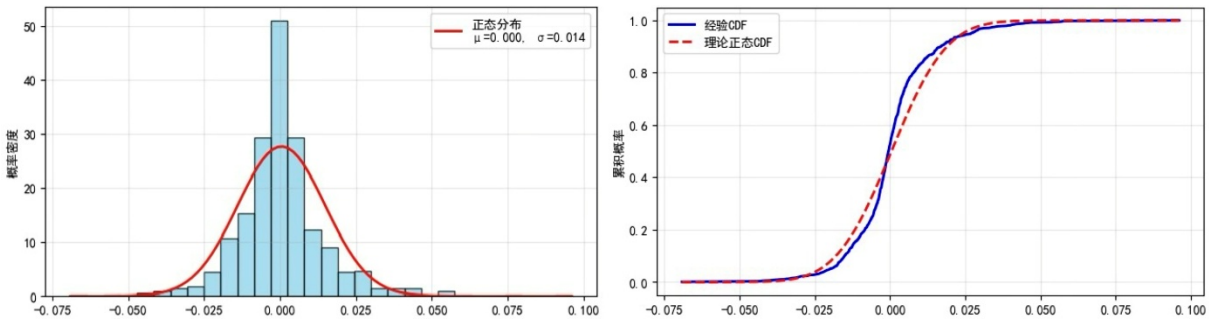


图9 概率分布与正态拟合图像（左）和累积分布函数对比图（右）

此外，本模型拟合得到的结果与数据集中的 Y 染色体浓度之间作差可以得到相应的残差，绘制其概率分布与正态拟合图像和累积分布函数比较图如下，由图可知，残

差的平均值非常接近于零，其整体近似正态分布，符合经典线性回归的假设，说明模型拟合效果很好。

5.4. 显著性检验与 Meta 分析

本模型的显著性检验主要在探讨并验证两个问题：**模型参数的显著性以及分组算法的合理性，分别采取 Meta 分析法和基于 Q 统计量的异质性检验。**

由上文模型的构建可知，在进行参数的显著性检验时，我们需要应对不同分组的模型参数，故选用 Meta 分析方法进行考察与计算，详细流程如下。

Step 1：计算标准误与方差

在每一次拟合寻找估计值时，获取 95%置信区间的上下限（记为 LL 和 UL），并计算相应的标准误 SE，其中 1.96 是标准正态分布中覆盖 95%概率区域的 Z 值（即 $Z_{0.025}$），同时方差为标准误的平方，故有：

$$SE=\frac{UL-LL}{2\times 1.96},\quad \delta=(SE)^2$$

Step 2：求解完整系数与完整方差

沿用前文所述模型的构建方法，经过数学推到可以计算出最终系数的值与其方差。

$$\alpha_0=\sum_{i=1}^{n}\frac{1}{\delta_{\alpha_i}}\cdot\alpha_i,\quad \delta_{\alpha_0}=\frac{1}{\sum\frac{1}{\delta_{\alpha_i}}},\quad \gamma_0=\gamma,\quad \delta_{\gamma_0}=\delta_{\gamma}$$

由此我们可以得到两个最终参数的取值，在本文中获得的具体数据如下：

表11　最终参数与对应方差

变量	α_0	δ_{α_0}	γ_0	δ_{γ_0}
取值	0.001044505	0.000001651	0.011496916	0.000265750

Step 3：对最终参数进行 Z 检验

首先可另原假设为$\alpha_0=0$ & $\gamma_0=0$利用上述数据，计算 Z 统计量，并查表获得相应置信度下的 P 值，公式与详细数据如下：

$$Z=\frac{\alpha_0-0}{SE(\alpha_0)}=\frac{\text{总回归系数}}{\sqrt{\text{总回归方差}}}$$

表12　Z 检验结果呈现

指标	Z 统计量	P 值	是否显著
α_0	632.53	0.00	是
γ_0	43.26	0.00	是

由上表中数据可知显著性检验通过，即可以拒绝“无差异”或“无效果”的原假设，表明我们观察到的数据差异或变量间的关系是真实存在的，而不是随机偶然的结果，可以说明模型在统计学意义上的可靠性。

Step 4：异质性检验

在此我们会对输出的两个参数数据进行基于 Q 统计量的异质性检验，通过求解 Cochran's Q 统计量没来判断各个独立研究的结果是否具有同质性。

$$Q_\alpha = \sum_{i=1}^{n} \frac{1}{\delta} (\alpha_i - \bar{\alpha})^2$$

此外，我们发现，Q_α 会随着数据量 n 的增大而增大，其受到自由度的影响亦有同样趋势，故为了便于比较，我们需要消去数据量自由度对客观评价指标的影响，故还会计算一个统计量I^2，若$I^2 > 75\%$则说明通过了异质性检验，即各个独立研究的结果之间不具有同质性，进行先分组再合并处理是合理且有效的。在本文中 Q 统计量为 64330.76，相应的I^2为 99.63%，显然通过了检验。

5.5. 模型一总结分析

在本模型中，首先利用基于 Fishers'Z 变换的分组整合的相关性分析，探求得到了 Y 染色体浓度与孕周时间 GA 呈现正相关（$r = 0.51$），后直接对整体 Y 染色体浓度与 BMI 值的相关性进行量化，发现两者呈现负相关（$r = -0.15$）；其次，经过充分调研，针对这几种医学指标的生理学意义进行了准确的分式建模，利用交替优化算法确定每组中的参数α_i和整体的参数γ，随后利用 Meta 分析方法，对独立研究的结果进行基于$1/\delta$权重的整合，得到完整模型的参数α_0和γ_0；最后，在模型检验方面，本文先后进行了对参数的 Z 检验和对整体的异质性检验，结果均通过，反映出模型的拟合效果优异。

6. 模型二：融入时间波动性的风险损失模型

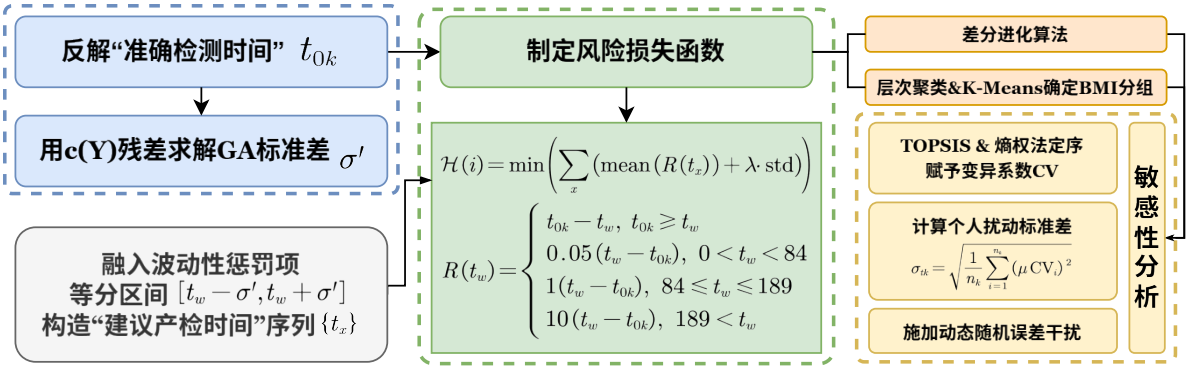


图10　模型二核心思路图

6.1. 模型构建思路

6.1.1. 任务目标分析

由题目中要求可知，本模型在此处的任务目标是希望针对每个有着自身 BMI 数据的个体，能够寻找到合适的阈值组合，依照 BMI 数据进行组别的划分。在每一个

BMI 的组别中，为组内用户提供一个最优的产检时间，能够尽可能避免并平衡“早检测的准确性不足”与“晚检测的治疗风险加剧”两者的矛盾点。

故而相应的算法与优化方向是希望能够找到最合适的阈值标准组合，并且告诉我每一个 BMI 分段中的合适的产检时间（孕周 GA 时间），使得我的风险损失函数可以实现最小化。

6.1.2. 模型构建流程

Step 1：计算特定孕妇 Y 染色体浓度达到 4%的准确时间

沿用模型一的思路，我们可以对前文中的分式进行反解。假设对于第k个孕妇，有一个固定的 BMI 数值，可以求解得出其 Y 染色体浓度达到 4%的准确时间t_{0k}：

$$t_{0k} = GA_k = c(Y)\cdot(1+\gamma\cdot \mathrm{BMI})\Big/\alpha$$

相应的对于每一个t_{0k}可以解出一个特定的可信标准差，记作σ'，其反映了在拟合条件下的可信时间范围。具体计算方法如下：

① 首先在式中由于可以视 BMI 为一个定值，故可以认为反解得到的“准确时间t_{0k}”的标准差可以由预测值$c(Y)$的标准差表示得到：$\sigma' = \sigma_Y\Big/\alpha$，故只需要解出在模型一预测的过程中，预测值$c(Y)$相较于测量值的残差的分布方差，如此可以将模型拟合出现的误差利用线性关系反映到“准确时间t_{0k}”上，提供一个基于拟合方程的可信时间范围。

② 其次，由模型一中拟合的决定系数的定义式可知

$$R^2 = 1-\frac{SSE}{SST},\ 其中\ SST=\sum_{i=1}^{n}(y_i-\bar{y})^2, SSE=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2$$

SST 为总平方和，SSE 为残差平方和。值得注意的是，**在此，本文不考察预测得到的数据本身所存在的分布规律，而只关注预测得到的残差的分布规律。因为当我们在鲁棒性框架中讨论“标准差”时，我们特指的是那个最源头的、描述模型自身参数估计精确度的标准差。**故相应的标准差计算式如下：

$$\sigma_Y = \sqrt{\frac{SSE}{n-1}} = \sqrt{\frac{\sum(y_i-\hat{y}_i)^2}{n-1}},\quad \sigma' = \sigma_Y\Big/\alpha$$

其中$n-1$是出于自由度的考量，当我提供上述等式后，一旦确定了$n-1$个数据，那么最后一个数据也就相应确定了，故认为上式可以实现“无偏估计”，更具有准确性。

Step 2：制定初步的风险损失函数$R(t_w)$

在本文医疗问题的情境中，风险是绝对希望避免的，所以以降低风险为核心目的的损失函数是建模的核心店所在。考虑到以下两种情况，本文在此决定对风险损失函数的核心成分进行初步定义：

① 用户早于 Y 染色体浓度恰好达到 4%的时间点t_{0k}进行孕检，会出现准确率不高的情况，但其属于是误检，后续发现问题并纠正的概率较大，对孕妇的危害风险较

小。

② 用户晚于 Y 染色体浓度恰好达到 4%的时间点t_{0k}进行孕检，会出现治疗不及时导致强制进行救治而对孕妇身体造成较大危害的风险。由题目中信息，“早期发现（12 周以内）风险较低；中期发现（13－27 周）风险高；晚期发现（28 周以后）风险极高”此种情况表明如果我的建议产检时间t_w晚于t_{0k}，对孕妇可能会造成较大的风险。所以综合考虑以上两点，本文利用“建议时间”与“准确时间”的差值来反映函数的损失状况，用每一项前的系数直观反映了此状态下对于孕妇身体带来的风险级别，定义了函数$R(t_w)$如下：

$$R(t_w)=\begin{cases} t_{0k}-t_w,\ t_{0k}\geqslant t_w \\ 0.05(t_w-t_{0k}),\ 0<t_w<84 \\ 1(t_w-t_{0k}),\ 84\leqslant t_w\leqslant 189 \\ 10(t_w-t_{0k}),\ 189<t_w \end{cases}$$

其中w表示的是第k个用户所处在的 BMI 阈值划分的第w组内（**假设目前将所有孕妇按照 BMI 的标准划分为 i 组**），t_w表示在第w组所对应的建议产检时间，值得注意的是，我们发现不同 BMI 分组中可能会出现建议产检时间重叠甚至交叉，所以在每一次迭代的过程中，对模型额外施加一个约束条件，即对于每一步迭代，都需要三组的建议 NIPT 产检时间单调递增。

Step 3：融入波动性的风险损失函数优化

最后，针对这种风险类问题，本文出于严谨性与科学性考虑，实际情况中如果某些“最优点”状态非常脆弱，面对一些哪怕很小的异常波动都会使得风险值迅速上升，这种情况并不是我们希望出现的，更何况在医疗场景中许多医学量的测量都是存在一定的误差和偏差的，所以有必要在损失函数中添加可以处理鲁棒性的部分。

首先，此时仍然会沿用 step1 中计算得到的标准差σ'，同时基于第k个用户的准确 NIPT 时间t_{0k}，来构建一个属于第k个孕妇的波动时间范围$[t_{0k}-\sigma',t_{0k}+\sigma']$，在此范围内，我们会去一些数据点，代入计算风险损失函数，经过大量调试与测验，人为取定步长j，即表示相邻两取样数据点之间的距离。

其次，令$p=\sigma'/j$，则在上述波动时间范围内共存在$2p+1$个采样的数据点，在本文中$p=5$：

$$\{t_{xk}\},\ x=1,2,...,11$$

现将其均带入 step2 中定义的$R(t_w)$，得到一组共计 11 个$\{R(t_{xk})\}$值，对于这些数据点，求解得到其标准差std 与平均值，汇总得到**最终版风险损失函数**如下：

$$\mathcal{H}(i)=\sum_k\left(\frac{1}{11}\sum_x R(t_{xk})+\lambda\cdot\mathrm{std}\right)，\text{其中}R(t_w)\text{的定义同上}$$

上式中左侧的自变量只有i，而右侧则存在t_x与 std 两个变量，那是因为右侧的两个变量包括第k个孕妇所处的分组索引都可以由变量i与确定的 BMI 值所解出，故上式是合理且可解释性强的。在此值得注意的是，λ作为权重反映的是在某个情境下对于

波动性的容忍程度，λ越大说明越希望模型具有较高的鲁棒性，在本文中计算得到标准差$\sigma' = 14.543$，另取$\lambda = 0.1$。

6.1.3. 模型求解思路

本模型的核心求解方法是一种**增添约束条件的差分进化算法。**首先基础差分进化算法的核心思路为以下四个步骤：

① **初始化：**在问题的可行解空间内，随机生成一个包含若干个体的初始化种群，向量中的每个个体都是问题的一个潜在解；

② **变异：**从种群中随机选择三个与目标不同的个体x_{r1}, x_{r2}, x_{r3}，计算其中两个个体的差分向量，将这个差分向量按照一个缩放因子F进行缩放，并与第三个个体相加，得到的变异向量为$v = x_{r1} + F \cdot (x_{r2} - x_{r3})$；

③ **交叉：**将上一步生成的变异向量与目标向量进行混合，逐个维度进行比较，以一个预设的交叉概率 CR 为依据，决定试验向量的该维度是继承自变异向量还是目标向量，既能帮喊新信息，也保留了部分原有信息，最终生成一个“试验向量”；

④ **选择：**采用“贪心”策略，对实验向量与目标向量进行一对一的生存竞争，比较两者的适应度，选择适应度更优的个体进入下一代种群，直到满足终止条件

随后，本文采用层次聚类与$\mathbf{K-Means}$聚类方法确定 BMI 阈值。在确定初始化种群时，由于算法的任务目标是确定一组对 BMI 的分组划分阈值，并给出各组内的建议产检时间，除去划分的组数i共计$2i-2$个需要迭代优化的对象。

$$\text{组数}\, i \rightarrow \text{BMI阈值} \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_{i-1} \end{pmatrix} \rightarrow \text{建议产检时间} \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_{i-1} \end{pmatrix}$$

所以出于算法的稳定性考虑，如果将全部$2i-2$个决策量全部纳入启发式算法的优化空间中，可能会导致结果波动无法收敛等问题，故在此先进行了层次聚类方法确定了$\{b_1, b_2, \ldots, b_{i-1}\}$。首先将数据集中的每一个数据点都视为一个独立的初始簇，随后计算每两个簇之间的距离（可理解为相似度），可以形成一个距离矩阵，在距离矩阵中按照平均连接准则，找到距离最近的两个簇并合并成一个新的簇，同时更新距离矩阵，如此不断循环迭代直到所有的数据点都被合并到一个簇中为止，得到的树状图如下。

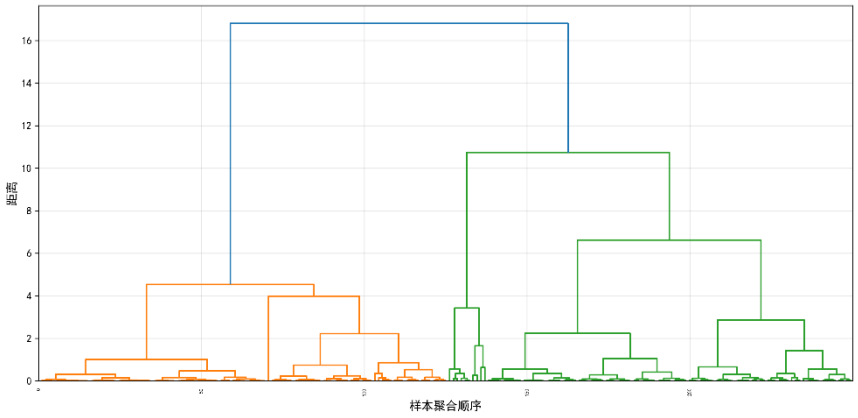


图11　层次聚类树状图

此时，对于上图中每一种衡量距离都存在不同的聚类方式，本文在此采用轮廓系数的方式进行量化选择，轮廓系数$s(i)$的定义如下：

$$s(i)=\frac{b(i)-a(i)}{\max\{a(i),b(i)\}}$$

其中$a(i)$表示簇内不相似度，即数据点与其自身所在簇中所有其他点的平均距离；$b(i)$表示簇间不相似度，即数据点与下一个最近簇中所有店的平均距离。对于不同的聚类数目而言，均可以确定一个轮廓系数，故绘制折线图如下，选择轮廓系数最高的点作为最优的组数划分。

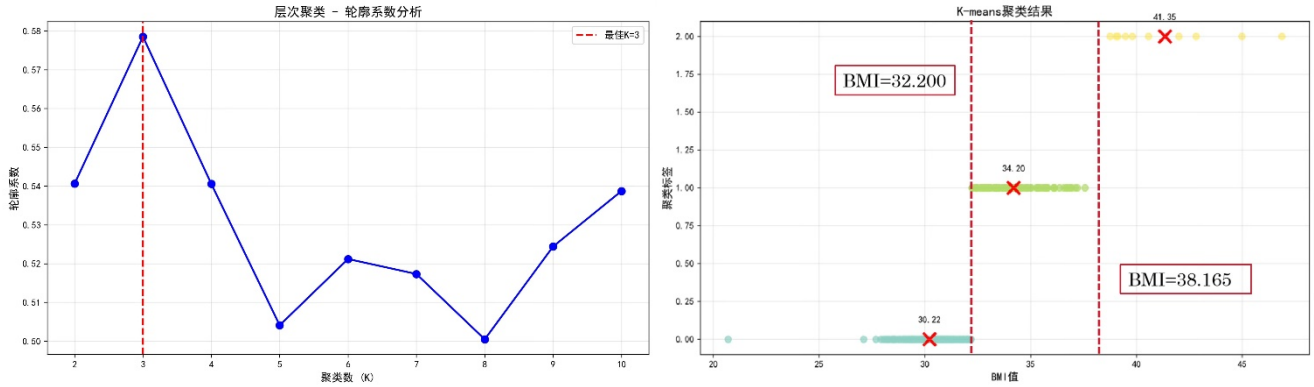


图12　轮廓系数折线图 & K-Means 聚类结果

由上图可知，在此数据集的条件下，最优的 BMI 组数划分为 3 组，即$i=3$，此时再利用其作为参数设定运行经典的K－Means 聚类方法。得到的三组阈值组合分别为：**组1[b_{min}，32.200]**、**组2[32.200，38.165]**、**组3[38.165，b_{max}]**，其中$b_{\min},b_{\max}$为全体被测的 BMI 最小值和最大值。此时我们将这三组的判准阈值代入前文所属的差分进化算法，即可求解得出每一个区间的最优产检时间t_1,t_2,t_3。

在此呈现完整的模型目标函数与约束条件如下：

$$\text{minimize } \mathcal{H}(i)=\sum_k\left(\frac{1}{11}\sum_x R(t_{xk})+\lambda\cdot\text{std}\right),\ x=1,2,...,11$$

$$\text{s.t. } t_{w1}<t_{w2}<t_{w3}$$

$$t_{wj}\in\mathbb{N},\ j=1,2,3$$

6.2. 模型结果与敏感性分析结果呈现

通过整合上文中构建的融入了时间波动性的风险损失模型，以及对于差分进化算法的诸多改进，现将模型的迭代结果呈现如图 13，由图可知模型的拟合效果极好，在第 8 次迭代后便基本可以认为稳定收敛。

相应的最终策略呈现如下：

- **当孕妇的**BMI$\in[b_{\min},\ 32.200]$**时，建议最佳产检时间 NIPT 为第 68 天；**
- **当孕妇的**BMI$\in(32.200,\ 38.165]$**时，建议最佳产检时间 NIPT 为第 69 天；**

• **当孕妇的BMI $\in(38.165,\ b_{\max}]$ 时，建议最佳产检时间 NIPT 为第 72 天；**

基于此数据集可以判断得到相应的上下界$b_{\min}=20.700$、$b_{\max}=46.875$，若其他孕妇超出此上下界则仍然按照 32.300 和 38.165 的标准进行划分。

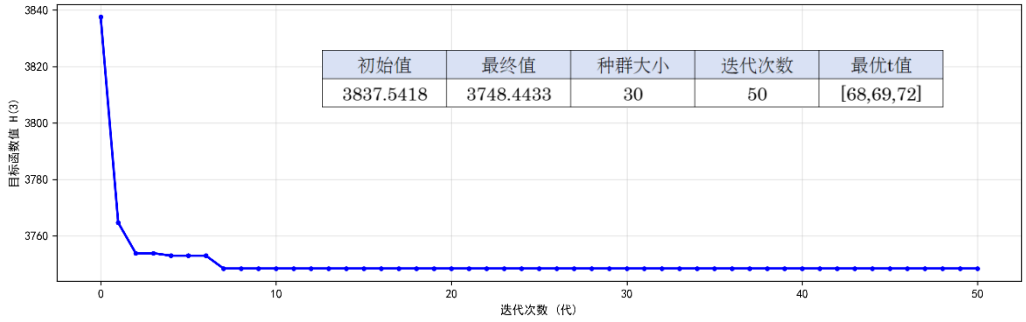


图13　模型目标函数随迭代次数增大的优化折线

6.3. 敏感性分析

在模型求解之外，同样重要的一点是模型对于环境中相关干扰因素的鲁棒性和稳定性，尤其在此类医疗背景下，更需要数学模型能够应对包括检测误差在内的诸多误差项的干扰，故本文在此对模型进行敏感性分析，详细步骤与原理介绍如下：

Step 1：基于 TOPSIS 与熵权法进行变异系数 CV 赋值

首先也是重要的一点，如何在尽可能贴近生活与医院实际情况下，对不同个体及不同采样数据赋予合理的干扰误差，是此时敏感性分析的关键所在。如果仅仅是简单的对全部数据点统一赋予 5%的干扰误差，会导致特定的干扰项添加得过大或是过小，使得干扰后得到结论的判断失真。

所以本文在此**集中考虑数据集中的六个数据值：**“原始读段数”、“在参考基因组比对的比例”、“重复读段的比例”、“唯一比对的读段数”、“GC 含量”与“被过滤掉读段数的比例”。这五项数据均为检测过程中得到的数值，通常来讲，随着采样基因数量的升高，检测出错的概率会有所下降[8]。故本文利用 TOPSIS 与熵权法构建一个综合的评价指标融合这五项数据值。

在进行原始数据矩阵的标准化操作后，对于第j个指标，计算其信息熵e_j与最终权重w_j：

$$e_j=-k\sum_{i=1}^{m}p_{ij}\ln(p_{ij}),\ \ j=1,2,3,4,5 \qquad w_j=d_j\Big/\sum_{j=1}^{n}d_j$$

随后我们需要定义正理想解与负理想解，基于这五项指标的生理学意义，对“重复读段的比例”和“被过滤掉读段数的比例”取相反数，即认为其数值越小越好，其余三者则认为越大越好。随后可以计算每一个评价对象与正理想解的欧氏距离D_i^+和与负理想解的欧氏距离D_i^-，并依此计算相对贴近度：

$$C_i=\frac{D_i^+}{D_i^++D_i^-},\ \ i=1,2,\ldots,1040$$

此时我们即可按照每个采样数据的相对贴近度C_i进行排序，获得从 1 到 1040 的一

串数据点序列 A，Lin H 等人在论文中的研究表明[9]，通过重复样本测定 Y 染色体浓度的变异系数（CV）为 **4.4% - 13.8%**。在此进行一步线性映射，即在序列 A 中第i位的采样数据，将其变异系数 CV 赋值为：

$$\mathrm{CV}_i = \frac{i-1}{1040-1}\cdot(13.8\% - 4.4\%) + 4.4\%$$

Step 2：计算数据扰动标准差σ_{tki}与个人扰动标准差σ_{tk}

在计算得到变异系数之后，值得注意的是变异系数的统计学意义，即用于衡量数据离散程度的相对指标可以定义为标准差与均值的比值，在此情景中可以通过CV_i来计算得到每个采样数据组的扰动标准差σ_{tki}。

$$\sigma_{tki} = \mu\cdot \mathrm{CV}_i$$

此处的μ代表的是采样数据的平均值，但是我们无法获得数据采集时原始检测的误差范围区间，沿用模型假设可以认为每一组数据中$c(Y)$均可以反映此时的采样数据平均值μ。随后，我们可以汇总获得同属于第k个孕妇的n_k数据的σ_{tki}汇总为一处，求解其平方平均值，即可得到第k个孕妇的个人扰动标准差σ_{tk}。

$$\sigma_{tk} = \sqrt{\frac{1}{n_k}\sum_{i=1}^{n_k}(\sigma_{tki})^2}$$

Step 3：对t_{0k}添加正态误差的随机干扰

承接上一个步骤中我们获得的属于特定孕妇的个人误差标准差后，即可以对其 Y 染色体浓度$c(Y)$施加一个均值为 0，标准差为σ_{tk}的随机误差值，在相应正态的概率分布曲线图中按照个点的概率值随机对一个数据采集点施加误差值。

综上所述，进行这一些操作，而非简单地直接全部添加上 5%的误差比例，可以更好地贴近实际情况中的检测误差，在考量模型的效果时能够做到科学、客观且严谨，能够很好地反映模型本身的鲁棒性与可靠性。具体的数据分析结果见下。

表13　引入扰动项后的模型敏感性分析

项目	组数	初始目标函数值	最终目标函数值	收敛代目	最优值
考虑误差	3	3950.5374	3744.3785	8	[68,69,78]
不考虑误差	3	3837.5418	3748.4433	7	[68,69,72]

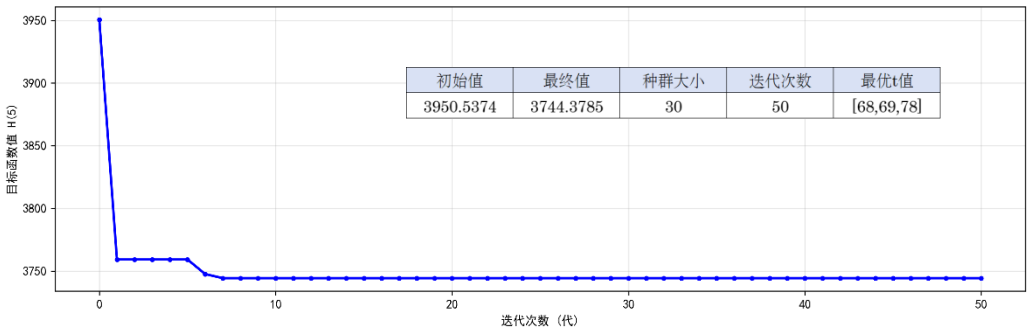


图14　施加扰动后模型目标函数随迭代次数增大的优化折线

由上图可知，模型在正确进行了施加误差的敏感性分析后，虽然其最终目标函数有所上升，但其收敛速度基本保持不变，均在第 7,8 次左右达到收敛的位置，并且优化得到的最优推荐 NIPT 值有两项都保持不变，第三项的变化幅度也不超过一周，在临床学上，对于一周以内的变动可以认为是合理的波动范围。这说明模型具有优异的鲁棒性与抵抗医学测量干扰的能力，为帮助孕妇顺利生产，提供了准确、科学的建议和简介清晰的解决方案，最大程度上减少风险，减少对孕妇造成的危害。

6.4. 模型二总结分析

在本模型中，我们首先沿用任务一中构建的的分式模型，利用孕妇的 BMI 和 $c(Y)=4\%$ 反解得出理论上第 k 个孕妇的最优产检时间 t_{0k}，并同时将任务一中预测得到的残差标准差转化为最优产检时间的可信范围 $\sigma'=14.543$。模型在此利用层次聚类与 K-Means 聚类确定了 BMI 分组的阈值，每一个阈值中都会提供一个建议的产检时间 t_w。此外模型的目标函数为融入波动性的风险损失函数。包含了两部分，其一：$R(t_w)$ 是基于“早检测准确率低”与“晚检测风险高”这二者赋予权重的分段函数。其二：利用 t_w 可信分范围内平均分段取点 t_x，用这若干个反映波动性的数据点计算标准差的惩罚项 std 以实现对目标函数的构建。随后在敏感性分析中，本文基于 TOPSIS 与熵权法对相关检测指标进行排序，并赋予相应的变异系数 CV_i、计算个人扰动标准差 σ_{tk}。依照此参数施加相应的扰动，发现稳健性良好，扰动后的策略变化仅为 7.6%，说明模型性能良好，具有较强的稳健性。

7. 模型三：基于 XGBoost 集成学习优化的风险损失模型

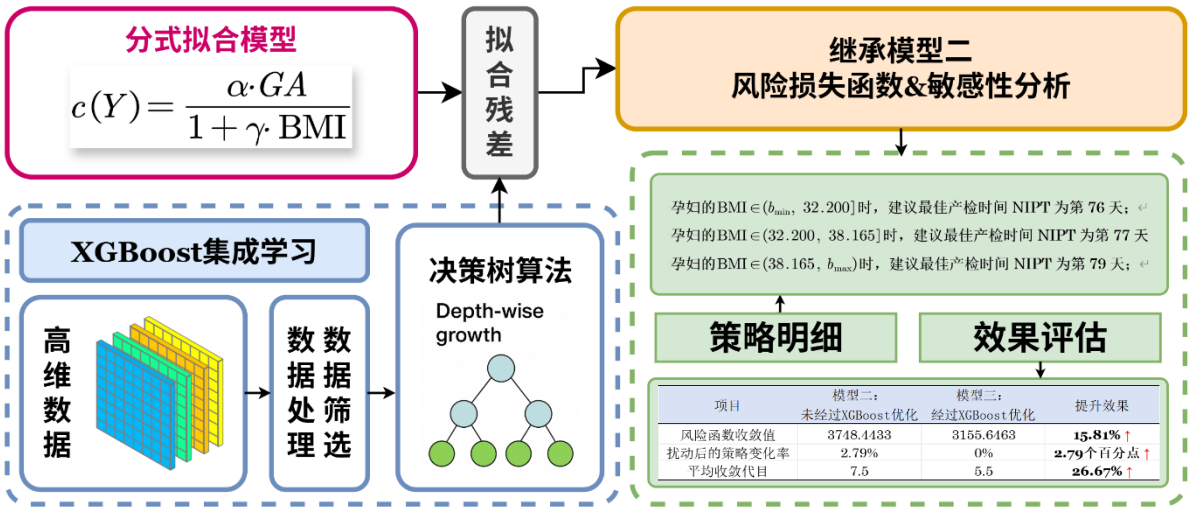


图15　模型三核心思路图

7.1. 任务目标分析

由题目信息可知，在本问中除了模型二中使用到的 BMI 和孕周时间 GA 数据，还需要多考虑一些其他因素对 BMI 分组判断的影响，例如年龄、升高、体重等等。故需

要重新拓展构建新模型，能够同时考虑多元的影响变量。本文在此选用 XGBoost 决策树模型对任务一中的分式模型进行补充，拟合其预测的残差，使得模型能够更精确地预测得到 Y 染色体浓度 ，随后将其再与模型二中的风险损失进行整合，实现多元变量考量下的的更科学的分组阈值确定。

7.2. 模型构建与分析

7.2.1. 模型特点优势

XGBoost 是一种由很多的 CART 分类回归树构成的 Boosting 集成学习算法模型，既可以用来进行分类的任务，也可以用来进行连续性目标变量预测的任务。在此本文选用之来构建基于回归树的模型，主要原因在于其有以下三点优势。

① XGBoost 相对多元回归，具有**较强的非线性关系**。在此情境中由于需要解释客观复杂的生理学指标之间的耦合作用关系（如 BMI 与年龄的作用等），利用此模型不需要手动构造多项式或者交互项来对复杂作用关系进行拟合；

② XGBoost 可以通过树的分裂过程自动学习变量之间的交互作用，输出特征重要性排序，**直观显示不同变量对于 Y 染色体浓度$c(Y)$的贡献度**。在此情境中适合用来对多变量的关系进行量化处理，更好地进行影响评估与敏感性分析；

③ XGBoost 相对多元回归，**对异常值不那么敏感**，内置了正则化与交叉检验可以处理噪声的破坏。在此情境中由于医疗场景中因检测设备与方法导致的不确定性较大，高维数据的特征较复杂，本模型可以尽可能避免错误拟合了数据特征。

7.2.2. 模型构建思路

XGBoost 的核心思想在于：通过不断地不断进行特征分裂来添加树结构，通过不断学习一个新函数来拟合上次预测的残差，使得回归不断优化。由此延伸，对于k棵决策树中样本对应的权重，求和即为所求的预测值。在此将其核心实现步骤进行呈现：

Step 1：数据与模型准备

再进行模型实现之前，需要先对各组数据进行$z-socre$标准化，将数据转换为均值为 0、标准差为 1 的标准正态分布，便于不同数据集间的比较与分析。本模型中需要转换的指标共有七个：**“孕妇身高”、“孕妇体重”、“孕妇年龄”、“孕妇怀孕次数”、“孕妇生产次数”、“NIPT 检测操作误差”、“孕妇 Y 染色体浓度超过 4%的占比”**。其中随后一列指标的含义是，对于第k个孕妇的n_k数据点，计算其中超过 4%的数据点所占比例，将这n_k个位置全部赋予这个比例值，此举可以一定程度上反映出此孕妇数据在 Y 染色体浓度这一个指标上的趋向程度。

而后需要划分训练集与测试集，并设定模型的相关超参数，包括树的最大数量、树的最大深度、学习率、正则化项系数等等，用来平衡调控模型的复杂度及拟合精度。

Step 2：样本输入与残差准备

在此，由于本模型需要对整体的的泛函进行优化，故需要先定义目标函数，如下所示，用来衡量树的的综合拟合效果：

$$\mathcal{L}^{(k)}=\sum_{i=1}^{n} l\left(y_i,\hat{y}_i^{(k)}\right)+\Omega\left(f_k\right)$$

该函数前半部分为损失函数项（用来揭示训练误差），后半部分为正则化项（用来惩罚复杂模型）。正则化项值越小复杂度越低，泛化能力越强，表达式为：

$$\Omega(f)=\gamma T+\frac{1}{2}\lambda\sum_{j=1}^{T} w_j^2$$

上式中γ和λ为模型超参数，T为叶子结点的数量，前一项用来控制节点的分裂，w_j为第j个叶子的权重，后一项通过对权重进行 L2 正则化，使得目标函数更倾向于选择权重较小的模型，有利于简化和泛化。

此时输入第一轮样本后，模型会开始进行迭代拟合。在每轮迭代中，根据前一轮的预测结果，计算并记录每个样本的如下两个重要判决量，后续将作用于树的分裂过程：

- 一阶导数 $g_i=\partial\mathcal{L}^{(k)}/\partial\hat{y}_i$，表示梯度，即为 Y 染色体浓度预测误差的方向
- 二阶导数 $h_i=\partial^2\mathcal{L}^{(k)}/\partial\hat{y}_i^2$，表示 Hessian 矩阵，即损失函数在此处的曲率

Step 3：分裂候选并寻找最优切分

基于上一步骤生成的决策树，对样本的每一种特征枚举其所有的可能切分点，将每种可能切分之后的的结果划分为“左子节点”和“右子节点”。对每一种切分尝试，计算“是否执行此操作”带来的目标函数增益（Gain）：

$$Gain=\frac{1}{2}\left[\frac{G_L^2}{H_L+\lambda}+\frac{G_R^2}{H_R+\lambda}-\frac{\left(G_L+G_R\right)^2}{H_L+H_R+\lambda}\right]-\gamma$$

其中G_L,H_L表示左子集的梯度和 Hessian 二阶导之和，G_R,H_R表示右子集的梯度和 Hessian 之和，λ为 L2 正则化项，γ为最小分裂增益阈值（用来控制剪枝）。

将模型的数据带入上述增益 Gain 计算，在所有特征的左右切分点中找到增益最大的分裂点，若该分裂点的 Gain 小于阈值γ，则不再进行分裂，可以认为构造完成决策树。重复 **Step 2** 和 **Step 3** 过程递归构建左右子树，直到达到最大深度，或增益小于最小阈值，或节点样本数小于设定值。

Step 4：确定叶片权重与模型学习

当树结构固定之后，模型会利用目标函数最小化的原则，为每一片叶子节赋予合适的权重大小，其原理主要是进行二阶的 Taylor 展开操作，通过求导方法得到相应的w_j^*，其简要过程呈现如下：

$$\begin{aligned}\mathcal{L}^{(k)}&=\sum_{i=1}^{n} l\left(y_i,\hat{y}_i^{(k-1)}+f_k(x_i)\right)+\gamma T+\frac{1}{2}\lambda\sum_{j=1}^{T} w_j^2\\&\simeq\sum_{j=1}^{n}\left[G_j w_j+\frac{1}{2}(H_j+\lambda)w_j^2\right]+\gamma T\end{aligned}$$

其中G_j, H_j的定义同上，在此通过结构函数将投入的数据变量映射到某个特定索引号的叶子节点上去。经过求导可以得到相应的权重：

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \text{此时 } \mathcal{L}^{(k)} = -\frac{1}{2}\sum_{j=1}^{T}\frac{G_j^2}{H_j + \lambda} + \gamma T$$

此时前的树结构固定后，对于投入样本的总体预测值将更新为$\hat{y}_i^{(k)} = \hat{y}_i^{(k-1)} + \eta f_k(x_i)$，故最后将森林中$k$棵树所得到的预测值按照学习率权重相加即可得到最终的样本预测值。

Step 5：对模型一残差的拟合

在按照前述流程正确构建 XGBoost 模型后，需要将其拟合的因变量设定为模型一种预测值与真实值的差异——残差，注意此处并非直接处理完整的$c(Y)$而是通过处理前置模型的不准确部分来提升整体的拟合效果。将第k个孕妇的n_k个数据点取平均值，作为模型一拟合的残差，再利用模型一预测出的$c(Y)$减去此残差以实现对其预测时间的纠偏，可以更高效地完成数据模型及其中规律的构建与预测，本问中计算得到相应的$\sigma' = 6.166$，仍取$p = 5$。

7.3. XGBoost 操作实现

7.3.1. 模型参数设定

本文对于模型的参数进行了优化设置：最多 100 棵决策树，每棵树的最大深度限制为 5 层以防止过拟合，以及泛化能力较差的问题；学习率设为 0.1 以确保模型稳定收敛；采用 0.8 的样本采样比例来增强模型的泛化能力。以均方误差作为优化目标，并固定随机种子以保证实验可重复性。

7.3.2. 模型结果呈现

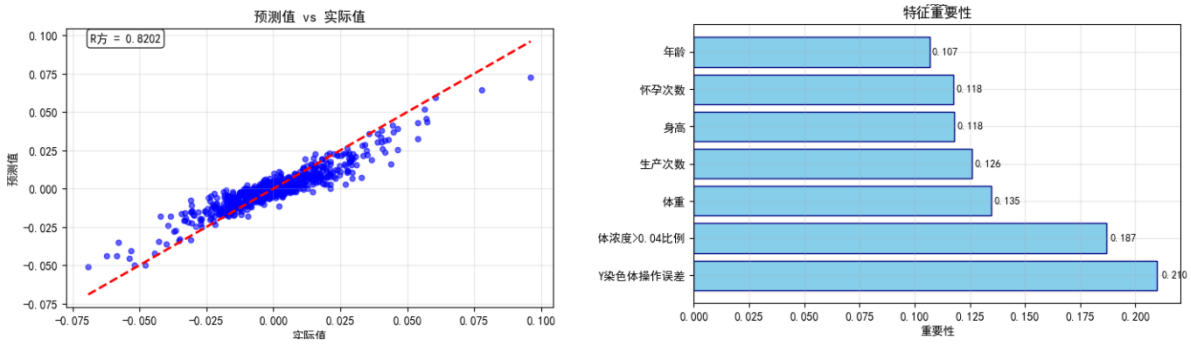


图16　$c(Y)$预测值与实际值关系（左）不同特征分量的影响权重（右）

对于上图，观察可知，模型拟合的效果优异，**R2 取值为 0.8202**，$c(Y)$的预测值在-0.025 至 0.025 的区间内与实际值紧密贴合 1:1 线。表明模型在中等浓度时预测准确，误差较小。然而在[-0.025,0.025]区间外数据点出现一定分散，但仍未过度偏离 1:1 线，说明在较高或较低$c(Y)$时可能存在轻微的欠预测或过预测的现象，这表明 XGBoost 模型在整体上表现优异。而对于不同的生理学特征，其重要性占比如右图所示。

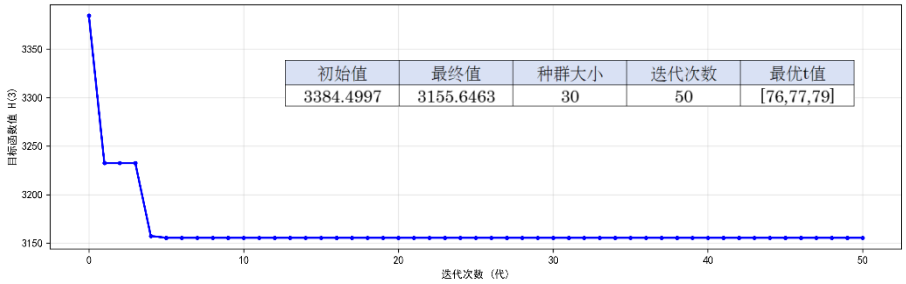


图17　模型三目标函数随迭代次数增大的优化折线

相应的最终策略呈现如下：

- **当孕妇的**BMI$\in[b_{\min},\ 32.200]$**时，建议最佳产检时间 NIPT 为第 76 天；**
- **当孕妇的**BMI$\in(32.200,\ 38.165]$**时，建议最佳产检时间 NIPT 为第 77 天；**
- **当孕妇的**BMI$\in(38.165,\ b_{\max}]$**时，建议最佳产检时间 NIPT 为第 79 天；**

基于此数据集可以判断得到相应的上下界$b_{\min}=20.700$、$b_{\max}=46.875$，若其他孕妇超出此上下界则仍然按照 32.300 和 38.165 的标准进行划分。因为 BMI 序列无变化，所以相应的阈值分组亦无变化。

7.3.3. 模型敏感性分析

在此处模型的敏感性分析同样沿用上文中**“基于 TOPSIS 与熵权法排序的正态误差随机扰动”**的思路，对于每一名孕妇的不同数据点，求解得到其个人的个人扰动标准差σ_{tk}，并依此赋予不同的随机误差扰动，随后运行模型二的风险损失模型部分，相应效果与数据呈现如下。

表14　引入误差项后的模型敏感性分析

项目	组数	初始目标函数值	最终目标函数值	收敛代目	最优值
考虑误差	3	2984.2926	2917.4809	6	[76,77,79]
不考虑误差	3	3384.4997	3155.6463	5	[76,77,79]

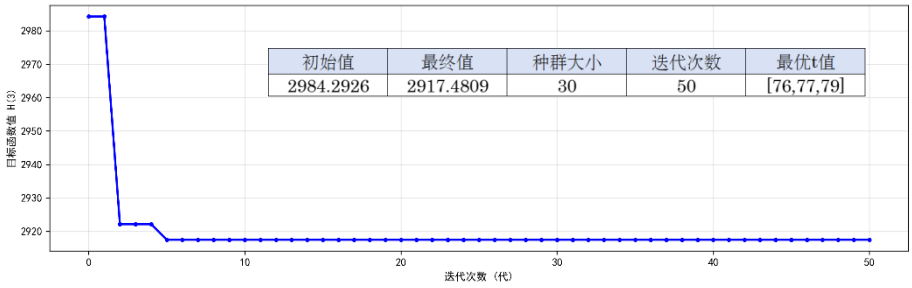


图18　施加扰动后模型三目标函数随迭代次数增大的优化折线

由上表上图中数据可知，XGBoost 集成学习组成对于整体风险优化模型性能的提高和影响可以从以下三个方面进行衡量，多角度数据量化比较呈现如下表：

表15　融入 XGBoost 集成学习优化后的模型性能对比

项目	模型二： 未经过 XGBoost 优化	模型三： 经过 XGBoost 优化	提升效果
风险函数收敛值	3748.4433	3155.6463	**15.81%** ↑
扰动后的策略变化率	2.79%	0%	**2.79** 个百分点 ↑
平均收敛代目	7.5	5.5	**26.67%** ↑

1、目标风险函数最终收敛值降低：

比较模型二与模型三的输出数据表格可知，模型二不包含 XGBoost 优化最终风险损失函数收敛于 3748.4433，而模型三的最终风险损失函数收敛于 3155.6463，提升大约 15.81%，说明融入集成学习优化可以显著提高拟合预测的精准度，极大助力实现了医疗场景中安全、科学的使用，尽可能减少了孕妇产检中面对的风险。

2、风险损失模型的鲁棒性显著增强：

在整体损失函数降低的基础上，还不难发现，模型三添加误差扰动后，对于模型的损失函数的影响很小，由表 13 中数据可知，模型二在施加误差扰动之后建议检测时间相差为 6 天，而在表 14 中添加相同随机数的扰动之后，建议检测的三个时间节点均保持不变，鲁棒性效果提升显著。表明 XGBoost 集成学习对模型进行优化后，除了拟合效果上的提升，同时也带来了稳定性的极大改良，在实际生产生活中，可以最大可能帮助孕妇应对因为诸多不可抗力误差造成的预测失真和误诊风险。

3、模型的迭代效率显著提高

此外由表 15 中数据可知，在未经过 XGBoost 优化时，模型在迭代过程中，风险损失函数初步达到稳定状态所需要的迭代次数大约为 7.5 次，而在本问经过优化后，相应的收敛代目达到了平均 5.5 次，提升效果大约 26.67%。表明模型三相对于模型二在使用相同差分进化算法的基础上，可以很大程度上缩短迭代时长，加快迭代速度，帮助医院方面尽可能节约资源、加快工作效率。

7.4. 模型三总结分析

在本模型中，相较前问进行的核心优化改良为引入了 XGBoost 集成学习算法进行分式模型的残差的拟合，本文从数据集中提取出若干变量并进行相应的处理（如计算“NIPT 操作误差”与“一个孕妇的数据中占比不超过 4%的比例”等等），用来纠正前置模型的拟合偏差。此后延续进行融入时间波动性的风险损失模型，以及基于 TOPSIS 与熵权法赋权以确定扰动误差的敏感性分析。将相关数据进行横向与纵向比对，可以得出加入 XGBoost 优化后的模型优势有三：其一，目标函数的最终收敛值降低，模型拟合准确率上升；其二，风险损失模型的鲁棒性显著上升，可以应对实际医疗场景下的多种不可避免的误差项；其三，模型的迭代效率有明显升高，可以尽可能提高应用的时效性。综上，本模型对于前置模型的改进优化操作是科学的、合理的，且对于风险的控制和优化具有显著的功用，具有较高的临床医学价值。

8. 模型四：基于主成分分析的 XGBoost 集成学习模型

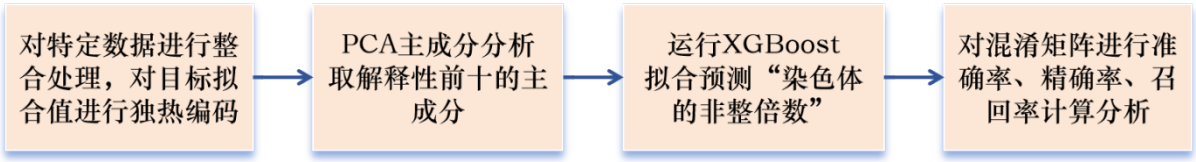


图19　模型四核心流程图

8.1. 任务目标分析

本任务是顺延前三个模型所解决的任务而来，具有一定的延展性与探索性，经过严谨分析观察，我们发现在“女胎检测数据”表格中所有的“胎儿是否健康”列均为“是”，故继续完全延续先前模型将没有意义，此外，由题目要求，我们需以女胎孕妇的 21 号、18 号和 13 号染色体非整倍体为判断和模型的拟合指标。更重要的是，我们在此需要对前置所有的指标进行尽可能完整的**综合考量**，所以本问中将集中采用复杂度较高的 XGBoost 模型对经过主成分分析编码处理的数据进行整合优化。

8.2. 模型构建与实现

8.2.1. 数据编码

出于综合考量的目的，本问中我们选取了数据集中的部分大部分标签作为模型的输入量，故在考虑生理学意义的基础上对不同标签的数据进行如下处理，其余变量均保留不变。

① 对于 IVF 妊娠，将“自然受孕”编码为 0，“试管婴儿”编码为 1；

② 对于检测孕周 GA，将对应的周数转化成总的怀孕天数；

③ 对于以下六项指标“原始读段数”、“在参考基因组比对的比例”、“重复读段的比例”、“唯一比对的读段数”“GC 含量”与“被过滤掉读段数的比例”，沿用模型二中敏感性分析时使用的 TOPSIS 与熵权法，整合得到的一列反映检测指标状态与检测误差大小的数据；

④ 对于“怀孕次数”，将 0 编码为 0，1 编码为 1，“≥3”编码为 3；

⑤ 将**染色体的非整倍数作为模型拟合的预测值**，按照三维独热编码的思路，将含有 T13 的数据第一位编码为 1，含有 T18 的数据第二位编码为 1，含有 T21 的数据第三位编码为 1，即“T13T18”即可编码为“110”；

8.2.2. PCA 主成分分析

此外，我们考虑到数据集中同时存在“身高”、“体重”和“BMI 数据”，直接将其输入给模型会产生较大的多重共线性、模型复杂度较高等问题。故决定在此进行 PCA 主成分分析。相较于直接删去孕妇 BMI 数据，此种方法可以在保留孕妇身高体重单独信息的基础上，还可以反映两者之间的相对关系这一特征。

故在此需要计算数据集两两变量之间的协方差矩阵 $\boldsymbol{R}=(r_{jk})_{n\times n}$，其中 r_{jk} 为第 j 个评价指标与第 k 个评价指标的协方差然后求出相关系数矩阵的 n 个特征根与特征向

量，确定主成分的个数，由特征方程式可以求解得到n个特征值，从大到小进行顺序排列：

$$|\lambda \boldsymbol{I}_n - \boldsymbol{R}| = 0$$

$$\lambda_1 \geqslant \lambda_2 \geqslant \cdots \geqslant \lambda_n \geqslant 0$$

其中特征根的大小描述了每个主成分在评价中所起作用的大小。每一个特征根对应一个特征向量，记为$\boldsymbol{u}_1, \boldsymbol{u}_2, \ldots, \boldsymbol{u}_n$，求得各主成分为：

$$z_{ij} = \boldsymbol{u}_j^T \boldsymbol{x}_i,\ \boldsymbol{x}_i = (x_{i1}, x_{i2}, \ldots, x_{in})^T$$

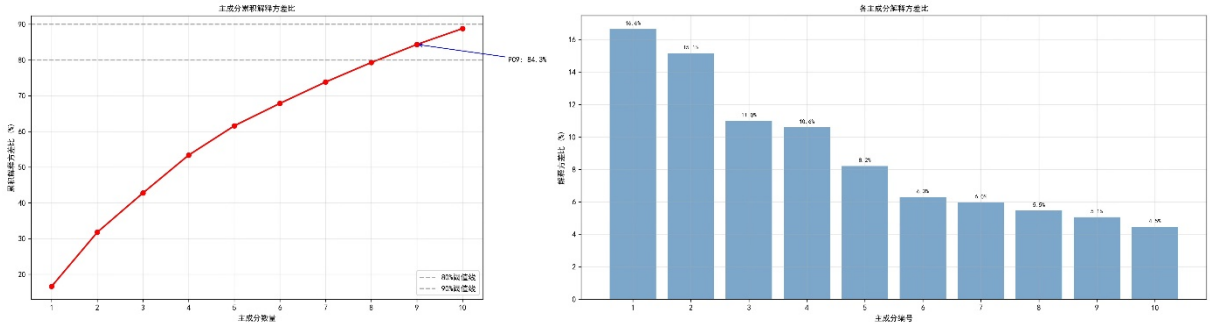


图20　主成分分析方差总体解释比（左）与各自解释比（右）

在此，我们提取的主成分特征根应大于所有主成分特征根的平均值，在此由于进行了标准化处理。分析上图可知，当 X≤10 时相应的特征值满足解释率大于 85%的条件，故选取前十个维度作为核心主成分解释值来代表。

8.2.3. XGBoost 模型预测

由上述可知我们在此提取并保留了解释比占前十的主成分数据，将其作为后续集成学习模型的输入数据，详细地 XGBoost 模型构建流程沿用了模型三的构建方式，但需要注意的一点，在模型三中我们仅使用 XGBoost 来拟合模型一中分式模型预测的残差，但是由于此问中考察的是“女胎检测数据”，原先的基础模型不太适用，想要单纯从生理学意义出发获得表达式又缺乏理论依据，所以本模型中可以直接利用 XGBoost 拟合前文中进行编码处理的“染色体非整数倍”。如此既能最大程度上保证模型的完整性，同时尽可能多地容纳多变量的不同特征对预测目标的作用。

相关参数为：分类器的树的数目为 40 棵、每棵树的最大深度为 6、学习率为 0.1、随机数种子取 42、将训练指标定为 Logarithmic loss 即对数损失函数。

8.3. 结果呈现与总结分析

依照前文所述的完整模型构建，包括主成分分析的特征提取以及 XGBoost 集成学习的全流程，将多维预测结果的混淆矩阵呈现如上图。分析图片中的数据，经过预测结果与实际标签的交叉整合，还可以计算得到下列反映预测效果的数据，呈现如下表。其中准确率可以由下式计算得到（本问中计算得到 Accuracy=99.41%）：

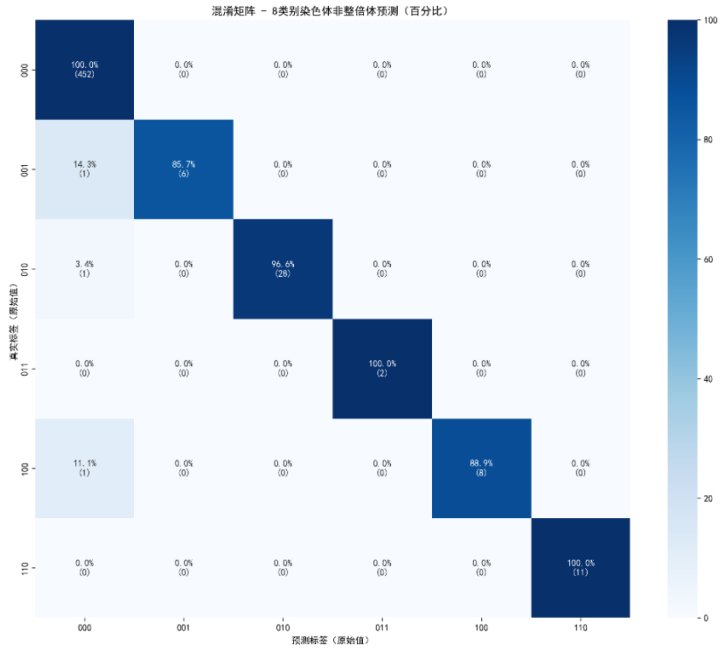


图21　XGBoost 模型预测结果混淆矩阵

$$\text{Accuracy} = \frac{\sum_{i=1}^{N} \text{TP}_i}{\text{Total Samples}}, \quad i = 1, 2, ..., 6$$

其中TP_i为对角线上的所有数据，而精确率和召回率的计算则需要针对每一个类别进行分别计算，后再通过某种方式合并为最终指标。对于“宏观平均”，整合方式为直接取平均值，对于“加权平均”，则是根据每个类别的样本数量进行加权来计算平均值，更侧重于样本量大的类别对整体性能的贡献。

表16　XGBoost 模型预测结果指标衡量

指标	宏观平均精确率	宏平均召回率	宏平均 F1-Score
数值	99.93%	95.20%	97.41%
指标	加权平均精确率	加权平均召回率	加权平均 F1-Score
数值	99.61%	99.41%	99.41%

以上数据说明，在 8 类别非整倍体分类任务中，模型的预测性能非常优异。混淆矩阵的记过显示，其总体准确率达到 99.41%，在绝大多数类别上实现了近乎完美的预测。仅在少数类别（如 001、100）存在极个别的错分情况，但整体分类的置信度极高。说明这种基于主成分优化的集成学习模型可以很有效地帮助女胎孕妇检测出来是否有基因以及具体的异常基因种类，在临床学与医学工程上均具有重要意义，可以帮助孕妇尽早地准确查明胎儿的健康状况，有助于尽早进行治疗，即保护了孕妇的身体健康，降低了孕期的风险，也有助于实现诊断准确，胎儿健康，家庭幸福，促进社会和谐稳定。

9. 总结与展望

9.1. 评估与评价

9.1.1. 模型优势

综上所述，本文所设计的四项模型优势明显，优点突出，可整理成一下三点：

1、模型整体连贯性强，可以从不同角度不断进行优势的集中，互为补充共同发挥作用。从模型一中的基础生理学分式计算式入手，到模型二的风险损失函数，再到模型三利用 XGBoost 集成学习对残差进行优化与趋势的拟合，在男胎的最优检测时间上不断优化，具有显著的效果。

2、模型的敏感性分析方法独特，可以对于不同采样数据情境下给予合适的误差扰动，使得敏感性分析的意义更加科学有效，对于模型效果的评估更加准确，且具有良好的拓展性，可以迁移至其他的评价场景。

3、模型的目标函数是考虑了波动性的风险损失函数，源自于我们对于现实情境中不可避免的误差项的考察，通过对“脆弱的局部最优解”添加惩罚项，可以提升模型的鲁棒性和面对复杂环境的稳定性。

9.1.2. 劣势与改进方向

1、对风险损失函数$R(t_x)$只是进行了初步的分段式的划分，不具有连续性，还可以进一步改良，使得其可以更细致地对风险进行量化评估。

2、本文的模型二在利用改进的差分进化算法求解最优建议 NIPT 时间时，可以将 BMI 分组阈值也加入进化算法的优化范畴，使得整体更具有连贯性与完整性。

9.2. 拓展与创新

本团队围绕 NIPT 检测时点选择与胎儿异常判定所构建的数学模型，充分融合了孕妇 BMI、孕周、胎儿染色体浓度及多种生物信息学指标，建立了动态化、个性化的最优检测时间推荐与风险预警体系。该模型不仅在理论层面显著提升了检测的准确性与时效性，更具备强大的跨领域迁移能力，为精准医疗的实践提供了可推广的范式。在临床应用中，该模型可无缝**集成至妇幼健康管理平台，形成智能决策支持系统**，协助医生为不同体质的孕妇制定个体化产前筛查方案，极大降低因检测时机不当导致的误诊与治疗窗口延误风险。

更进一步，本建模成果的核心方法论，即“基于多维度生物特征进行人群分层、并优化关键时间节点的策略”，可广泛拓展至**其他重大疾病的早期筛查与健康管理领域**。例如，在肿瘤早筛、慢性病管理等工作中中，能为患者提供个性化的体检频率与项目建议，实现疾病风险的前瞻性防控。此外，模型中所引入的数据质量控制机制、误差传播分析及统计显著性检验方法，也为生物医学大数据分析提供了可靠的技术框架，适用于基因组学、流行病学监测等多类数据驱动型应用场景，具备高度的实际应用价值与行业推广潜力。

10. 参考文献

[1] Shtumpf M, Piroeva K V, Agrawal S P, Jacob D R, Teif V B. NucPosDB: a database of nucleosome positioning in vivo and nucleosomics of cell-free DNA[J]. Chromosoma, 2022, 131(1): 19-28. DOI:10.1007/s00412-021-00763-6.

[2] Aliyu M H, Salihu H M, Keith L G, Ehiri J E, Islam M A, Jolly P E. High

parity and fetal morbidity outcomes[J]. *Obstetrics and Gynecology*, 2005, 105(5 Pt 1): 1045-1051. DOI:10.1097/01.AOG.0000157444.74674.75. PMID:15863543.

[3] Bonett D G, Wright T A. Sample size requirements for estimating Pearson, Kendall and Spearman correlations[J]. *Psychometrika*, 2000, 65: 23-28. DOI:10.1007/BF02294183.

[4] Schmid F, Schmidt R. Multivariate extensions of Spearman's rho and related statistics[J]. Statistics & Probability Letters, 2007, 77(4): 407–416. DOI:10.1016/j.spl.2006.08.007.

[5] Kazemi N Y, Fedyshyn B, Yelsa I, Fedyshyn Y, Ruano R, Markovic S N, Chakraborty R, Enninga E A L. Increased cell-free fetal DNA release after apoptosis and sterile inflammation in human trophoblast cells[J]. *American Journal of Reproductive Immunology*, 2021, 86(5): e13483. DOI:10.1111/aji.13483. PMID:34233077; PMCID:PMC8541917.

[6] Hou Y P, Yang J X, Qi Y M, et al. Factors affecting cell-free DNA fetal fraction: statistical analysis of 13,661 maternal plasmas for non-invasive prenatal screening[J]. *Human Genomics*, 2019, 13: 62. DOI:10.1186/s40246-019-0244-0.

[7] Ju J, Li J, Liu S, et al. Estimation of cell-free fetal DNA fraction from maternal plasma based on linkage disequilibrium information[J]. *NPJ Genomic Medicine*, 2021, 6: 85. DOI:10.1038/s41525-021-00247-z.

[8] Fumagalli M. Assessing the effect of sequencing depth and sample size in population genetics inferences[J]. *PLoS ONE*, 2013, 8(1): e79667. DOI:10.1371/journal.pone.0079667.

[9] Lin H, Cheung W K, Chen S, et al. Molecular diagnosis of sex chromosome aneuploidy using quantitative PCR[J]. *Genetic Testing and Molecular Biomarkers*, 2011, 15(6): 459-463. DOI:10.1089/gtmb.2010.0213.

本参赛队未使用任何 AI 工具。

11. 附录

11.1. 附录 1 支撑材料目录

支撑材料
├──第一问代码
│　　correlation_analysis.py
│　　fitting_analysis.py
│　　分组拟合分析图.png
│　　分组拟合结果.xlsx
│　　数据清洗后的数据.xlsx
│　　残差分析.py
│　　相关性分析结果.xlsx
│　　
│　　└──残差分析
│　　　　01_直方图与正态分布拟合.png
│　　　　02_累积分布函数比较.png
│
├──第二问代码
│　　BMI 聚类结果.xlsx
│　　calculate_4percent_time.py
│　　calculate_y_chromosome_error.py
│　　confusion_matrix.png
│　　extract_pregnancy_data.py
│　　extract_topsis_data.py
│　　feature_importance.csv
│　　feature_importance.png
│　　kmeans_bmi_analysis.py
│　　topsis_entropy_analysis.py
│　　TOPSIS 熵权法评价结果.xlsx
│　　xgboost_model.json
│　　Y 染色体浓度 4%时间计算结果.xlsx
│　　优化_扰动前.py
│　　优化_扰动后.py
│　　分组拟合结果.xlsx
│　　加操作误差数据.xlsx

```
|   |   孕妇待分组数据.xlsx
|   |   孕妇扰动后数据.xlsx
|   |   孕妇操作误差数据.xlsx
|   |   对达到 4%浓度的孕期天数扰动.py
|   |   差分进化目标函数收敛曲线.png
|   |   待计算误差数据.xlsx
|   |   扰动前数据_含标准差.xlsx
|   |   数据提取合并程序.py
|   |   数据清洗后的数据.xlsx
|   |   计算每人操作误差.py
|   |
|   ├──clustering_plots
|   |       01_轮廓系数分析.png
|   |       02_层次聚类树状图.png
|   |       03_聚类结果散点图.png
|   |
|   └──迭代过程分析
|           差分进化目标函数收敛曲线_扰动前.png
|           差分进化目标函数收敛曲线_扰动后.png
|
├──第三问代码
|   |   calculate_residual_average.py
|   |   calculate_target_concentration_time.py
|   |   extract_optimization_data.py
|   |   xgboost_model.pkl
|   |   XGBoost_预测结果.xlsx
|   |   XGboost 拟合残差.py
|   |   xgboost 效果分析.png
|   |   Y 染色体浓度 4%时间计算结果.xlsx
|   |   优化_扰动前.py
|   |   优化_扰动后.py
|   |   分组拟合结果 copy.xlsx
|   |   分组拟合结果.xlsx
|   |   分组拟合结果_preXGboost_processed.xlsx
|   |   加操作误差数据.xlsx
|   |   孕妇待优化数据.xlsx
```

```
│   │   孕妇扰动后数据.xlsx
│   │   孕妇操作误差数据.xlsx
│   │   孕妇预测残差平均值.xlsx
│   │   对达到 4%浓度的孕期天数扰动.py
│   │   扰动前数据_含标准差.xlsx
│   │   数据提取合并程序.py
│   │   目标浓度时间计算结果.xlsx
│   │   计算每人操作误差.py
│   │
│   └──迭代过程分析
│           差分进化目标函数收敛曲线_扰动前.png
│           差分进化目标函数收敛曲线_扰动后.png
│
├──第四问代码
│   │   pca_analysis.py
│   │   pca_visualization.py
│   │   PCA 分析结果_85percent.xlsx
│   │   process_female_data.py
│   │   topsis_entropy_analysis.py
│   │   TOPSIS 熵权法评价结果.xlsx
│   │   xgboost_prediction.py
│   │   XGBoost 预测结果.xlsx
│   │   女胎检测数据_处理后.xlsx
│   │   女胎检测数据_处理后_加误差.xlsx
│   │   待计算误差数据.xlsx
│   │   数据清洗后的数据.xlsx
│   │
│   ├──PCA 结果
│   │       PCA_累积解释方差比.png
│   │       PCA_解释方差比.png
│   │
│   └──XGBoost 结果分析
│           confusion_matrix_percent.png
│           confusion_matrix_raw.png
│           feature_importance.csv
│           feature_importance.png
```

```
|
└──预处理可视化图片
        不同怀孕次数_胎儿实际健康率_女.png
        不同怀孕次数_胎儿实际健康率_男.png
        不同生产次数_胎儿实际健康率_女.png
        不同生产次数_胎儿实际健康率_男.png
        动态 IQR 汇总分析_1.png
        动态 IQR 汇总分析_2.png
        动态 IQR 箱线图对比分析_1.png
        动态 IQR 箱线图对比分析_2.png
        女胎_染色体 Z 值分布图.png
        女胎检测数据_X 染色体 Z 值分布.png
        妊娠类型占比统计女胎.png
        妊娠类型占比统计男胎.png
        异常值百分比折线图.png
        染色体 GC 箱线图.png
        男胎_染色体 Z 值分布图.png
        男胎检测数据_X 染色体 Z 值分布.png
```

11.2. 附录 2 代码运行顺序及代码作用说明

注意下载所需的库，而后按如下顺序依次运行代码。

Step1 第一问代码

correlation_analysis.py 相关性分析

fitting_analysis.py，残差分析.py 拟合与显著性检验

Step2 第二问代码

calculate_4percent_time.py 反算 GA

extract_topsis_data.py，topsis_entropy_analysis.py，calculate_y_chromosome_error.py，计算每人操作误差.py 计算操作误差

数据提取合并程序.py，对达到 4%浓度的孕期天数扰动.py 对 GA 做扰动

extract_pregnancy_data.py 完成数据整理，为后续聚类和优化做准备

kmeans_bmi_analysis.py 聚类

优化_扰动前.py 对扰动前数据优化

优化_扰动后.py 对扰动后数据优化

Step3 第三问代码

XGboost 拟合残差.py 拟合残差

calculate_residual_average.py，calculate_target_concentration_time.py，extract_optimization_data.py 计算得纠偏后的 GA

计算每人操作误差.py 计算每个人的操作误差

数据提取合并程序.py，对达到 4%浓度的孕期天数扰动.py 做扰动

优化_扰动前.py 对扰动前数据优化

优化_扰动后.py 对扰动后数据优化

Step4 第四问代码

process_female_data.py 整理女胎数据，为后续 PCA 和 XGBoost 做准备

topsis_entropy_analysis.py 计算误差相对值（排序）

pca_analysis.py，pca_visualization.py 计算分析 PCA（跑 PCA，可视化）

xgboost_prediction.py 用 XGBoost 进行预测

11.3. 附录 3 自编程序代码（部分，具体见支撑材料）

优化_扰动前.py（第二问代码）

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from matplotlib import rcParams
import warnings
import os
warnings.filterwarnings('ignore')

# 设置中文字体
rcParams['font.sans-serif'] = ['SimHei', 'DejaVu Sans']
rcParams['axes.unicode_minus'] = False

class FixedBMIDEOptimizer:
    def __init__(self, data, p, delta, max_iterations=50, population_size=30):
        self.data = data
        self.p = p
        self.delta = delta
        self.j = delta / p
        self.max_iterations = max_iterations
        self.population_size = population_size

        # 提取 BMI 和孕期天数数据
```

```
        self.bmi = data['平均 BMI'].values
        self.pregnancy_days = data['达到 4%浓度的孕期天数'].values
        self.k = len(self.bmi)  # 孕妇数量

        self.bmin = np.min(self.bmi)
        self.bmax = np.max(self.bmi)

        # 固定的 BMI 分组边界（3 段）
        self.fixed_boundaries = [32.20, 38.165]
        self.b_values = np.array([32.20, 38.165, self.bmax])  # 三段的上边界

        # 差分进化参数
        self.F = 0.8  # 缩放因子
        self.CR = 0.9  # 交叉概率

        # t 值的搜索边界（3 个 t 值）
        self.t_bounds = [(1, 300), (1, 300), (1, 300)]  # 每个 t 值的上下界

    def enforce_monotonic_t(self, t_values):
        """强制 t 值单调递增并确保为整数"""
        # 首先将 t 值四舍五入为整数
        t_constrained = np.round(t_values).astype(int).astype(float)
        n = len(t_constrained)

        # 从左到右扫描，确保单调递增
        for i in range(1, n):
            if t_constrained[i] <= t_constrained[i-1]:
                t_constrained[i] = t_constrained[i-1] + 1.0

        # 从右到左再次调整，避免某些组的 t 值过大
        for i in range(n-2, -1, -1):
            if t_constrained[i] >= t_constrained[i+1]:
                t_constrained[i] = max(1.0, t_constrained[i+1] - 1.0)

        # 最终检查并微调，确保为整数
        for i in range(1, n):
            if t_constrained[i] <= t_constrained[i-1]:
                t_constrained[i] = t_constrained[i-1] + 1.0

        # 确保所有值都是整数
        t_constrained = np.round(t_constrained).astype(int).astype(float)

        return t_constrained
```

```
    def assign_groups_fixed(self):
        """根据固定的 BMI 边界分配每个孕妇到相应组别"""
        group_assignments = np.zeros(self.k, dtype=int)

        for k in range(self.k):
            bmi_k = self.bmi[k]
            if bmi_k <= 32.20:
                group_assignments[k] = 0  #  第 1 组
            elif bmi_k <= 38.165:
                group_assignments[k] = 1  #  第 2 组
            else:
                group_assignments[k] = 2  #  第 3 组

        return group_assignments

    def calculate_R(self, tx, t0k):
        """计算函数 Rk(tx)"""
        if tx < t0k:
            return t0k - tx
        elif tx > t0k:
            if 0 < tx < 84:
                return  0.05*(tx - t0k)
            elif 84 <= tx <= 189:
                return  (tx - t0k)
            elif tx > 189:
                return  10*(tx - t0k)
        else:  # tx == t0k
            return 0

    def objective_function(self, t_values):
        """计算目标函数 H(3) -  只优化 t 值"""
        #  使用固定的分组分配
        group_assignments = self.assign_groups_fixed()

        total_cost = 0

        for k in range(self.k):
            wk = group_assignments[k]
            twk = t_values[wk]
            t0k = self.pregnancy_days[k]        //……后续代码省略，见附件
```